

Министерство образования и науки Российской Федерации  
Северо-Восточный федеральный университет имени М.К. Аммосова  
Институт математики и информатики

*Н. М. Охлопков, Ф. В. Иванов*

# **ЧИСЛЕННЫЕ МЕТОДЫ И ВЫЧИСЛИТЕЛЬНЫЕ АЛГОРИТМЫ**

Якутск  
2018

**УДК 519.6 (075.8)**

**ББК 22.193 Я73**

**О92**

**Рецензенты:**

*П.П. Пермяков, д.ф.-м.н., ведущий научный сотрудник ИФТПС СО РАН;*

*Н.П. Старостин, д.т.н., зав. лабораторией ИПНГ СО РАН*

***Охлопков, Н.М.***

**Численные методы и вычислительные алгоритмы** [электронный ресурс] : учебное пособие / Н.М. Охлопков, Ф.В. Иванов. – Якутск : Издательский дом СВФУ, 2018. – 1 электрон. опт. диск.

ISBN 978-5-7513-2471-1

*В учебном пособии изложена история и методология вычислительной математики, рассмотрены некоторые вопросы теории погрешностей, вычислительная задача и вычислительный алгоритм, обусловленность вычислительной задачи, численные методы решения некорректных задач математической физики.*

*Предназначено студентам, изучающим курсы «Методы вычислений», «Численные методы», «Вычислительная математика», также материалы пособия можно использовать для проведения научно-практических расчетов на ЭВМ.*

УДК 519.6 (075.8)

ББК 22.193 Я73

© Северо-Восточный федеральный университет, 2018

ISBN 978-5-7513-2471-1

© Охлопков Н.М., Иванов Ф.В., 2018

## ОГЛАВЛЕНИЕ

|                                                                                                 |     |
|-------------------------------------------------------------------------------------------------|-----|
| Введение .....                                                                                  | 5   |
| Глава 1. История и методология вычислительной математики .....                                  | 9   |
| § 1. История вычислительной математики .....                                                    | 9   |
| § 2. Методологические вопросы вычислительной математики .....                                   | 28  |
| Литература.....                                                                                 | 41  |
| Глава 2. Некоторые вопросы теории погрешностей.....                                             | 43  |
| § 1. Абсолютная и относительная погрешность .....                                               | 43  |
| § 2. Десятичная запись приближенных чисел.<br>Значащая цифра числа. Верная значащая цифра. .... | 47  |
| § 3. Округление чисел .....                                                                     | 51  |
| § 4. Связь между числом верных знаков<br>и относительной погрешности числа .....                | 54  |
| § 5. Погрешность суммы и разности .....                                                         | 56  |
| § 6. Погрешность произведения. Погрешность частного.<br>Относительная погрешность корня .....   | 61  |
| § 7. Общая формула для погрешности .....                                                        | 65  |
| § 8. Погрешность функции .....                                                                  | 66  |
| § 9. Общие правила проведения вычислений.....                                                   | 68  |
| § 10. Обратная задача теории погрешностей.....                                                  | 69  |
| § 11. Погрешности вычислений на ЭВМ .....                                                       | 70  |
| Литература.....                                                                                 | 73  |
| Глава 3. Вычислительная задача и вычислительный алгоритм .....                                  | 74  |
| § 1. Вычислительная задача.....                                                                 | 74  |
| §2. Корректность вычислительной задачи.....                                                     | 76  |
| §3. Обусловленность вычислительной задачи .....                                                 | 80  |
| § 4. Об алгоритмах вычислительной математики .....                                              | 86  |
| Литература.....                                                                                 | 103 |
| Глава 4. Обусловленность вычислительной задачи .....                                            | 105 |
| § 1. Обусловленность задачи решения<br>системы линейных алгебраических уравнений.....           | 105 |

|                                                                                                             |     |
|-------------------------------------------------------------------------------------------------------------|-----|
| § 2. Чувствительность итерполяционного многочлена<br>к погрешностям входных данных .....                    | 124 |
| § 3. Обусловленность задачи минимизации .....                                                               | 125 |
| § 4. Обусловленность формул численного дифференцирования.....                                               | 127 |
| § 5. Обусловленность задачи вычисления корня .....                                                          | 131 |
| § 6. Распространение ошибок в начальных данных при решении<br>обыкновенных дифференциальных уравнений ..... | 135 |
| Литература.....                                                                                             | 137 |
| Глава 5. Численные методы решения некорректных задач<br>математической физики .....                         | 138 |
| § 1. Понятие о корректно и некорректно поставленных задачах<br>математической физики .....                  | 138 |
| § 2. Метод регуляризации М. М. Лаврентьева .....                                                            | 145 |
| § 3. Метод квазиобращения .....                                                                             | 147 |
| § 4. Приближенные методы решения некорректных задач .....                                                   | 148 |
| § 5. Уравнение теплопроводности с обратным временем.....                                                    | 155 |
| § 6. Выбор параметра регуляризации .....                                                                    | 157 |
| § 7. Численная реализация метода квазиобращения .....                                                       | 159 |
| § 8. Метод расщепления для схемы квазиобращения .....                                                       | 162 |
| § 9. Псевдопараболическая регуляризация.....                                                                | 163 |
| § 10. Метод итерационной регуляризации .....                                                                | 165 |
| § 11. Метод нелокального возмущения начальных условий .....                                                 | 167 |
| § 12. Численная реализация метода квазиобращения<br>для двумерного уравнения теплопроводности.....          | 170 |
| § 13. Прием расщепления разностного оператора четвертого<br>порядка для метода квазиобращения .....         | 172 |
| § 14. Второй вариант метода квазиобращения .....                                                            | 174 |
| § 15. Псевдопараболическая регуляризация<br>для двумерного уравнения.....                                   | 176 |
| § 16. Итерационное уточнение начального условия.....                                                        | 177 |
| Литература .....                                                                                            | 178 |

## ВВЕДЕНИЕ

Методологические проблемы математики не могут быть решены вне связи с ее историей. Важной частью методологии математики является учение о методе, о специфическом для этой науки способе исследования объективной реальности. Знание методологии математики позволяет человеку, работая с абстракциями, формальными методами и моделями, характерными для современного этапа развития математики, видеть за ними реальную действительность, изучение которой привело к созданию этих моделей и абстракций, и в то же время понимать относительную самостоятельность математики как особой формы познания действительности. Основным методом получения теоретических математических результатов является логический вывод, не опирающийся на экспериментальную проверку.

Математика обладает свойством универсальной применимости. При этом, чем более отвлеченными от содержания являются используемые в исследовании понятия и методы, тем шире область возможных применений этих методов. В любой области, где только удастся математически поставить задачу, математика дает результат с точностью, соответствующей точности постановки задачи.

Свойства и отношения материальных объектов, чтобы считать предметом математического исследования, должны быть абстрагированы от их вещественного содержания, абстрагирует эти отношения и формы и делает их объектом математического исследования. Однако в математическом мире существует ряд объектов и отношений, математическое описание которых не сводится в чистом виде к количественным отношениям и пространственным формам. Таким образом, в предмет математики теперь входят не только количественные отношения и пространственные формы материального мира, а любые формы и отношения, взятые в отвлечении от их содержания.

В отличие от других наук о природе, исследующих различные формы движения материи, математика изучает формы и отношения материального мира, взятые в отвлечении от содержания. Математика не изучает никакой особой формы движения материи и, следовательно, не может рассматриваться как одна из естественных наук.

Математика занимает особое положение в системе наук - ее нельзя отнести ни к гуманитарным, ни к естественным наукам. Она дает те основные понятия, которые используются почти во всех науках. Математика - фундаментальная наука, представляющая языковые средства другим наукам, тем самым она выявляет их структурную взаимосвязь и способствует нахождению самых общих законов природы.

Математика изучает воображаемые, идеальные объекты и соотношения между ними, используя формальный язык. В общем случае математические понятия и теоремы не обязательно имеют соответствие чему-либо в физическом мире.

Основным содержанием классической математики является исследование ее собственных закономерностей, а прикладная математика нацелена на решение "внешних", по отношению к математике, задач. Прикладная математика является теоретической основой любой специальной области знания. Развитие теоретических основ специальных дисциплин тесным образом связаны с развитием прикладной математики, что в ряде случаев оказывается затруднительным провести четкую границу между ними.

Главная задача математика-прикладника – создать математическую модель, достаточно адекватную исследуемому реальному объекту. Задача математика-теоретика – обеспечить достаточный набор удобных средств для достижения этой цели.

Прикладники – это специалисты, использующие достижения математики в нематематических целях, допуская для обоснования своих действий привлечение нематематических средств. Математическое решение прикладных задач обладает специфическими особенностями.

Здесь принципиально недостижима доказательность того уровня, что в чисто математических исследованиях.

Если "чистый" математик категорически исключает возможность привлечения к рассуждениям и доказательствам аргументации нематематического характера, прикладной математик считает допустимым пользоваться для достижения поставленной цели любыми средствами, принимая во внимание весь накопленный практический опыт.

Практическое использование результатов теоретического математического исследования требует получения ответа на поставленную задачу в числовой форме. Между тем даже после исчерпывающего теоретического разбора задачи, это часто оказывается весьма трудным делом. Зародившаяся в конце XIX - начале XX вв. численные методы анализа, алгебры выросли в связи с созданием и использованием ЭВМ в самостоятельную ветвь математики – вычислительную математику.

С появлением ЭВМ произошли существенные изменения в языке математики. Если язык классической вычислительной математики состоял из формул алгебры, геометрии и анализа, ориентированный на описание непрерывных процессов природы, изучаемых естественными науками, то современный ее язык - это язык алгоритмов и программ, включающий старый язык формул в качестве частного случая. Широкое применение ЭВМ привело к необходимости исследовать реальные процессы с помощью дискретного представления математических моделей. "Дискретность структуры материальных тел - это одна из основных особенностей материи, без учета которой невозможно описать ее диалектическую противоречивость, сколько-нибудь детально изучить ее свойства. И в то же время игнорирование этого факта привело к созданию математики континуума, которая оказалась одним из величайших достижений человеческого гения <sup>1\*</sup>.

Тенденция развития современной математики состоит в усилении прикладной ветви математического знания. Это видно в расширении влияния вычислительно-алгоритмического направления с применением

ЭВМ. Теоретические и прикладные исследования имеют тенденцию к сближению между собой на основе математических моделей конкретных наук. Это сопровождается перестройкой учебного процесса, отходом от сложившихся стандартов доказательности и единство математического знания все более восстанавливается в процессе алгоритмизации и построения математических модулей, т.е. к арифметико-алгебраическому строению, к повышению роли вычислительной математики. Обучение закрепляет целостность математического знания и устраняет противопоставление теоретического и практического знания, которые имеют тенденцию к объединению в едином комплексе единой и неделимой математики.

Существенные изменения происходят в учебных планах всех специальностей в сторону усиления вычислительно-алгоритмического блока на базе математических моделей реальных и абстрактных объектов. В связи с этим происходят серьезные изменения в области подготовки кадров. Настоятельной необходимостью становится воспитание специалистов, занимающихся созданием и анализом математических моделей, которые будут определять, в конечном счете, лицо современной математики. В процессе обучения любой учебной дисциплине реализуются идеи развития творческой личности студентов. При этом, важное значение имеют: знания исторических предпосылок создания и развития вычислительной математики, ее вклада в научно-технический прогресс человеческого общества.

**1\***. Рождественский К. В., Патрушев Л.А. Некоторые вопросы мировоззренческой подготовки студентов исследовательских специальностей. – Ленинград, ЛКИ, 1984 – с. 23.



# **Глава 1. ИСТОРИЯ И МЕТОДОЛОГИЯ ВЫЧИСЛИТЕЛЬНОЙ МАТЕМАТИКИ**

## **§ 1. История вычислительной математики**

**1.** В Древнем Египте и Вавилонии весь познавательный процесс проходил путем вычислений, вычислением решали все хозяйственные вопросы - площади земельных участков, объемы простых тел, вопросы орошения, строительства, навигации и т. д. Задачи решались арифметически. Геометрия не выделялась в самостоятельную область знания. Классификация задач осуществлялась не по методам, а по их прикладной тематике. Геометрические знания проявлялись в процессе земледельческой практики, а арифметические знания возникли из пересчета предметов, отношений обмена.

Общими источниками возникновения математических знаний являются: астрономические наблюдения, практика сбора налога и урожая, письменная фиксация результатов хозяйственной деятельности, которые были закреплены обучением. В процессе обучения появляются новые задачи, не вытекающие из практики. Например, обратные задачи, которые используются для проверки правильности решения прямой задачи. Таким образом, постепенно происходит внутреннее расслоение типов задач с акцентированием внимания на общих методах решения типовых задач. Постепенно убеждаются в том, что для однотипных задач сходных объектов, отличающихся только размерами и числовыми коэффициентами, используемые понятия операций одинаково применимы и произошло отождествление принципов решения подобных геометрических и аналогичных числовых задач.

На первом этапе развития математики вычисления не нуждались в своем теоретическом обосновании. При этом орудием счета были пальцы человека, т. е. счет на пальцах. Искусство счета складывалась и развивалась в течении многих веков. Важную роль в развитии и усовер-

шенствовании практики вычислений играли различные системы счисления.

Иероглифическая система счисления египтян была аддитивной. Все вычислительные процедуры были основаны на сложении и решали задачи типа: "сколько надо еще прибавить, чтобы получить известный результат?" На этой системе счисления сложение и вычитание натуральных чисел производилось просто, а умножение и деление оставались еще громоздкими. Всякую дробь древние египтяне представляли в виде суммы конечного числа аликвотных дробей, т. е. дробей вида  $\frac{1}{n}$  с различными знаменателями.

В Вавилонии в результате долгого развития математики сложилась оригинальная шестидесятиричная позиционная система счисления. Чтобы облегчить выполнение арифметических операций вавилоняне пользовались многочисленными таблицами: умножения, обратных величин, квадратов, квадратных и кубических корней и другими. Решали задачи на суммирование квадратов натуральных чисел, арифметические прогрессии, вычисление процентов, решение квадратных и биквадратных уравнений. Для вычисления квадратных корней вавилоняне изобрели итерационный процесс: новое приближение получалось из предыдущего по формуле:

$$a_{n+1} = \frac{a_n + \frac{N}{a_n}}{2}, n = 0, 1, \dots$$

2. Древние греки, начиная с V века до н.э., определяли число как собрание единиц, т. е. как натуральное число. Греки дроби не считали числами.

Одним из важных открытий пифагорейцев было открытие иррационального в виде несоизмеримых отрезков. Из соотношения стороны и диагонали квадрата было обнаружено, что такое отношение не выражается "числами", т. е. рациональным числом (целым или дробным числом). Пифагорейской арифметикой допускались только рациональные числа. Тем самым был открыт факт, что некоторые отношения нельзя

выразить с помощью целых чисел. Это открытие противоречило пифагорейской точке зрения о представимости мира с помощью целых чисел и вызвало первый кризис в истории математики.

Математики стали задумываться над разрешением кризиса в основаниях математики. Основой математики выбрали геометрию, которая сумела выразить отношения, невыразимые с помощью арифметики чисел и их отношений.

Открытие несоизмеримостей не только стимулировало ученых к исследованию иррациональных объектов, но обогатили и вычислительную математику. Появились такие понятия, как приближенные числа, приближенные решения, погрешность приближенных чисел и их оценки. Древнегреческие ученые четко различали понятия “равно” и “приближенно равно”. Эти понятия за последние две тысячи лет не протерпели существенных изменений. Если число не могли вычислить точно, то важно было знать ошибку при расчетах, математики определяли точные границы, в которых лежит это число. Например, Архимед вычислил довольно точную границу для числа  $\pi$ :

$$3\frac{10}{71} < \pi < 3\frac{1}{7}$$

с двумя верными значащими цифрами. Иногда решали и гораздо более сложную обратную задачу: зная предельную допустимую ошибку результата, определяли, с какой точностью необходимо вычислять (измерять) исходные данные.

В IV веке до н. э. Евдокс дал общую теорию пропорций. Евдоксова теория отношений покончила с арифметической теорией пифагорейцев, применимой только к соизмеримым величинам. Эта геометрическая теория сделала излишними какие-либо оговорки относительно несоизмеримости или измеримости рассматриваемых величин. Евклид писал: “Новое, более широкое понимание пропорций означало, что здесь по сути дела закладываются новые основания математики, новые представления об ее исходных понятиях, где иррациональные величины уже

охвачены ими”. Тем не менее, следует подчеркнуть, что построенный впервые Евдоксом теории действительного числа не хватало гибкости и не способствовала развитию вычислительной техники, и особенно алгебраического исчисления.

Греческие математики сознательно отмежевались от “логистов” (профессиональных вычислителей), которые, так же как и их египетские и вавилонские предшественники, не задумываясь, рассматривали дробь как число.

“Отношения” Евдокса чаще всего назывались “числами”; к ним применяли правила исчисления целых чисел, таким образом, получали точные результаты, не стремясь доискиваться причин успеха этих приемов.

Характерной особенностью для более древних культур является единство научных знаний и практических приложений. Эта традиция в античной греческой математике нарушается: достойной для развития философского ума наукой считается геометрия, а всякого рода исчисления (алгебра и арифметика), философия Платона не считала достойным предметом науки. Платон высмеивал вычислителей, “которые разменивают единицу на мелкую монету” и говорит, что там, где они делят ученым умножают. Например, для математиков, равенство двух отношений

$$\frac{a}{b} \text{ и } \frac{c}{d}$$

устанавливается не путем деления  $a$  на  $b$  и  $c$  на  $d$ , что ведет к исчислению дробей, а путем проверки условия:

$$a * d = b * c.$$

**3.** Со второго века развитие классических направлений греческой математики почти полностью останавливается. Развиваются такие направления, как: сферическая геометрия (Менелай, первая неевклидова геометрия), тригонометрия хорд (Птолемея), приближенные вычисления (Герон). Интересы математиков склоняются в сторону вычислительной математики.

Герон предлагает различные вычислительные алгоритмы решения математических задач, трактует дроби и иррациональности по существу как числа и интересуется метрическими свойствами геометрических фигур. Начинают развиваться: числовая алгебра линейных, квадратных уравнений, решение неопределенных уравнений в рациональных числах, создаются элементы алгебраической символики.

Диофант (III в.) формально воспроизводя евклидово определение числа, фактически понимает под числом неизвестное в алгебраических задачах, решение которых может быть целым числом, или дробью, или даже иррациональным числом. Он уже не делает различия между натуральными числами и дробями, называя те и другие числами. Диофант вводит отрицательные числа, называя их недостатками, и чисто аксиоматически определяет правила действий с ними и знает о существовании иррациональных чисел.

Следует отметить, что дробные и иррациональные числа с самого момента своего возникновения связаны с измерением непрерывных величин. Отрицательные числа возникают в основном из внутренних потребностей алгебры и лишь позднее получают самостоятельное значение.

**4.** После краха античного рабовладельческого общества развитие математики на долгие века происходило в странах Востока (Китай, Индия, Ближний и Средний Восток). Математика в странах Востока представляла собой учение в постоянных величинах и неизменных геометрических фигурах.

Систематизация математических знаний происходит вычислительно-алгоритмическим способом. Центральным ядром в этой систематизации выступает вычислительный алгоритм. Вычислительно-алгебраическая направленность усиливает лишь алгоритмический подход.

Практические потребности требовали решать задачи: коммерческой арифметики, задачи налогообложения, строительных сооружений,

раздел наследства, торговля, практическая астрономия, мореплавание, судостроение, измерение углов при стрельбе, измерение расстояния до недоступного предмета и т. д.

Практика в средние века дает мощный толчок развитию математики и в то же время главная проблема для математики средних веков – это проблема практики, отсюда и вычислительное направление развития математики.

Типы задач группируются вокруг задач практики. Отсюда видно, что математика средних веков подчинена практической деятельности. Таким образом, для практической математики средних веков структурообразующими элементами были непосредственные практические потребности.

Для численного решения различного рода прикладных задач выделились типичные задачи: на пропорции, линейные уравнения и их системы, извлечение квадратных и кубических корней, квадратные и кубические уравнения.

В Древнем Китае о состоянии вычислительной математики можно судить по книге “Математика в девяти книгах” (II – I вв. до н. э.). Эта книга явилась руководством для землемеров, астрономов, чиновников и содержит правила действий с дробями и отрицательными числами, пропорции, прогрессии, правила извлечения квадратных и кубических корней.

В восьмой книге решается система из  $n$  линейных алгебраических уравнений с  $n$  неизвестными методом исключения неизвестных. Численно решается алгебраическое уравнения высоких степеней.

Китайские вычислители в X-XIII веках пользовались десятичными дробями, похожими на современные.

Перемена во взглядах в вопросе о числе связана с одним из самых замечательных достижений в истории математики, и именно с развитием алгебры.

Индийские ученые создали алгебру, свободно оперирующей не только с дробями, но и с иррациональными и отрицательными числами. Геометрические познания индийских математиков ограничивались вопросами вычислительной геометрии, разработкой вопросов приближенных приемов вычислений. Развитие тригонометрии связано с решением задач астрономии. Значительным достижением индийских математиков являлась замена хорд синусами, что способствовало введению различных функций, связанных со сторонами и углами прямоугольного треугольника. Одним из существенных достижений индийских математиков было более точное вычисление числа  $\pi$  разложением в ряд (с десятью верными значащими цифрами).

Выдающимся достижением индийских ученых является создание десятичной позиционной системы счисления.

Индийские математики достигли существенных успехов в разработке алгебраических и арифметических исчислений: разработка приемов решения алгебраических уравнений первой и второй степеней с довольно развитой символикой, правила действия над положительными и отрицательными числами, решение уравнений с одним и несколькими неизвестными, решение неопределенных уравнений первой и второй степеней в целых числах, определенные и неопределенные уравнения с несколькими неизвестными, доказательства теоремы Пифагора и т. д.

Ученые стран ислама разработали вычислительную математику значительно дальше. Они создали тригонометрию как самостоятельную большую науку и выделили алгебру в самостоятельную дисциплину. В дальнейшем развитие теоретических основ вычислительной математики имело большое значение развитие общей теории отношений и введение понятия об иррациональном положительном числе.

Слово “алгоритм” произошел от латинизированной формы прозвища аль-Хорезми, означающее всю систему десятичной позиционной арифметики. В дальнейшем термин “алгоритм” приобрел значение регулярного вычислительного процесса, дающее решение некоторого вычисли-

тельного процесса, дающее решение некоторого класса задач за конечное число действий (шагов). Понятие алгоритма занимает одно из центральных мест в современной математике, прежде всего вычислительной.

Омар Хайям (XI – XII вв.) использовал геометрические и численные методы решения уравнения третьей степени. Аль Каши принадлежит ряд превосходных работ по вычислительной математике. Им получено число  $\pi$  с 17-ю десятичными знаками. Для проведения вычислений с необходимой точностью Аль Каши разработал метод последовательных приближений (метод итераций). Аль Каши ввел в науку десятичные дроби, аналогично десятичным ввел 60-ричные дроби. Сформулировал правила действия с 60-ричными числами и правила перевода их в десятичные.

В странах ислама стирается различие между геометрическими иррациональностями, и иррациональные числа становятся полноправным предметом арифметики и алгебры, т. е. они становятся объектом теоретического исследования. Принцип однородности выполнения действий в геометрической алгебре нарушается. Аль - Бируни постоянно говорил о “произведении линий”, когда умножаются два отрезка.

Классическое определение пропорции заменяется новым на основе алгоритма Евклида. Омар Хайям считает необходимым в математике введения делимой единицы и новой категории чисел, которые соответствуют любым отношениям величин. Теперь любые отношения выражаются числами, тем самым обретают функцию измерения любых величин. Эта точка зрения более отчетливо представлена в работах Насирэддина ат Туси, что каждое отношение может быть названо числом.

Китайские и индийские математики ввели в рассмотрение отрицательные числа, а математики стран ислама пришли к понятию действительного числа (рациональные и иррациональные числа).

Развитие аппарата вычислительных средств, в первую очередь арифметики, в Европе связано с распространением индийской десятич-



ной позиционной системы и арабских цифр, через аль-Хорезми и других математиков Среднего и Ближнего Востока.

Начиная с XIII века алгебраические методы проникают в вычислительную практику, в первое время ожесточенно конкурируя с арифметическими.

Работа Леонардо Пизанского (Фибоначчи) “Книга абака” (Арифметика, 1202 г.) отличается разнообразием решаемых задач, используемых методов и доказательностью изложения. Намечается тенденция обобщения решаемых задач на подобные им.

Отрицательные числа появляются в Европе впервые у Леонардо Пизанского, который трактовал их в форме долга. Операции с отрицательными числами систематизируется немецким ученым М. Штифелем (XVI в.). Такие числа он назвал “фиктивными”.

Иордан Неморарий в работе “Арифметика, изложенная в десяти книгах” систематически употребляет буквы вместо конкретных чисел. Он не выражает величины с помощью отрезков и прямоугольников, а использует буквенные символы, как чисто арифметический знак произвольного числа. И. Неморарий в работе “О данных числах” задачи решаются в общем виде, а затем иллюстрируются числовыми примерами.

Никола Орем (1323-1382 гг.) в работе “Трактат о пропорциях” дает обобщение возведения в степень на положительные дробные показатели. Недостаточное развитие символической алгебры не позволили пользоваться формулами, которые стали в XVII-XVIII веках основным способом задания функций.

Н. Орем в работе “О размерах форм” графически сопоставляет зависимые и независимые переменные, который фактически является предвестником координатной системы и функциональной зависимости.

В работах Иоганна Мюллера (Региомонтанус) тригонометрия становится самостоятельной наукой, не зависящей от астрономии. Подобное было сделано в XVIII в., но дальнейшего развития не получило.

5. В конце XV века в математических сочинениях появляются принятые теперь знаки  $+$  и  $-$ . Быстро следует введение и всеобщее признание остальных знаков (степени, корня, скобок и т. д.).

К началу XVI века завершилась борьба между абацистами (сторонниками вычисления на абаке) и алгоритмистами в пользу сторонников позиционной десятичной системой счисления. Развивалась алгебраическая символика, введены дробные и отрицательные показатели и отрицательные числа. Идея функциональной зависимости и ее геометрического представления зарождается в университетской математике. Математика постепенно вторгается в естествознание и становится мощным методом познания.

В XVI в. усилиями итальянских ученых Тарталья, Кардано, Феррари и Ферро было решено алгебраическое уравнение третьей степени в радикалах. Уравнение четвертой степени решается сведением к уравнению третьего порядка (метод Феррари). К этому времени отрицательные числа еще не использовались в математике в “законных” основаниях. Поэтому рассматривали только положительные корни уравнения. Эта трудность была преодолена Раффаэле Бомбелли (1526 – 1572 гг.) в работе “Алгебра”, где вводит последовательную теорию мнимых (комплексных) чисел. Однако полное признание комплексного числа произошло в XIX веке. Р. Бомбелли первым ввел в алгебру мнимые величины, дал определение отрицательным числам и установил правила обращения с ними. Современное определение мнимого числа с тех пор не изменилось, а арифметические действия с ними производятся так, как это делал Бомбелли в XVI веке. Тогда они применялись только в промежуточных выкладках, но для результата использовались только действительные числа.

В буквенной алгебре Франсуа Виета (1540 – 1603 гг.) уравнения записываются в буквенном виде. Таким образом, был сделан важный шаг в записи формул в символьной форме. Над формулами можно производить операции и получить новые формулы и соотношения. Новые

результаты возможны благодаря новому способу записи математических объектов. Подходящее обозначение лучше и вернее отображает действительность, чем неудобное и порождает новое. Это повлекло за собой применение алгебры в геометрии у Декарта (алгебраическая геометрия Декарта).

6. Отрицательные числа получили у Декарта реальное истолкование в виде направленных ординат.

Симон Стевин (1548-1620 гг.) в работе “Десятина” (1585 г.) ввел десятичные дроби. Это было очень большим усовершенствованием, которое стало возможным благодаря всеобщему принятию индийско-арабской системы счисления. В это же время произошло усовершенствование вычислительной техники изобретением логарифмов.

К середине XVII века полностью сложился аппарат символов современной алгебры - употребление букв, входящих в задачу величин. Теперь часть математических рассуждений можно заменить механическими операциями. По словам Лейбница оно “разгружает память”. До Виета математика было без формул. В XVII веке Рене Декарт (1596 – 1650 гг.) в “Геометрии” уже отказался и от принципа однородности.

Р. Декарт связывал античную общую теорию пропорций с арифметикой.

С. Стевин выступил в пользу признания иррациональных чисел, а И. Ньютон определяет число как отвлеченное отношение какой-либо величины к другой величине того же рода, принятой за единицу.

Европейские математики в течение трех столетий работали над усовершенствованием техники вычислений. Расположение арифметических действий приобретает современный вид. Развивается учение об обыкновенных дробях. Сложение и вычитание дробей в современном виде предложил впервые Л. Пизанский. В XVII веке подобно Л. Пизанскому действовал Н. Тарталья и Х. Клавий. Умножение дробей в современном виде встречается в работе М. Штифеля.

Огромную роль в технике вычислений сыграло изобретение логарифмов. Оно повлияло на всю методику решения математических задач (Дж. Непер, Й. Бюрги ). Открытие Непера имело для вычислительной математики столь же большое значение, как открытие тригонометрических функций.

Замена умножений сложением была давней мечтой всех поколений вычислителей. Логарифмирование и использование этой операции для вычислений начали применять в первой половине XVII века после работ

Дж. Непера и Й. Бюрги.

Бриггс усовершенствовал логарифмы и опубликовал в 1624 году “Логарифмическую арифметику”. Полная таблица логарифмов с десятичным основанием была опубликована де Деккером и Блаком в 1627 году. Натуральные логарифмы появились одновременно с Бригговскими, но не были вначале должным образом оценены.

Широко пользовались линейным счетом (“линейный алгоритм”) до конца XVII века. Счет производили с помощью жетонов-фишек.

В России на рубеже XVI-XVII веков появился “дощаной счет”, из которого произошли в XVIII веке русские счеты.

При составлении и пользовании таблицами возникает проблема интерполяции. Ученые XVII века начинают замечать, что для повышения точности вычислений старый способ линейной интерполяции становится малопригодной по мере отклонения первой разности от постоянной. Например, Бриггс пользуется при вычислении логарифмов разностями высокого порядка. Ньютон и Грегори приходят разными путями к формуле интерполяций посредством многочленов, к биномиальным ряду, к разложениям в степенные ряды. Они уделяют большое внимание составлению таблиц, вычислению сумм числовых рядов и интегралов. Постоянно упоминают о сходимости рассматриваемых ими рядов, но нет методов их исследования. У них встречаются также вычис-

ления значения функций по их разностям, практическое вычисление интегралов и даже интегрирование дифференциального уравнения.

Паскаль и Ферма занимались вопросами исследования биномиальных коэффициентов и их применения к исчислению вероятностей и к исчислению конечных разностей. Все это означает, что открылась эпоха математики переменных величин, символьной алгебры, аналитической геометрии, дифференциального и интегрального исчисления.

В XVII веке было создано новое исчисление – дифференциальное и интегральное со своими понятиями и обозначениями. Создатели этого исчисления Ньютон и Лейбниц основное внимание уделяли созданию универсального алгоритма решения задачи изменения и движения, т. е. задач естествознания (физики, механики, астрономии). Ближайшими предшественниками Ньютона и Лейбница являются Декарт, Ферма, Кавальери, Кеплер, Гюйгенс, которые рассматривали различные исчисления бесконечно малых. Лейбниц с юных лет мечтал создать “характеристику”, т. е. универсального символического языка, который был бы для человеческих мыслей тем же, чем являются алгебраические обозначения для алгебры. Эту мечту Лейбниц реализовал в анализе бесконечно малых, выделив основные концепции исчисления, и дал им обозначения почти в современном виде.

Ньютон и Лейбниц отводили основную роль дифференцированию, сводя интегрирование к обратной к нему операции. Понадобилось еще не мало времени, чтобы восстановить равновесие.

Математический анализ XVIII века считается анализом Л. Эйлера, который очень много сделал для формирования анализа в фундаментальную математическую дисциплину. Однако полное обоснование математического анализа проведено в XIX веке усилиями почти всех крупных математиков того времени. Окончательную точку в этом вопросе поставил О. Коши, опубликовав два учебных пособия (1821, 1823 гг.).

7. Во второй половине XIX века поток задач практического характера для численного решения нарастал. Разработка численных методов явно отставал от потребностей практики. Методы оказывались ориентированными для решения узкого круга задач и не поддавались теоретическому анализу. Вычисления оставались все более трудоемкими для исполнения.

Оставалась нереализованной идея построения теории алгоритмов: оценка погрешностей, установление сходимости алгоритмов, определение эффективности алгоритмов. Кроме трудностей теоретического характера столкнулись с сугубо практическими трудностями, связанными с реализуемостью алгоритма. Эта проблема снята только с середины XX века с появлением ЭВМ.

Раздельное существование теоретических исследований и вычислительных методов решения задач сохранилось в научной и учебной литературе и в практике преподавания вплоть до XX века.

Зародившиеся в конце XIX и в начале XX веков численные методы анализа и алгебры выросли в связи с созданием и использованием ЭВМ в самостоятельную ветвь – вычислительную математику.

С практической точки зрения для вычисления корней алгебраического уравнения по заданным коэффициентам не было особой необходимости в общих формулах решения для уравнений высокой степени, так как даже для уравнения 3-ей и 4-ой степеней аналитические формулы практически мало полезны. В вычислительной математике численное решение уравнений пошло по пути приближенного вычисления, так как на практике и сами коэффициенты уравнения известны только приближенно. Однако и даже для приложений полезно уметь чисто теоретическим путем, без вычислений дать ответ на вопросы: отделение корней, о числе корней, о характере корней и т. д.

Не менее важно, что решение систем линейных уравнений составляет существенную часть вычислительной математики. Для решения таких уравнений разработаны много прямых и итерационных методов.

**8.** Рассмотрим историю развития приближенных методов вычислительной математики.

### **1. Нелинейные уравнения**

1.1. Ученые Вавилона в 2000 г. до н. э. умели решать квадратные уравнения и составлять таблицы для решения кубических уравнений.

1.2. В XVI в. Ш. Ферро нашел способ решения кубических уравнений специального вида. Этот результат стал отправным пунктом для развития алгебры. Дж. Кардано нашел решение приведенного кубического уравнения (“Великое искусство”, 1545 г.). Л. Феррари первым решил алгебраическое уравнение 4-ой степени (“Великое искусство”, 1545 г.).

1.3. В 1591 г. Ф. Виет ввел символическое обозначение в алгебраических уравнениях; указал на зависимость между корнями и коэффициентами уравнений (формулы Виета).

1.4. В 1799 г. К. Гаусс дал первое доказательство основной теоремы алгебры.

1.5. В 1824 г. Н. Х. Абель доказал тот факт, что общее уравнение 5-ой и более высокой степени не может быть решено чисто алгебраическими средствами.

1.6. В 1832 г. Э. Галуа дал общее теоретико-групповое обоснование всей проблемы.

1.7. В развитие численных методов решения нелинейных уравнений внесли существенный вклад: И. Ньютон, Д. Рафсон, Д. Стирлинг, Б. Бернулли, Ж. Лагранж, П. Руффини, П. Л., Чебышев, К. Х. Крамер, Н. Г. Чеботарев и другие.

### **2. Линейная алгебра**

2.1. В Древнем Китае о состоянии вычислительной математики можно судить по книге “Математика в девяти книгах” (II – I вв. до н. э.). В восьмой книге решается система из  $n$  линейных алгебраических уравнений с  $n$  неизвестными методом исключения неизвестных.

2.2. В VI в. индийцы умели решать системы линейных алгебраических уравнений (С.Л.А.У.).

2.3. Во 2-ой половине XVI в. была реализована полная символизация алгебры, которая дала возможность развить общие методы решения СЛАУ.

2.4. На базе теории линейных уравнений возникла линейная алгебра

2.5. В 1746 г. Ж. Даламбер доказал основную теорему алгебры.

2.6. Методы решения СЛАУ разработали: Г. Крамер, К. Гаусс, Я. Якоби, Ф. Л. Зейдель, Л. Кронекер, Э. Рунге, М. Жордан, Ф. Г. Фробениус, А. Капелли, А. Л. Холецкий и другие.

2.7. Разработкой теории определителей занимались: Ю. М. Воронский-Гене, О. Коши, Я. Якоби, Д. Д. Сильвестр, А. Кэли и другие.

2.8. Введение в 1879 г. Ф. Г. Фробениусом понятие о ранге матрицы позволило ему, а также А. Капелли в 1892 г. сформулировать необходимое и достаточное условие совместности неоднородной системы.

2.9. В 1859 г. А. Кэли показал, что и матрица может рассматриваться как единый алгебраический символ.

### **3. Интерполяция функций**

3.1. В начале XVII в. при помощи линейной интерполяции были табулированы тригонометрические и логарифмические функции.

3.2. В 1624 г. был опубликован труд Г. Бригса “Логарифмическая арифметика”.

3.3. Г. Бригс начал работы по приближению функций многочленами высших порядков.

3.4. В середине 70-х годов XVII в. И. Ньютоном была получена общая формула интерполирования функций с равностоящими узлами в виде интерполяционного полинома  $n$ -го порядка

3.5. Во второй половине XVIII в. возникла задача о замене сложной функции более простой (Ж. Лагранж, интерполяционный полином  $n$ -го порядка).

3.6. В 1809 г. К. Гаусс, в 1806 г. А. М. Лежандр разработали метод наименьших квадратов.



3.7. Интерполяционные вычисления сыграли большую роль в получении новых квадратурных формул и разложения функций в ряды.

3.8. В развитии теории интерполяции существенный вклад внесли: Дж. Грегори, Д. Стирлинг, Ф. В. Бессель, Г. Ган, П. Л. Чебышев, Е. И. Золотарев, К. Д. Т. Рунге, Э. Борель, С. Т. Бернштейн и другие

#### **4. Численное интегрирование**

4.1. Фактическое интегрирование было проведено Архимедом (III в. до н. э.), который пользовался методом вписанных и описанных многоугольников, получая, таким образом, нижнюю и верхнюю границы площади, неограниченно приближающихся друг к другу.

4.2. Метод трапеций древних был усовершенствован путем использования полиномов второй и высшей степени для интерполяции равноотстоящих данных.

4.3. В 1743 г. Т. Симпсоном была получена формула для вычисления приближенного значения определенного интеграла.

4.4. В 1814 г. К. Гаусс разработал эффективный метод вычисления площадей, основанный на свойствах полиномов Лежандра.

4.5. Приближенные методы вычисления определенных интегралов разработаны в работах: Р. Котеса, Л. Эйлера, Ш. Эрмита, П. Л. Чебышева, А. А. Маркова, Л. А. Люстерника, С. М. Никольского, С. Л. Соболева, Н. С. Бахвалова и других.

#### **5. Интегральные уравнения**

5.1. Исследование интегральных уравнений началось с конца XIX в. Первые результаты в этом направлении принадлежит Ж. Фурье, который в 1811 г. вывел формулы обращения.

5.2. Другое интегральное уравнение получено Н. Абелем.

5.3. основополагающие исследования по теории линейных интегральных уравнений были получены: В. Вольтерра, Д. Гильбертом, А. М. Ляпуновым, Э. И. Фредгольмом, Э. Шмидтом, Ф. Ришем, Т. Карлеменом и другими.

5.4. Эти результаты послужили основой для создания приближенных методов: методы квадратур, итераций, вырожденных ядер, собственных функций, применение интегральных преобразований.

5.5. Дальнейшее развитие теории и приближенных методов их решения нашло отражение в работах: Г. М. Вайникко, А. Ф. Верланя, А. Н. Колмогорова, Л. А. Люстерника, Г. И. Марчука, В. С. Сизикова, С. Л. Соболева, В. А. Треногина, С.В. Фомина и других.

## **6. Численные методы решения обыкновенного дифференциальных уравнений (ОДУ )**

6.1. В XVII в. заложены основы теории ОДУ трудами: И. Ньютон, Я. Бернулли, Г. Лейбница, И. Бернулли, Д. Ф. Риккати, А. Фонтен де Бертена и других.

6.2. Методы решения ОДУ разработаны в работах: Я. Германа, Х. Голдбаха, А. К. Клеро, А. Н. Крылова, А. И. Лексея, А. В. Летникова, А. М. Ляпунова и других.

6.3. Основы приближенных методов ОДУ были заложены в работах: Б. Тейлора, Л. Эйлера, П. С. Лапласа, Д. К. Адамса, А. Пуанкаре, К. Д. Т. Рунге, А. Н. Крылова, М. В. Кутты, Б. Г. Галеркина и других.

## **7. Численные методы решения дифференциальных уравнений в частных производных**

7.1. Зарождение и развитие теории дифференциальных уравнений связано с решением задач механики, физики.

7.2. Основы теоретических исследований и методов решения задач физики, механики заложены в трудах: Я. Германа, Б. Тейлора, Д. Бернулли, Л. Эйлера, Ж. Даламбера, Ж. Лагранжа, Г. Монжа, Н. Лапласа, А. М. Лежандра, Ж. Б. Ж. Фурье, С. Д. Пуассона, Н. Е. Зернова, Б. Римана, В. Г. Имшенецкого и других.

7.3. Далее в трудах: Н. Е. Жуковского, С. В. Ковалевской, А. Н. Крылова, Х. Лява, В. А. Стеклова, Н. М. Гюнтера, Л. Прандтля, Э. Шрёдингера, Р. Куранта, М. А. Лавреньева, С. Л. Соболева, А. Н. Тихонова, М. В. Келдыша и других.

7.4. В развитии теории конечно-разностного методов решения задач физики и механики сыграли большую роль установление: необходимого условия устойчивости явного разностного уравнения, изложенное в 1928 г. в статье

Р. Куранта, К. Фридрихса, Г. Леви; локального критерия устойчивости Дж. фон Неймана и Р. Д. Рихтмайера.

7.5. В работах С. К. Годунова, П. Лакса, В. С. Рябенского, А. В. Филиппова и других получены результаты по устойчивости разностных схем.

7.6. Важные результаты в теории разностных схем были получены на основе энергетического метода исследования устойчивости, разработанный Р. Курантом, О. А. Ладыженской, Г. Леви, Л. А. Люстерником, К. Фридрихсом и другими.

7.7. Исследования аппроксимации, устойчивости, сходимости создали благоприятные условия для широкого поиска эффективных разностных схем для решения уравнений с частными производными.

7.8. К началу 70-х годов XX в. сформировалось несколько направлений развития конечно-разностных методов. Среди них:

7.8.1. Построение консервативных разностных схем. Значительные результаты получены в работах: К. И. Бабенко, О. М. Белоцерковского, С. К. Годунова, А. А. Дородницына, О. А. Ладыженской, П. Лакса, В. В. Русанова, А. А. Самарского, А. Н. Тихонова, Г. И. Марчука и других.

7.8.2. Поиск экономичных методов решения многомерных стационарных задач. Методы факторизации: варианты точных методов факторизации (Ф. А. Абрамов, К. И. Бабенко, И. М. Гельфонд, М. В. Кельдыш и другие); методы приближенной факторизации (М. Х. Стоун и другие); метод переменных направлений (Д. Дуглас, Д. Д. Биргоф, Н.С. Бахвалов и другие).

7.8.3. Методы расщепления (Н. Н. Яненко, А. А. Самарский, Г. Н. Марчук, Ж. Л. Лионс, Е. Г. Дьяконов, А. Н. Коновалов и другие).

## **§ 2. Методологические вопросы вычислительной математики**

1. Широкие возможности для вычислительной математики наступили в 30-х годах XX века в связи с появлением релейных вычислительных машин. Носителями исходной информации были перфокарты, перфоленты, магнитные ленты, киноплёнки.

Переломный момент в развитии вычислительной математики наступил в связи с открытием факта, что каждой математической или логической формуле, составленной с использованием алгебры логики, однозначно соответствует некоторая релейно-контактная сеть, осуществляющая функции всех видов вычислений. Тем самым релейно-контактная сети явились моделями вычислительного процесса. Затем релейно-контактные вычислительные устройства были заменены бесконтактными, роль реле выполняли электронные лампы. Такая машина была построена в 1946 году (ENIAC). Начиная с середины XX века постепенно изменилось содержание и методология вычислительной математики.

До появления ЭВМ вычисления играли подчиненную роль в экспериментальных и теоретических исследованиях. ЭВМ появились лишь в середине XX в. и только после этого стало возможным механизация и автоматизация вычислительных работ. Стали использовать ЭВМ не только в прикладной математике, но и в теоретической математике.

Начиная с 1920-х годов небывалого расцвета достигла алгебра, произошла алгебраизация математики. Современный успех развития алгебры в большей степени определяется повсеместным использованием ЭВМ и компьютеризацией знания. Все эти факторы требуют алгоритмизации математики. Общая схема изучения многих математических объектов, порой очень далеких от алгебры, состоит в построении алгебраических систем, хорошо отражающих поведение изучаемых объектов. Алгебраизация и компьютеризация приводит к алгоритмизации математики.

Более точное описание процессов и явлений, вызванное потребностями науки и техники, требуют применения все более нового и современного математического аппарата, появления новых разделов математики. В свою очередь массовое использование ЭВМ для решения математических задач, особенно задач прикладной математики, способствовало ускоренному развитию численных методов и алгоритмов вычислительной математики. Алгоритмизация знания дает возможность переноса из одной области в другую не только результатов научного исследования, но и методов, приемов их получения, в той или иной науке. Отсюда один путь к алгоритмической интеграции, к практической ориентации математического знания, к арифметика – алгебраическому его строению, к повышению роли вычислительных методов.

2. В историческом плане наиболее привлекательной и исследованной является задача решения алгебраических уравнений. Поэтому теоретические, аналитические и численные методы исследования (решения) алгебраических уравнений могут служить моделью системы научного знания вообще. Эта теория исследует вопросы разрешимости и решения уравнения:

$$P_n(x) = a_0 + a_1x + \dots + a_nx^n = 0. \quad (2.1)$$

Задача вычисления значения полинома является прямой задачей

$$(P_n(x) = y, y = ?),$$

а нахождение корней уравнения (2.1) представляет собой обратную задачу

$$(P_n(x) = 0, x = ?).$$

Задача точного аналитического решения уравнения (2.1) является теоретической, а задача численного решения уравнения (2.1) является практической.

Таким образом, одна задача рассматривается как две задачи (в рамках абстрактной и прикладной математики), которые используют различные методы и критерии решения. Отнесение первых к теории (теоретической математике), а вторых к эмпирии (прикладной математике) оправдано не только логически, но и исторически. Из теории Абе-

ля и Галуа известно, что алгебраические уравнения (2.1) выше четвертой степени в общем случае не имеют точного аналитического решения. Это говорит о том, что теория алгебраических уравнений неполна относительно аналитического решения. Эту неполноту преодолевают (дополняют) «практически», на вычислительном уровне, образованном численными методами решения уравнения (2.1). С этой целью задачу (2.1) заменяют задачей вида:

$$P_n(x) \approx 0 \quad (2.2)$$

Требование нахождения точного решения уравнения (2.1) является теоретическим, т. е. задачей абстрактной математики. В рамках прикладной математики требование точного нахождения корня уравнения (2.1) делает задачу практически неразрешимой. Так как входные данные задачи задаются приближенно и используются для решения уравнения (2.1) приближенные численные методы, которые всегда допускают вычислительные погрешности. По этим причинам в прикладной задаче (2.2) не ищется единственное решение, как в теоретической задаче (2.1). Прикладная задача имеет бесконечно много решений, заполняющих числовой интервал, величина которого определяется практическими интересами исследователя (точностью задания входных данных). Любое из этих решений прикладник рассматривает как решение задачи. С точки зрения прикладника задача (2.1) представляется некорректной (нереализуемой) и он заменяет ее адекватной задачей (2.2), которая является некорректной (нет единственности решения) уже с точки зрения теоретика. Возникшее противоречие между теоретической и прикладной математикой преодолевается диалектной мышления – компромиссом с той и с другой сторонами.

Метод простого подбора решения превращается в систематический, эффективный метод (метод итераций) решения широкого круга сложных математических задач. Это достигается преобразованием оператора (функции) задачи  $P_n$  в алгебраический оператор  $\varphi$ , осуществляющий сжимающее отображение числового интервала в себя. Первое

приближение  $x_0$  прикладной задачи выбирается произвольно из области определения корня и этот произвол указывает на происхождение метода итерации от "метода" подбора. Исходное уравнение (2.2) преобразуется к виду:

$$x = \varphi(x), \quad x \in [a, b], \quad \varphi(x) \in [a, b]. \quad (2.3)$$

Начальное приближение  $x_0$  подставив в правую часть уравнения (2.3), получим  $x_1 = \varphi(x_0)$ .

Аналогичным образом имеем:

$$x_2 = \varphi(x_1) = \varphi(\varphi(x_0)) = \varphi^2(x_0), \dots, x_k = \varphi^k(x_0).$$

Метод итераций связывает выход  $(x_k)$  машины  $\varphi$  с ее "входом"  $(x_0)$  обратной связью. В силу указанного свойства оператора (функции)  $\varphi$  числовая последовательность

$$x_k = \varphi(x_{k-1}), \quad k = 1, 2, \dots$$

стремится, по мере роста номера  $k$ , к решению задачи (2.1). Иными словами бесконечная числовая последовательность  $x_0, x_1, \dots, x_k, \dots$  является сходящейся к точному решению  $x = \xi$ . Вычислитель может прервать процесс последовательных приближений на любом конечном шаге итераций ( $k=n$ ), зависящем от требуемой точности решения, и считать значение  $x_n$  решением прикладной задачи (2.2). Работающая таким образом эмпирическая машина (алгоритм), реализующая метод итераций, требует для остановки вмешательства субъекта (задание точности вычисления  $\varepsilon > 0$  и критерия остановки машины). Только после остановки "машины"  $\varphi$  она дает результат  $x_n \approx x = \xi$ .

Количество итераций  $k=n$  определяется самим субъектом исходя из вне теоретических (практических) соображений, а машина руководствуется теоретическими (математическими) критериями. Таким образом, решение, достигнутое численными методами имеет и субъектив-

ный (зависящий от произвола субъекта) и объективный (теоретический) источники и может быть названо синтетическим.

В силу неполноты теории относительно прикладных задач и неполноты вычислений относительно теоретических задач, знания, полученные этими методами не тождественны, но они вместе дополняют друг друга. В задаче (2.1) можно считать теоретической – задачу точного решения уравнения методом аналитических преобразований, а прикладной – задачу приближенного решения уравнения методом итераций. Точное аналитическое решение уравнения (2.1), ввиду "запрета Галуа", возможно для немногих уравнений. Численное (синтетическое) решение возможно для всех уравнений (2.1), но оно неточно. Тем не менее они вместе решают одну общую задачу – полное исследование объекта.

Решения прямой задачи особых усилий от исследователя не требует, носит по преимуществу, механический характер вычислений по известному алгоритму, поэтому она не является исследовательской задачей. В полном смысле слова задачами являются обратные задачи (некорректные задачи) и плохо обусловленные задачи, требующие для своего решения нестандартного мышления, изобретательности, в результате которого открываются алгоритмы, дающие возможность единообразно решать задачи из данных классов подобных им задач.

После открытия алгоритмов решения таких задач, они по существу, становятся корректными и хорошо обусловленными задачами. Решать обратную задачу – значит свести ее к решению последовательности прямых задач:

$$P_n(x) = 0 \rightarrow P_n(x) \approx 0 \rightarrow x = \varphi(x) \rightarrow x_{k+1} = \varphi(x_k).$$

Контроль правильности или применимости решения обратной задачи  $Ax=y$ ,  $x=?$  осуществляется путем решения соответствующей ей прямой задачи  $Ax=y$ ,  $y=?$

Достоверность решения задачи прикладной математики, проверяется с сравнением его с данными опыта, служит одновременно критерием правильности расчетов и степени адекватности выбранной модели.



3. В 1932 году Ж. Адамар [29] указал на отличие некорректных задач от корректных краевых задач математической физики. В конкретных приложениях исходная информация всегда дана с некоторой погрешностью, отсюда Адамар сделал вывод, что только математически корректно поставленные задачи могут иметь физическую интерпретацию. Те задачи, которые не удовлетворяют условию корректной постановки задачи, по мнению Адамара, не могут иметь физической интерпретации, а потому не представляют ни теоретического, ни практического интереса. Действительно, для некорректно поставленных задач понятие "приближенное решение" теряет смысл, так как одно "приближенное решение" может очень сильно отличаться от другого при малом изменении входных данных. При решении некорректных задач классическими методами нет сходимости приближенных решений к точному решению. Отказ Адамара признать правомерность решения некорректных задач на первый взгляд вполне обоснована, так как некорректность задачи может быть истолкована как дефектность математической модели, на основе которой она сформулирована. Потом выяснилось, что отказ Адамара от физической интерпретации некорректных задач был ошибочным. Адамар не учел того обстоятельства, что в данном случае не "виновата" модель, которая описывает реальный процесс, а "виноваты" существующие в данное время методы вычислений, которые могут быть несовершенными и не позволяют извлечь полезной информации, содержащейся в модели, или даже создавать впечатление неполноценности модели. Отказ Адамара физической интерпретации некорректных задач оказалась обусловленной ограниченностью классических методов их приближенного решения, а не дефектами математической модели соответствующего процесса.

В 1943 году для решения некорректных задач математической физики был предложен новый алгоритм, основанный на сужении класса возможных решений путем использования дополнительной априорной информации о решении (метод сведения к условию корректной задаче).

Обратные задачи математической физики относятся к классу некорректных задач (нет устойчивости решения), которые определяются наличием необратимых во времени процессов.

В преодолении принципиальных трудностей в решении обратных некорректных задач сыграл предложенный А. Н. Тихоновым в 1963 году общий метод нахождения приближенного решения некорректных задач, получивший название метод регуляризации. После работ А. Н. Тихонова последовало быстрое развитие теории некорректных задач и алгоритмов их решения (А. Н. Тихонов, М. М. Лаврентьев, В. К. Иванов и другие).

Многие специалисты считали, что теперь все основные вопросы некорректных задач решены и нет никаких принципиальных затруднений в разработке вычислительных алгоритмов для решения широкого класса таких задач. Однако выяснилось, что в действительности дело обстоит не так просто. Класс регуляризуемых некорректных задач был описан в работах В. А. Винокурова [4, 5].

Решение некорректной задачи, абстрагируясь от несущественных деталей представляют как приближенное вычисление некоторой разрывной функции. Алгоритм, который используется для регуляризации непрерывных функций называется тривиальным алгоритмом. В математике до 60-х годов XX века использовались только тривиальные алгоритмы.

По мере развития науки и техники практические задачи требовали приближенного вычисления разрывных функций. Для широкого класса разрывных функций оказалось возможным разработать нетривиальный вычислительный алгоритм, что потребовало развития принципиально новых методов вычислений.

Ошибочность Адамара заключается в том, что он рассматривал только тривиальные алгоритмы и не допускал использование более сложных вычислительных алгоритмов. Усложнение математических моделей реальных процессов потребовало проведения более точного

анализа и обоснования постановки задачи приближенного решения некорректной математической задачи.

Для функций, имеющих “слишком много” точек разрыва приближенное вычисление таких функций практически неосуществимо, так как их значения слишком часто и резко меняются. Таким образом, проблема приближенной вычислимости для широкого класса функций оказывается неразрешимой. Это означает, что для широкого класса математических задач справедливо утверждение [4, 5]: с какой бы высокой (конечной) точностью мы ни задавали входную информацию, отклонение от точного решения не может быть меньше некоторой фиксированной величины.

Требование приближенной вычислимости не ограничивает сферу применения ЭВМ, но сужает свободу построения математической модели.

Математические модели должны удовлетворять следующим требованиям.

1. Математическая основа модели должна быть непротиворечивой и подчиняться всем законам математики и математической логики.

2. Модель должна отражать действительность как на уровне конечной, так и на уровне промежуточной информации.

3. Не следует тратить время на уточнение решения с использованием данной математической модели, если это не оправдано самой математической постановкой задачи.

4. Математическая модель должна быть хорошо структурированной.

5. Важным условием применимости математической модели к описанию реальных объектов является количественное соответствие модели с точностью физических измерений реального объекта.

6. Точность исследования зависит от степени адекватности модели и объекта и от точности применяемых методов и алгоритмов вычислительной математики.

7. Необходимо сопоставить точность метода решения с точностью исходных данных.

8. Модель должна быть достаточно полной, но в то же время она обязана быть достаточно простой, чтобы можно было бы пользоваться существующими в математике средствами ее реализации на ЭВМ.

9. Математическая модель не может отражать структуру материального мира сразу, целиком и полностью, она всегда находится лишь в гомоморфном соответствии с моделируемым оригиналом.

10. Правильность работы математической модели реальных процессов свидетельствует о правильности используемых для построения математических моделей теорий, алгоритмов и программ.

11. Критерием адекватности математической модели к реальному процессу является практика (эксперимент).

12. Таким образом, основными требованиями, предъявляемыми к математическим моделям реальных процессов, является: достаточная точность отражения реального процесса; разумная простота, реализуемость на современных ЭВМ; приближенной вычислимости, так как в случае невыполнения этого требования из модели не удастся извлечь практически полезной информации.

4. В настоящее время центральным ядром организации математического знания является построение математических моделей конкретных наук, соединяющих вместе различные ветви математического знания.


Со второй половины XX века с появлением ЭВМ и интенсивным внедрением компьютеров во все сферы человеческой деятельности успешно развивается теоретико-алгоритмическое направление в рамках абстрактной и прикладной математики на базе математических моделей. Математические модели исследуются как теоретические конструкции аксиоматического типа. Выявляются общие методы, заложенные в структуре математических моделей. Особое внимание уделяется разработке вычислительных алгоритмов, удовлетворяющих современным

требованиям вычислительной математики. С одной стороны, математическая модель служит для прикладной математики экспериментальным средством, а с другой стороны на основе математических моделей проводится вычислительный эксперимент, который выступает как теоретико-практическая реализация метода математического моделирования, означающего нового способа описания реальности, конкурирующего с традиционными идеалами аксиоматически -дедуктивных методов построения теорий.

Обработка огромного количества данных в цифровом виде дали возможность человеку использовать цифровую технику не только в целях вычисления, но и для анализа выяснения глубинных свойств реального мира.

Среди всех преобразователей информации ЭВМ при работе с любыми входными данными перед исполнением операции приводит их к "общему знаменателю", представляя их в виде конечной последовательности цифр – информационной модели. Теперь стало возможным окружающий мир записать цифровым способом, то что казались людям совершенно разными, теперь они выражаются одним способом – через последовательности двоичных кодов, т. е. "все сущее можно представить в виде двоичных кодов" [24]. Вычислительное направления исследований в дальнейшем трансформировался в новую методологию и технологию проведения научных исследований, которое получило название вычислительного эксперимента [20].

Общую схему проведения вычислительного эксперимента можно представить следующим образом (рис).



**Рис.** Общая схема вычислительного эксперимента

Здесь А – алгоритм, П – программа, ВЭ – вычислительный эксперимент, ПМ – прикладная математика, КН – конкретные науки, ММ – математическая модель, МС – математические структуры, ТМ – теоретическая математика, УО – управление объектом.

Арифметические действия можно представить, как модели реальных операций над предметами (камешками, фишками, перемещение

элементов механических счетных устройств, электронных импульсов). С этой точки зрения современный компьютер можно рассматривать как моделирующее устройство. В этом смысле реализация математических моделей и оптимизация вычислительного процесса на ЭВМ можем рассматривать как эксперимент модельный, опирающийся на материальное созерцание абстрактных объектов.

### **Особенности вычислительной математики**

1. Вычислительная математика имеет дело не только с непрерывными, но и с дискретными объектами. Так, вместо отрезка прямой часто рассматривается система точек, вместо непрерывной функции – функция дискретного аргумента, вместо производной – ее разностная аппроксимация. Такие замены порождают погрешности метода.
2. В машинных вычислениях присутствуют числа с ограниченным количеством знаков после запятой из-за конечности длины мантиссы при представлении действительного числа в памяти ЭВМ. Другими словами, в вычислениях присутствуют машинная погрешность (погрешность округления). Это приводит к вычислительным эффектам, неизвестным в классической математике.
3. В вычислительной практике большое значение имеет обусловленность задачи, т. е. чувствительность ее решения к малым изменениям входных данных.
4. В отличие от классической математики выбор вычислительного алгоритма влияет на результаты вычислений.
5. Существенная черта численного метода – экономичность вычислительного алгоритма, т. е. минимизация числа элементарных операций при выполнении его на ЭВМ.
6. Погрешности при численном решении задач делятся на две категории – неустранимые и устранимые. К первым относятся погрешности, связанные с построением математической модели объекта и приближенным заданием входных данных, ко вторым – погрешности метода реше-

ния задачи и ошибки округления, которые являются источниками малых возмущений, вносимых в решение задачи.

7. Характерной особенностью современных вычислительных методов является абстрактность и конструктивность. Только такой путь развития вычислительных методов обеспечивает универсальность и реализуемость вычислительных алгоритмов.

8. В задачу вычислительной математики входит также разработка приемов и методов наиболее рационального решения конкретных задач.

9. Общей целью теории численных методов и вычисленных алгоритмов является разработка эффективных вычислительных методов, которые дают возможность получить решение исходной задачи с заданной точностью за минимальное количество действий, т. е. с минимальными затратами машинного времени.

#### **5. Дадим следующее определение, относящееся к вычислительной математике**

1. Вычислительная математика – область математической науки, которая изучает реальные и абстрактные объекты с использованием ЭВМ.

2. Методом вычисленной математики являются вычислительные методы математики.

3. Предметом вычислительной математики является создание вычислительных методов и алгоритмов, позволяющих вычислять математические закономерности на ЭВМ.

4. Структурой вычислительной математики выступают вычислительные задачи математики.

5. Ядром вычислительной математики являются вычислительные алгоритмы.



## Литература

1. Антаков С. М. Прямая и обратная задачи в структуре научного исследования. Автореф. Дисс.. канд. философ. науки. Нижний Новгород, 1994, 20 с.
2. Барабашев А. Г. Диалектика развития математического знания (закономерность эволюции способа систематизации). М.: Изд-во МГУ, 1993, 166 с.
3. Бурбаки Н. Архитектура математики. М.: Знание, 1972, 32 с. (Сер. "Математика, кибернетика" №1).
4. Винокуров В. А. О понятии регуляризуемости разрывных отображений. Журнал вычислительной математики и математической физики, 1971, т. 11, №5.
5. Винокуров В. А. Регуляризуемость и аналитическая престаивимость. ДАН СССР, 1975, т. 220, № 2.
6. Иванов В. В. Методы вычислений на ЭВМ. Справочное пособие. Киев, Наук. Думка, 1986.
7. Каханер Д., Моулера К., Нэш С. Численные методы и программное обеспечение. Пер. с англ. – М.: Мир, 2001. – 575 с.
8. Колмогоров А. Н. Математика // Матем. энцикл. словарь. – М.: Советск. энцикл., 1988. – С. 7-38.
9. Королев Л. Н., Рыбников К. А. Вычислительная математика и вычислительная техника. Очерки истории. – М.: МГУ, 1999.
10. Охлопков Н. М. Методологические вопросы теории и практики разностных схем. – Иркутск: изд-во ИГУ, 1989. – 256 с.
11. Охлопков Н. М. История, методология и философия вычислительной и прикладной математики. – Якутск: ЯГУ. – 342 с. ДЭИ, № 16415 от 8 июня 2009 г.
12. Ланцош К. Практические методы прикладного анализа. М.: ФМЛ, 1961. – 524 с.
13. Марчук Г. И. Методы вычислительной математики. М.: Наука, 1977. – 456 с.
14. Охлопков Н. М. Методологические и технологические вопросы прикладной и вычислительной математики. – Якутск: ЯГУ, 1991. – 202 с.

15. Охлопков Н. М. Вычислительный метод познания // Информационная технология в науке, образовании и экономике. Сб. трудов, Якутск, ЯГУ, 2003, - с. 82-89.
16. Охлопков Н. М., Иванов Ф. В. Методы вычислений (задачи математической физики) – Якутск: ЯГУ, 2008. – 111 с.
17. Охлопков Н. М., Охлопков Г. Н. Введение в специальность "Прикладная математика". Учебное пособие, ч. 1. Якутск: ЯГУ, 1997, 93 с.
18. Панов В. Ф. Математика древняя и юная / Под ред. Зарубина В.С. – 2-е изд. испр. – М: изд-во МГТУ им. Н. Э. Баумана, 2006. – 648 с.
19. Русанов В. В., Росляков Г. С. История и методология прикладной математики. – М: МГУ, 2004.
20. Самарский А. А. Математическое моделирование и вычислительный эксперимент // Вестник АН СССР, 1979, № 5. – с. 38-49.
21. Тихонов А. Н. О решении некорректно поставленных задач и метода регуляризации. ДАН СССР, 1963, т. 151, №3.
22. Тихонов А. Н. О регуляризации некорректно поставленных задач. ДАН СССР, 1963, т. 153, № 1.
23. Тихонов А. Н., Костомаров Д. П. Вводные лекции по прикладной математике. – М.: фмл, 1984.
24. Томпсон М. Философия науки./ Мел Томпсон. – пер. с англ. А. Гарькавого. – М.: ФАИР-Пресс, 2003. – 304 с.
25. Хемминг Р. В. Численные методы для научных работников и инженеров. – М.: Наука 1968. – 400 с.
26. Хрестоматия по истории математики. М.: Просв., 1976, под. ред. А. П. Юшкевича.
27. Юшкевич А. П. Математика в ее истории. М.: ЯНУС, 1996. – 413 с.
28. Яненко Н. Н. Методологические вопросы современной математики. Вопросы философии, 1981, № 8.
29. Hadamard J. Le probleme de Cauchy et les equations aux derives partielles lineaires hyperboliques. Paris, 1932.
30. Охлопков Н. М., Иванов Ф. В. Численные методы: теория и практика: учебное пособие. – Якутск: Издательский дом СВФУ. 2016. – 370 с.

## Глава 2. НЕКОТОРЫЕ ВОПРОСЫ ТЕОРИИ ПОГРЕШНОСТЕЙ

### § 1. Абсолютная и относительная погрешности

Приближенным числом  $a$  называется число, незначительно отличающееся от точного числа  $A$  и заменяющее последнее в вычислениях.

Под погрешностью  $\Delta$  приближенного числа  $a$  понимается разность между соответствующим точным числом  $A$  и данным приближенным числом, т.е.

$$\Delta = A - a.$$

Для того чтобы получить точное число  $A$ , надо прибавить к приближенному числу  $a$  его погрешность  $\Delta$ , т.е.

$$A = a + \Delta.$$

Однако часто бывает, что знак погрешности неизвестен. В этом случае удобно пользоваться абсолютной погрешностью приближенного числа.

Абсолютной погрешностью  $\Delta a$  приближенного числа  $a$  называется абсолютная величина разности между соответствующим точным числом  $A$  и числом  $a$ , т. е.

$$\Delta a = |A - a|. \quad (1.1)$$

Здесь возможны два случая.

1. Точное число  $A$  известно. Тогда абсолютная погрешность легко вычисляется по формуле (1.1).

Пример 1. Пусть  $A=784,2737$ ,  $a=784,274$ . Тогда:

$$\Delta a = |A - a| = |784,2737 - 784,274| = 0,0003.$$

2. Точное число  $A$  нам не известно. Тогда абсолютную погрешность по формуле (1.1) невозможно вычислить. Поэтому пользуются понятием границы абсолютной погрешности, удовлетворяющей неравенству:

$$|A - a| \leq \Delta^* a.$$

Граница абсолютной погрешности, т.е. число заведомо превышающее абсолютную погрешность (или в крайнем случае равное ей), называется предельной абсолютной погрешностью. Следовательно, если  $\Delta^*a$  – предельная абсолютная погрешность, то:

$$\Delta a = |A - a| \leq \Delta^*a. \quad (1.2)$$

Значение точного числа  $A$  всегда заключено в следующих границах:

$$a - \Delta^*a \leq A \leq a + \Delta^*a. \quad (1.3)$$

Пример 2. Число 45,3 получено округлением. Точное значение числа неизвестно, однако, пользуясь правилами округления чисел, можно сказать, что абсолютная погрешность не превышает (меньше или равна) 0,05.

Тогда предельной абсолютной погрешностью можно считать 0,05. Это записывается так:  $45,3 \pm 0,05$ . В качестве границы абсолютной погрешности берут по возможности меньшее число.

Пример 3. При измерении длины отрезка оказалось, что ошибка, допущенная нами не превышает 0,5 см., тем более она не превышает 1, 2 или 3 см. Каждое из этих чисел можно считать границей абсолютной погрешности. Однако нужно указать наименьшую из них, так как чем меньше граница абсолютной погрешности, тем точнее выражается приближенное значение числа.

На практике часто применяют выражение типа: “с точностью до 0,01”, “с точностью до 1 см.”. Это значит, что предельная абсолютная погрешность равна соответственно 0,01; 1 см. и т.д.

Пример 4. Если длина отрезка  $l=184$  см. измерена с точностью до 0,05 см., то пишут  $l = 184 \text{ см.} \pm 0,05$ . Здесь предельная абсолютная погрешность  $\Delta^*l = 0,05 \text{ см.}$ , а точная величина длины  $l$  отрезка заключена в следующих границах  $183,95 \text{ см.} \leq l \leq 184,05 \text{ см.}$

По абсолютной и предельной абсолютной погрешностям нельзя судить о качестве измерения.

Пример 5. Пусть при измерении длины книги и длины стола были получены результаты:  $l_1 = 28,4 \pm 0,1$  (см.) и  $l_2 = 110,3 \pm 0,1$  (см.)

Предельная абсолютная погрешности  $\Delta_{l_1}^* = 0,1$ ,  $\Delta_{l_2}^* = 0,1$ . Однако второе измерение было произведено более точно, чем первое.

Для определения качества произведенных измерений необходимо определить, какую долю составляет абсолютная или предельная абсолютная погрешность от измеряемой величины. В связи с этим вводится понятие относительной погрешности.

Относительной погрешностью  $\delta a$  приближенного числа  $a$  называется отношение абсолютной погрешности  $\Delta a$  к модулю точного числа  $A$  ( $A \neq 0$ ), т. е.

$$\delta a = \frac{\Delta a}{|A|}. \quad (1.4)$$

Отсюда

$$\Delta a = |A| * \delta a. \quad (1.4')$$

Число  $\delta_a^*$ , заведомо превышающее относительную погрешность (или в крайнем случае равное ей), называется предельной относительной погрешностью:

$$\delta a \leq \delta_a^*. \quad (1.5)$$

Из соотношений (1.4) и (1.5) вытекает, что  $\frac{\Delta a}{|A|} \leq \delta_a^*$ ,  $\Delta a \leq |A| * \delta_a^*$ .

Из определения предельной абсолютной погрешности следует, что  $\Delta a \leq \Delta_a^*$ . Тогда можно записать ( $\Delta a \ll |A|$ )

$$\Delta_a^* a = |A| * \delta_a^* a \quad (1.6)$$

и за предельную относительную погрешность приближенного числа  $a$  можно принять ( $\delta_a^* \ll 1$ ):

$$\delta_a^* a = \frac{\Delta_a^* a}{|A|}. \quad (1.7)$$

Учитывая, что  $A$ , как правило, неизвестно и что  $A \approx a$ , то равенства (1.6) и (1.7) можно записать так:

$$\Delta^* a = |a| * \delta^* a, \quad (1.6')$$

$$\delta^* a = \frac{\Delta^* a}{|a|}. \quad (1.7')$$

Пример 5'. Вычисляем:

$$\delta^* l_1 = 0,1 \text{ см} / (28,4 \text{ см}) \approx 0,0035, \text{ или } 0,35\%;$$

$$\delta^* l_2 = 0,1 \text{ см} / 110,3 \text{ см} \approx 0,0009, \text{ или } 0,09\%.$$

Пример 6. Определить (в процентах) предельную относительную погрешность приближенного числа  $a = 35,148 \pm 0,00074$ .

Решение. По формуле (1.7') имеем:

$$\delta^* a = (\Delta^* a) / |a| = 0,00074 / 35,148 = 0,000021 (0,0021\%).$$

Пример 7. Определить предельную абсолютную погрешность приближенного числа  $a = 4,123$ , если  $\delta^* a = 0,01\%$ .

Решение. По формуле (1.6') имеем

$$\Delta^* a = |a| * \delta^* a = 4,123 * 0,0001 \approx 0,00041.$$

Пример 8. Определить относительные погрешности чисел  $x$  и  $y$ , полученных при измерении углов. Какой из результатов более точный?

| $x$          | $\Delta x$ | $y$          | $\Delta y$ |
|--------------|------------|--------------|------------|
| $50,30'10''$ | $3''$      | $45,15'36''$ | $2''$      |

Решение. Переведем  $x$  и  $y$  в секунды и определим относительные погрешности измерений:

$$x = 50 * 3600 + 30 * 60 + 10 = 181810 \pm 3,$$

$$\delta x = 3 / 181810 \approx 0,000017 = 0,0017\%;$$

$$y = 45 * 3600 + 15 * 60 + 36 = 162936 \pm 2,$$

$$\delta y = 2 / 162936 \approx 0,000012 = 0,0012\%;$$

Измерение  $y$  произведено более точно.

Пример 9. Определить, какое равенство точнее:

$$a_1 = 13/19 \approx 0,684 \text{ или } a_2 = \sqrt{52} \approx 7,21?$$

Решение. Для нахождения предельных абсолютных погрешностей берем числа  $a_1$  и  $a_2$  с большим числом десятичных знаков:

$13/19 \approx 0,68421$ ;  $\sqrt{52} \approx 7,2111$ . Определяем предельные абсолютные погрешности, округляя их с избытком:

$$\Delta^* a_1 = |0,68421 - 0,684| \leq 0,00022;$$

$$\Delta^* a_2 = |7,2111 - 7,21| \leq 0,0012.$$

Находим предельные относительные погрешности:

$$\delta^* a_1 = (\Delta^* a_1) / |a_1| = 0,00022 / 0,684 \approx 0,00032 = 0,03 \%;$$

$$\delta^* a_2 = (\Delta^* a_2) / |a_2| = 0,0012 / 7,21 \approx 0,00017 = 0,017 \%.$$

Второе равенство является более точным, поскольку  $\delta^* a_2 < \delta^* a_1$ .

## § 2. Десятичная запись приближенных чисел.

### Значащая цифра числа. Верная значащая цифра

Системой счисления, или нумерацией, называется совокупность правил, служащих для наименования и обозначения чисел.

Цифрами называются условные знаки, используемые при обозначении чисел. При записи чисел в десятичной системе счисления используются десятью цифрами 0,1,2,3,4,5,6,7,8,9. Эта система является позиционной: значение каждой цифры в числе зависит от ее положения среди других цифр этого числа. Например, 7777,77. Значение первой слева цифры – 7000, второй – 700, третьей – 70, четвертой – 7, пятой – 0,7, шестой – 0,07. Число 7777,77 является сокращенной записью следующей суммы:

$$7777,77 = 7 * 10^3 + 7 * 10^2 + 7 * 10 + 7 * 10^0 + 7 * 10^{-1} + 7 * 10^{-2}.$$

Всякое десятичное положительное число  $a$  можно представить в виде конечной или бесконечной десятичной дроби:

$$a = \alpha_1 * 10^m + \alpha_2 * 10^{m-1} + \alpha_3 * 10^{m-2} + \dots + \alpha_n * 10^{m-n+1} + \dots, \quad (2.1)$$

где  $\alpha_i$  – цифры числа ( $i = \overline{1, n}$ ), причем  $\alpha_1 \neq 0$ , а  $m$  – старший десятичный разряд числа  $a$ .

Значение единицы соответствующего разряда есть цена разряда. Так, цена первого (слева) разряда приближенного числа  $a$  есть  $10^m$ , второго –  $10^{m-1}$ , ...,  $n$ -го –  $10^{m-n+1}$ .

При решении задач очень часто ставится условие: вычислить результат с точностью до одной десятой, одной сотой и т. д.

Создается впечатление, что точность вычислений определяется числом десятичных знаков после запятой. Это неправильно, так как число десятичных знаков зависит от единицы, выбранной для измерения. Определяющим точность вычисления является не число десятичных знаков, а число значащих цифр результата.

Значащими цифрами приближенного числа  $a$  называется все цифры в его десятичном представлении, отличные от нуля, и нули, если они содержатся между значащими цифрами или расположены в конце числа и указывают на сохранение разряда точности. Нули, стоящие левее первой отличной от нуля цифры, не являются значащими цифрами.

Пример 1. Числа  $0,001405$  и  $5,0300$  имеют соответственно 4 и 5 значащих цифр.

При написании целых чисел нули справа могут быть в одних случаях значащей цифрой, в других – незначащей.

Если число 83500 задано с точностью до единиц, то все три нуля справа – значащие цифры. Если же это число задано с точностью до сотен, то последние два нуля незначащие цифры, а ноль в разряде сотен – значащая цифра.

Пример 2. Число 399,837 округлив до тысяч, получим 400,000. Ноль в разряде тысяч является значащей цифрой, так как стоит в разряде точности. Все остальные, стоящие левее нуля, находящиеся в разряде точности, являются так же значащими. Последние три нуля – незначащие цифры. Для того, чтобы по записи числа можно было бы определить, являются ли крайние правые нули значащими или нет, рекомендуется числа представлять в виде произведения двух сомножителей, например:



$$400 * 10^3, \text{ или } 40,0 * 10^4, \text{ или } 4,00 * 10^5.$$

Последняя форма записи, когда запятая поставлена после первой слева значащей цифры, называется нормальной и является предпочтительной. В таком представлении количество значащих цифр числа равно количеству значащих цифр первого сомножителя.

Однако точность приближенного числа зависит не от того, сколько в этом числе значащих цифр, а от того, сколько значащих цифр заслуживают доверия, т.е. от количества верных значащих цифр.

Приближенное число

$$a = \alpha_1 * 10^m + \alpha_2 * 10^{m-1} + \alpha_3 * 10^{m-2} + \dots + \alpha_n * 10^{m-n+1} + \dots.$$

содержит  $n$  верных значащих цифр в узком смысле, если абсолютная погрешность этого числа не превосходит половины единицы десятичного разряда, выражаемого  $n$ -ой значащей цифрой, считая слева направо, т.е. если выполняется неравенство:

$$\Delta a \leq 0,5 * 10^{m-n+1}. \quad (2.2)$$

Если это неравенство не выполняется, то цифру  $\alpha_n$  называют сомнительной. Очевидно, что если цифра  $\alpha_n$  – верная, то и все предшествующие ей цифры тоже верные. Таким образом, среди верных цифр всегда можно указать последнюю.

Пример 3. Для точного числа  $A=17,976$  число  $a=17,98$  является приближением с четырьмя верными знаками в узком смысле, так как

$$\Delta a = |A - a| = 0,004 < 0,5 * 0,01 = 0,005, \\ (m = 1, \Delta a \leq (1/2) * 10^{1-n+1}, 1 - n + 1 = -2, n = 4).$$

Приближенное число

$$a = \alpha_1 * 10^m + \alpha_2 * 10^{m-1} + \alpha_3 * 10^{m-2} + \dots + \alpha_n * 10^{m-n+1} + \dots.$$

Содержит  $n$  – верных значащих цифр в широком смысле, если абсолютная погрешность этого числа не превосходит единицы десятичного разряда, выражаемого  $n$ -ой значащей цифрой, считая слева направо, т. е. если выполняется неравенство:

$$\Delta a \leq 1 * 10^{m-n+1}. \quad (2.3)$$

Пример 4. Для точного числа  $A=17,976$  число  $a=17,97$  является приближением с четырьмя верными цифрами в широком смысле, так как  $\Delta a = |A - a| = 0,006 < 1 * 0,01$ . ( $m = 1$ ,  $1 - n + 1 = -2$ ,  $n = 4$ ).

Неравенства (2.2) и (2.3) можно записать в виде:

$\Delta a \leq w * 10^{m-n+1}$ , где  $0,5 \leq w \leq 1$  указывает на характер проводимых вычислений.

Если приближенные числа появляются в результате вычислений по формулам с точными значениями исходных данных, т. е. когда можно практически достигнуть любой заданной точности, то  $w = 0,5$ .

Если же приближенные числа получаются в результате вычислений с недостаточно точными исходными данными, то  $w = 1$ .

Пример 5. Сколько верных значащих цифр содержит приближенное число  $a = 85,267 \pm 0,0084$ : 1) в узком смысле; 2) в широком смысле?

Решение. 1)  $\Delta a = 0,0084 < (1/2) * 10^{-1} = 0,05$ .

Следовательно, верными в узком смысле будут цифры 8, 5, 2 ( $m = 1$ ,  $1 - n + 1 = -1$ ,  $n = 3$ ).

2)  $\Delta a = 0,0084 < 0,01$ , верными в широком смысле будут цифры 8, 5, 2, 6 ( $m = 1$ ,  $1 - n + 1 = -2$ ,  $n = 4$ ).

Пример 6. Определить предельные абсолютные погрешности приближенных чисел,  $a = 96,387$  и  $b = 9,32$ , если они содержат только верные цифры в узком и широком смысле соответственно.

Решение.

1) Так как для числа  $a=96,387$  последняя цифра 7, стоящая в разряде тысячных долей, является верной значащей цифрой в узком смысле, то  $\Delta a \leq 0,5 * 0,001$ , т. е.  $\Delta a \leq 0,0005$ , или  $\Delta^* a = 0,0005$ . Тогда число  $a$  можно записать так:  $a = 96,387 \pm 0,0005$ .

2) Последняя цифра приближенного числа  $b=9,32$  стоит в разряде сотых долей. Так как это число содержит верные цифры в широком смысле,

то, следовательно  $\Delta b \leq 1 * 0,01$ , т. е.  $\Delta b \leq 0,01$ , или  $\Delta^* b = 0,01$ . Число  $b$  можно записать так:  $b = 9,32 \pm 0,01$ .

### § 3. Округление чисел

Правило 1. Если первая из отброшенных цифр больше 5, то последняя из сохраняемых цифр усиливается, т. е. увеличивается на единицу. Усиление производится и тогда, когда первая из отброшенных цифр равна 5, а за ней следуют отличные от нуля цифры.

Пример 1. Округляя до десятых долей число 73,473, получим 73,5, так как  $7 > 5$ .

Правило 2. Если первая из отброшенных цифр меньше 5, то последняя из оставшихся цифр не усиливается, т. е. остается без изменения.

Правило 3. Если первая из отброшенных цифр равна 5 и за ней не следуют отличные от нуля цифры, то последняя оставшаяся цифра усиливается, если она нечетная, и остается без изменения, если она четная.

Пример 2. Округляя число 5,785 до сотых долей, получаем 5.78. Округляя число 5,775 до второго десятичного знака, имеем 5.8.

Таким образом, при применении выше рассмотренных правил округления абсолютная погрешность округления не превосходит половины единицы разряда, определяемого последней оставленной значащей цифрой.

Если точное число  $A$  округляется до  $n$  значащих цифр по правилу дополнения, то получаемое приближенное число  $a$  имеет абсолютную погрешность, равную погрешности округления. В этом случае приближенное число  $a$  имеет  $n$  верных значащих цифр в узком смысле.

Пример 3. Округляя число  $A=26,837$  до трех значащих цифр, получим  $a=26,8$ . Откуда

$$\Delta a = |A - a| = |26,837 - 26,8| = 0,037 < (1/2) * 10^{-1} = 0,05,$$

т. е. число  $a$  имеет три верные значащие цифры в узком смысле

$$(m = 1, 1 - n + 1 = -1, n = 3).$$

При округлении приближенного числа  $a_1$  получаем новое приближенное число  $a_0$ , абсолютная погрешность каждого складывается из абсолютной погрешности первоначального числа  $a_1$  и погрешности округления, т.е.

$$\Delta a_2 = \Delta a_1 + \Delta_{окр}. \quad (3.1)$$

Пример 4. Округлить сомнительные цифры числа  $a_1 = 34,124 (\pm 0,021)$ . Определить абсолютную погрешность результата.

Решение. Приближенное число  $a_1$  имеет три верные цифры в узком смысле: 3, 4, 1, так как  $\Delta a_1 = 0,021 < (1/2) * 10^{-1} = 0,05$ . Применяя правила округления, найдем приближенное значение  $a_2$ , сохранив десятичные доли:  $a_2 = 34,1$ . Теперь получаем

$$\Delta a_2 = \Delta a_1 + \Delta_{окр} = 0,021 + 0,024 = 0,045 < 0,05.$$

Таким образом, все значащие цифры  $a_2$  верные (в узком смысле), т. е.  $a_2 = 34,1$ .

Однако при округлении приближенного числа  $a_1$ , имеющего  $n$  верных значащих цифр (в узком смысле), до  $n$  значащих цифр может оказаться, что округленное число  $a_2$  будет иметь  $n$  верных значащих цифр в широком смысле.

Пример 5. Приближенное число  $a_1 = 15,3654 \pm 0,0018$  имеет четыре верные значащие цифры в узком смысле 1, 5, 3, 6, так как

$$\Delta a_1 = 0,0018 < (1/2) * 10^{-2} = 0,005.$$

При округлении до 4-х значащих цифр получим  $a_2 = 15,37$  и

$$\Delta a_2 = \Delta a_1 + \Delta_{окр} = 0,0018 + 0,0046 = 0,0064.$$

Очевидно, что  $0,005 < 0,0064 < 0,01$ . Следовательно, число  $15,37 \pm 0,0064$  имеет четыре верные цифры в широком смысле ( $m = 1, 1 - n + 1 = -2, n = 4$ ).

Пример 6. Округлить сомнительные цифры числа

$$a_1 = 26,7245 \pm 0,0026,$$

оставив верные знаки в узком смысле. Определить абсолютную погрешность результата.

Решение. По условию  $\Delta a_1 = 0,0026 < 0,005$ , следовательно в числе 26,7245 верными в узком смысле являются цифры 2, 6, 7, 2. Используя правила округления, найдем приближенное значение  $a_2$ , сохранив сотые доли:

$$a_2 = 26,72.$$

Далее имеем

$$\Delta a_2 = \Delta a_1 + \Delta_{окр} = 0,0026 + 0,0045 = 0,0071.$$

Полученная погрешность больше 0,005 ( $0,005 < 0,0071$ ), поэтому уменьшим число цифр в приближенном числе до трех:

$$a_3 = 26,7.$$

Находим

$$\Delta a_3 = \Delta a_1 + \Delta_{окр} = 0,0026 + 0,0245 = 0,0271,$$

т.е.

$$\Delta a_3 < (1/2) * 10^{-1} = 0,05.$$

Следовательно, оставшиеся цифры верны в узком смысле

$$(m = 1, 1 - n + 1 = -1, n = 3).$$

Пример 7. Округлить сомнительные цифры числа  $a_1 = 22,7314$ , оставив верные знаки в узком смысле. Определить абсолютную погрешность числа, если  $\delta a_1 = 0,2\%$ .

Решение. Запишем  $\delta a_1 = 0,2/100 = 0,002$  и определим  $\Delta a_1$  по формуле  $\Delta a_1 = |a| * \delta a_1 = 22,7314 * 0,002 = 0,0455$ .

Так как  $\Delta a_1 = 0,0455 < 0,05$ , то верными в этом числе будут три цифры: 2,2,7 ( $m = 1, 1 - n + 1 = -1, n = 3$ ). Округлим число 22,7314, сохранив в нем десятые доли:  $a_2 = 22,7$ . Тогда  $\Delta a_2 = \Delta a_1 + \Delta_{окр} = 0,0455 + 0,0314 = 0,0769$ . Поскольку полученная по-

грешность больше 0,05, уменьшим число цифр в приближенном числе до двух:  $a_3 = 23$ ; тогда  $\Delta a_3 = \Delta a_1 + \Delta_{окр} = 0,0455 + 0,2686 = 0,3141$ , т. е.  $\Delta a_3 < 0,5$ . Таким образом, в полученном округленном числе 23 обе цифры являются верными в узком смысле

$$(m = 1, 1 - n + 1 = 0, n = 2).$$

Пример 8. Округлить сомнительные цифры числа  $a_1 = 5,273$ , оставив верные знаки в широком смысле. Определить абсолютную погрешность числа, если  $\delta a_1 = 0,1\%$ .

Решение. Находим  $\Delta a_1 = |a_1| * \delta a_1 = 5,273 * 0,001 = 0,0053 < 0,01$ . В числе  $a_1$  верными в широком смысле являются три цифры  $m = 0, 0 - n + 1 = -2, n = 3$  (5, 2, 7), поэтому округляем его до трех значащих цифр:  $a_2 = 5,27$ . Отсюда

$$\Delta a_2 = \Delta a_1 + \Delta_{окр} = 0,0053 + 0,003 = 0,0083 < 0,01.$$

Следовательно, округленное число 5,27 имеет три верные цифры в широком смысле ( $m = 0, 0 - n + 1 = -2, n = 3$ ).

#### § 4. Связь между числом верных знаков и относительной погрешности числа

Абсолютная погрешность приближенного числа связана с числом верных знаков соотношением:

$$\Delta a \leq w * 10^{m-n+1}, \quad (4.1)$$

что следует из определения верной значащей цифры. В какой же зависимости от числа верных значащих цифр находится относительная погрешность?

Запишем приближенное число

$$a = \alpha_1 * 10^m + \alpha_2 * 10^{m-1} + \alpha_3 * 10^{m-2} + \dots +$$

$$\alpha_n * 10^{m-n+1} + \dots, \alpha_1 \neq 0, \quad (4.2)$$

все цифры которого при данном выборе параметра  $w$  верные ( $0,5 \leq w \leq 1$ ). Разделив обе части неравенства (4.1) на  $|a|$ , получим:

$$\frac{\Delta a}{|a|} \leq \frac{w * 10^{m-n+1}}{|\alpha_1 * 10^m + \alpha_2 * 10^{m-1} + \alpha_3 * 10^{m-2} + \dots + \alpha_n * 10^{m-n+1} + \dots|} \leq$$

$$(w * 10^{m-n+1}) / (\alpha_1 * 10^m) = (w * 10^m) / (\alpha_1 * 10^m * 10^{n-1})$$

т.е.

$$\delta a \leq w / (\alpha_1 * 10^{n-1}), \quad (4.3)$$

где  $\alpha_1$  – первая значащая цифра числа;  $n$  – количество верных значащих цифр.

За предельную относительную погрешность можно принять:

$$\delta^* a = w / (\alpha_1 * 10^{n-1}). \quad (4.4)$$

Пример 1. Какова предельная относительная погрешность приближенного числа  $a=4,176$ , если оно имеет только верные цифры в узком смысле?

Решение. Так как в числе 4,176 все цифры верны в узком смысле, то выбираем  $w = 0,5$ . По формуле (4.4) находим предельную относительную погрешность:

$$\delta^* a = w / (\alpha_1 * 10^{n-1}) = 1 / (2 * 4 * 10^3) = 0,000125 = 0,0125 \%$$

Заметим, что предельную относительную погрешность числа  $a$  можно найти, пользуясь формулой  $\delta^* a = \Delta^* a / |a|$ . Так как в данном числе  $a$  все цифры верны в узком смысле, то

$$\Delta a = 0,0005 \quad (\Delta a \leq 0,5 * 10^{-3} = 0,0005, m = 0, 0 - n + 1 = -3, n = 4).$$

$$\text{Тогда } \Delta a = 0,0005 / 4,176 \approx 0,000120 = 0,0120\%.$$

Как видим, разница невелика, но применение формулы (4.4) несколько упрощает вычисление  $\delta^* a$ .

Пример 2. Какова предельная относительная погрешность числа  $a = 14,278$ , если оно имеет только верные цифры в широком смысле?

Решение. Так как все пять цифр числа верны в широком смысле, то  $w = 1$ . Тогда:

$$\delta^* a = w / (\alpha_1 * 10^{n-1}) = 1 / (1 * 10^4) = 0,0001 = 0,01\%.$$



Пример 3. Со сколькими верными десятичными знаками в узком смысле надо взять  $\sqrt{18}$ , чтобы погрешность не превысила 0,1%?

Решение. Здесь  $a = \sqrt{18} \approx 4, \dots$ ;  $\delta^* a \leq 0,001$ ;  $w = 0,5$ .

Поэтому имеем  $\delta^* a = 1/(2 * 4 * 10^{n-1}) \leq 0,001$ , откуда  $125 \leq 10^{n-1}$ ,

$$1,25 * 10^2 \leq 10^{n-1}, \log 1,25 + 2 \leq n - 1, n \geq 3 + \log 1,25, \text{ т.е. } n \geq 3,$$

где  $n$  – наименьший целочисленный аргумент. Для большей точности можно взять  $n = 4$ .

## § 5. Погрешность суммы и разности

### 5.1. Абсолютная погрешность

Теорема. Абсолютная погрешность алгебраической суммы нескольких приближенных чисел не превышает суммы абсолютных погрешностей этих чисел.

Доказательство. Пусть  $A = X_1 + X_2 + \dots + X_n$  – сумма точных чисел, причем  $X_i$  могут быть любого знака;  $a = x_1 + x_2 + x_3 + \dots + x_n$  – сумма приближенных значений этих чисел. Их абсолютные погрешности соответственно равны  $\Delta x_1, \Delta x_2, \Delta x_3, \dots, \Delta x_n$ . Вычитая  $A - a$ , имеем  $A - a = (X_1 - x_1) + (X_2 - x_2) + \dots + (X_n - x_n)$ . Переходя к модулям, получим  $|A - a| \leq |X_1 - x_1| + |X_2 - x_2| + \dots + |X_n - x_n|$ . Следовательно,

$$\Delta a \leq \Delta x_1 + \Delta x_2 + \dots + \Delta x_n \quad (5.1)$$

Следствие. Предельная абсолютная погрешность алгебраической суммы равна сумме предельных абсолютных погрешностей слагаемых.

Действительно, имеем  $\Delta x_1 \leq \Delta^* x_1, \dots, \Delta x_n \leq \Delta^* x_n$ . Подставляя значения предельных абсолютных погрешностей в неравенство (5.1), мы еще более усилим его:

$$\Delta a \leq \Delta^* x_1 + \dots + \Delta^* x_n,$$

или



$$\Delta^* a = \Delta^* x_1 + \dots + \Delta^* x_n. \quad (5.2)$$

При сложении чисел различной абсолютной точности рекомендуется поступать следующим образом:

- 1) выделить число (или числа) наименьшей абсолютной точности (т.е. число, имеющее наибольшую абсолютную погрешность);
- 2) наиболее точные числа округлить таким образом, чтобы сохранить в них на один знак больше, чем в выделенном числе (т.е. оставить один запасной знак);
- 3) произвести сложение, учитывая все сохраненные знаки;
- 4) полученный результат округлить на один знак.

Пример 1. Сложить несколько приближенных чисел:

$$a = 0,1732 + 17,45 + 0,000333 + 204,4 + 7,25 + 144,2 + 0,0112 + 0,634 + 0,0771$$

В каждом из приведенных чисел верны все значащие цифры (в широком смысле).

Решение. Выделяем два числа наименьшей точности: 204,4 и 144,2. Оба они верны с точностью до 0,1. Следовательно, остальные числа следует округлить с точностью до 0,01. Округлим и сложим эти числа:

|       |   |
|-------|---|
| 0,1   | 7 |
| 17,4  | 5 |
| 0,0   | 0 |
| 204,4 | - |
| 7,2   | 5 |
| 0,0   | 1 |
| 144,2 | - |
| 0,6   | 3 |
| 0,0   | 8 |
| 374,1 | 9 |

Округляя полученное число до 0,1, окончательно получим  $a = 374.2$ . Оценим точность результата. Для этого найдем полную погрешность, которая состоит из трех слагаемых:

1. суммы предельных погрешностей исходных данных

$$\Delta_1 = 0,0001 + 0,01 + 0,000001 + 0,1 + 0,01 + 0,1 + 0,0001 + 0,001 + 0,0001 = 0,221301 < 0,222$$

;

2. абсолютной величины суммы ошибок (с учетом их знаков) округления слагаемых

$$\Delta_2 = |0,0032 + 0,000333 + 0,0012 + 0,004 - 0,0029| = 0,005833 < 0,006;$$

3. заключительной погрешности округления результата  $\Delta_3 = 0,010$ .

Следовательно,

$$\Delta a = \Delta_1 + \Delta_2 + \Delta_3 \leq 0,222 + 0,006 + 0,010 = 0,238 < 0,3.$$

Искомая сумма есть  $374,2 \pm 0,3$ . Таким образом, убеждаемся, что окончательная погрешность не меньше предельной абсолютной погрешности наименее точного из слагаемых ( $0.3 > 0.1$ ).

## 5.2. Относительная погрешность суммы приближенных чисел

Определим предельную относительную погрешность суммы нескольких приближенных чисел. Рассмотрим два случая:

- 1) все слагаемые имеют одинаковые знаки;
- 2) слагаемые имеют разные знаки.

Рассмотрим первый случай: пусть  $a = x_1 + x_2 + \dots + x_n$ , где приближенные числа  $x_i$  ( $i = \overline{1, n}$ ) имеют соответственно предельные абсолютные погрешности  $\Delta^* x_1, \Delta^* x_2, \dots, \Delta^* x_n$ . Положим для простоты  $x_i > 0$ , тогда

$$\delta^* a = \Delta^* a / a. \quad (5.3)$$

Согласно формуле (5.2)  $\Delta a = \Delta^* x_1 + \dots + \Delta^* x_n$ . Подставляя  $\Delta^* a$  в формуле (5.3) и заменяя  $a$  суммой  $\sum_{i=1}^n x_i$ , получим

$$\delta^* a = \frac{\sum_{i=1}^n \Delta^* x_i}{\sum_{i=1}^n x_i}. \quad (5.3/)$$

Так как  $\Delta^* x_i = x_i * \delta^* x_i$ , то

$$\delta^* a = \frac{\sum_{i=1}^n x_i * \delta^* x_i}{\sum_{i=1}^n x_i}. \quad (5.3//)$$

Обозначим через  $\delta_{max}^*$  и  $\delta_{min}^*$  наибольшее и наименьшее из чисел  $\delta_{x_i}^*$ ; тогда имеем:

$$\delta^* a = \frac{\sum_{i=1}^n x_i * \delta^* x_i}{\sum_{i=1}^n x_i} < \frac{\delta_{max}^* * \sum_{i=1}^n x_i}{\sum_{i=1}^n x_i} = \delta_{max}^*.$$

Аналогично можно получить, что  $\delta^* a > \delta_{min}^*$ . Таким образом,

$$\delta_{min}^* < \delta^* a < \delta_{max}^*.$$

(5.4)

Следовательно, предельная относительная погрешность суммы слагаемых одного знака заключена между наименьшей и наибольшей предельными относительными погрешностями слагаемых.

Пример 2. Оценить относительную погрешность суммы чисел в примере 1 и сравнить ее с относительными погрешностями слагаемых.

Решение. Относительная погрешность суммы  $a$  такова:

$$\delta^* a = 0,3/374,2 = 0,0008 = 0,08\%.$$

Предельные относительные погрешности слагаемых составляют соответственно:

$$\begin{aligned} 1/1732 &= 0,058\%, \quad \frac{1}{1745} = 0,057\%, \quad 1/333 = 0,3\%, \\ 1/2044 &= 0,049\%, \quad 1/725 = 0,14\%, \quad 1/1442 = 0,069\%, \\ \frac{1}{112} &= 0,89\%, \quad \frac{1}{634} = 0,16\%, \quad \frac{1}{771} = 0,13\%, \\ \delta_{min}^* &= 0,049\%, \quad \delta_a^* = 0,08\%, \quad \delta_{max}^* = 0,89\%. \end{aligned}$$

Итак  $0,049 < 0,08 < 0,89$ .

Рассмотрим второй случай (разность): Пусть  $x > 0$ ,  $y > 0$  и  $x - y = a$ . Тогда, сохраняя прежние обозначения, получим:

$$\delta^* a = \frac{\Delta^* a}{|a|} = \frac{\Delta^* x + \Delta^* y}{|x - y|}.$$

Таким образом, если числа  $x$  и  $y$  мало отличаются друг от друга, то даже при малых погрешностях  $\Delta^* x$  и  $\Delta^* y$  величина предельной относительной погрешности может оказаться значительной.

Пример 3. Пусть  $x = 5,125$ ,  $y = 5,135$ ; здесь  $\Delta^* x = 0,0005$ ,  $\Delta^* y = 0,0005$ ,  $\delta^* x \approx \delta^* y \approx \frac{0,0005}{5,125} \approx \frac{0,0005}{5,135} \approx 0,01\%$ . Пре-

дельная же относительная погрешность разности  $a = x - y$  равна:

$$\delta^* a = \frac{0,0005 + 0,0005}{0,01} * 100 = 10\%.$$

В результате вычитания двух близких чисел может произойти большая потеря точности.

Пример 4. Найти разность  $u = \sqrt{6,27} - \sqrt{6,26}$  с тремя верными знаками.

Решение. Возьмем  $\sqrt{6,27}$  и  $\sqrt{6,26}$  с достаточно большим количеством верных значащих цифр, так как при вычитании близких друг другу чисел первые несколько цифр могут пропасть:

$$\sqrt{6,27} = 2,503997 \dots; \sqrt{6,26} = 2,501999 \dots$$

получим:

$$u = \sqrt{6,27} - \sqrt{6,26} = 0,001998 \approx 0,00200 = 2,00 * 10^{-3}.$$

Поступим по другому:

$$u = \sqrt{6,27} - \sqrt{6,26} = \frac{(\sqrt{6,27} - \sqrt{6,26}) * (\sqrt{6,27} + \sqrt{6,26})}{\sqrt{6,27} + \sqrt{6,26}} = \frac{6,27 - 6,26}{\sqrt{6,27} + \sqrt{6,26}},$$

тогда

$$u = \frac{0,01}{2,50 + 2,50} = \frac{0,01}{5,00} = 0,00200 = 2,00 * 10^{-3}$$

как и прежде.

Пример 5. Вычислить значение функции  $y = 1 - \cos x$  для следующих значений аргумента: 1)  $x = 80^\circ$ ; 2)  $x = 1^\circ$ .

Подсчитать предельные абсолютную и относительную погрешности результата.

Решение.

1. По таблице находим  $\cos 80^\circ = 0,1736$ . Так как все цифры этого числа верны в узком смысле, то  $\Delta_{\cos 80^\circ}^* = 0,00005$ . Тогда  $y_1 = 1 - \cos 80^\circ = 1 - 0,1736 = 0,8264$  и  $\Delta_{y_1}^* = 0,00005$ . Следовательно,  $\delta_{y_1}^* = \frac{0,00005}{0,8264} = 0,00006 = 0,006\%$ .

2. Имеем  $\cos 1^\circ = 0,9998$ ,  $\Delta_{\cos 1^\circ}^* = 0,00005$ ,  
 $y_2 = 1 - \cos 1^\circ = 1 - 0,9998 = 0,0002$ ,  $\Delta_{y_2}^* = 0,00005$ ,  
 $\delta_{y_2}^* = \frac{0,00005}{0,0002} = 0,25 = 25\%$ .

Изменим при малых значениях аргумента вычислительную схему  $y = 1 - \cos x = 2 * \sin^2 \frac{x}{2}$ . Обозначим  $a = \sin 0^\circ 30' = 0,0087$ .

Тогда  $\Delta_a^* = 0,00005$ ,  $\delta_a^* = \frac{0,5}{87} = 0,58\%$ . Но

$$y_2 = 1 - \cos x = 1 - \cos 1^\circ = 2 * \sin^2 0^\circ 30' = 2 * 0,0087^2 = 0,000151,$$

$$\delta_{y_2}^* = \delta_{a^2}^* = 2 * \delta_a^* = 1,16\%.$$

$$\Delta_{y_2}^* = y_2 * \delta_{y_2}^* = 0,000151 * 0,0116 = 0,0000018.$$

Таким образом, простое преобразование расчетной формулы позволило по тем же таблицам получить большую точность.

## § 6. Погрешность произведения.

### Погрешность частного. Относительная погрешность корня

Абсолютную погрешность произведения и частного удобно находить через относительную погрешность, используя формулу

$$\Delta u = |u| * \delta \text{ и.}$$

#### 6.1. Погрешность произведения

**Теорема.** Относительная погрешность произведения нескольких приближенных чисел, отличных от нуля, не превышает сумма относительных погрешностей этих чисел.

Доказательство. Пусть

$$u = x_1 * x_2 * x_3 * \dots * x_n, \quad x_i > 0, \quad (6.1)$$

и имеют абсолютные погрешности  $\Delta x_1, \Delta x_2, \dots, \Delta x_n$  соответственно. Из (6.1) имеем:

$$\ln u = \ln x_1 + \ln x_2 + \ln x_3 + \dots + \ln x_n. \quad (6.2)$$

По теореме из § 5 имеем:

$$\Delta \ln u \leq \Delta \ln x_1 + \dots + \Delta \ln x_n. \quad (6.3)$$

Используя приближенную формулу:

$$\Delta \ln x \approx d * \ln x = \frac{\Delta x}{x}, \quad \Delta \ln u \approx d * (\ln u) = \frac{\Delta u}{u}, \quad (6.4)$$

получим

$$\frac{\Delta U}{U} = \frac{\Delta x_1}{x_1} + \frac{\Delta x_2}{x_2} + \dots + \frac{\Delta x_n}{x_n}; \quad (6.5)$$

беря абсолютные значения, имеем:

$$\left| \frac{\Delta U}{U} \right| \leq \left| \frac{\Delta x_1}{x_1} \right| + \left| \frac{\Delta x_2}{x_2} \right| + \dots + \left| \frac{\Delta x_n}{x_n} \right|.$$

Или

$$\delta U = \frac{\Delta U}{U} \leq \sum_{i=1}^n \frac{\Delta x_i}{|x_i|},$$

так как  $x_i > 0, U > 0$ , т.е.

$$\delta U \leq \delta x_1 + \dots + \delta x_n. \quad (6.6)$$

Формула (6.6) верна и для случая  $x_i < 0$  и когда  $x_i$  имеют разные знаки. Зная  $\delta U$  можно вычислить  $\Delta U$ :

$$\Delta U = |U| * \delta U.$$

Следствие. Предельная относительная погрешность произведения равна сумме предельных относительных погрешностей сомножителей.

Действительно,

$$\delta^* x_1 \geq \delta x_1, \dots, \delta^* x_n \geq \delta x_n \quad (6.7)$$

Отсюда

$$\delta U \leq \delta^* x_1 + \dots + \delta^* x_n$$

или

$$\delta^* U = \delta^* x_1 + \dots + \delta^* x_n \quad (6.8)$$

Если приближенным числом является лишь значение множителя  $x_i$ , то

$$\delta^* U = \delta^* x_i. \quad (6.9)$$

Пусть  $U = k * x$ , где  $k$  – точный сомножитель, отличный от нуля. Тогда согласно формуле (6.9) имеем  $\delta^* U = \delta^* x$ , или

$$\Delta^* U = |u| * \delta^* U = |u| * \delta^* x = |k * x| * \frac{\Delta^* x}{|x|} = |k| * \Delta^* x,$$

т.е.

$$\Delta^* U = |k| * \Delta^* x \quad \text{и} \quad \delta^* U = \delta^* x \quad (6.10)$$

т.е. при умножении приближенного числа на точный множителей  $k$  относительная погрешность не меняется, а абсолютная погрешность увеличивается в  $|k|$  раз.

При перемножении чисел разной относительной точности (т.е. имеющих разное число верных значащих цифр) выполняют следующие действия по вычислению произведения:

- 1) выделяют число с наименьшим количеством верных значащих цифр (наименее точное число);
- 2) округляют оставшиеся сомножители таким образом, чтобы они содержали на одну значащую цифру больше, чем количество верных значащих цифр в выделенном числе;
- 3) сохраняют в произведение столько значащих цифр, сколько верных значащих цифр имеет наименее точный из сомножителей (выделенное число).

Пример 1. Найти произведение приближенных чисел  $x_1 = 3,6$  и  $x_2 = 84,489$  все цифры которых верны.

Решение. В первом числе две верные значащие цифры, а во втором – пять. Поэтому второе число округляем до трех значащих цифр. После округления имеем  $x_1 = 3,6$ ,  $x_2 = 84,5$ . Отсюда  $x_1 * x_2 = 3,6 * 84,5 = 304,20 \approx 3,0 * 10^2 = 300$ . В результате оставлены

две значащие цифры, т. е. столько, сколько их имел сомножитель с наименьшим количеством верных значащих цифр.

Пример 2. Пусть имеем числа  $x_1 = 12,2$ ,  $x_2 = 73,56$ . Все цифры верные. Найти произведение и число верных знаков.

Решение. Имеем  $\Delta_1 = 0,05$  (в узком смысле),  $\Delta_2 = 0,005$ . Отсюда  $\delta U = \frac{0,05}{12,2} + \frac{0,005}{73,56} = 0,042 \approx 0,004$ . Так как  $U = 897,432$ , то  $\Delta U = U * \delta U \approx 3,6 \approx 4$ . Отсюда видно, что  $U$  имеет лишь 2 верных знака в узком смысле ( $4 < \frac{1}{2} * 10^1$ ,  $m = 2$ ,  $2 - n + 1 = 1, n = 2$ ) и результат следует записать в виде  $U = 897 \pm 4$ .

## 6.2. Погрешность частного

Теорема.\_ Относительная погрешность частного не превышает суммы относительных погрешностей делимого и делителя.

Доказательство. Если  $U = \frac{x_1}{x_2}$ , то  $\ln U = \ln x_1 - \ln x_2$ ,  $\frac{\Delta U}{U} = \frac{\Delta x_1}{x_1} - \frac{\Delta x_2}{x_2}$ ,  
 $\left| \frac{\Delta U}{U} \right| = \left| \frac{\Delta x_1}{x_1} \right| + \left| \frac{\Delta x_2}{x_2} \right|$ ,  $\delta U \leq \delta_1 + \delta_2$ .

Пример 3. Найти число верных знаков частного  $U = \frac{27,7}{3,6}$ , если все цифры делителя и делимого верны (в узком смысле).

Решение.  $\delta U = \frac{0,05}{27,7} + \frac{0,05}{3,6} = 0,002 + 0,014 = 0,016$ . Так как  $U = 7,69$ , то  $\Delta U = 0,016 * 7,69 = 0,12$ , т. е. результат деления имеет два верных знака в широком смысле ( $m = 0,0 - n + 1 = -1, n = 2$ ) или одну цифру в узком смысле ( $m = 0, 0 - n + 1 = 0, n = 1$ ),  $U = 7,7 \pm 0,1$ .

Пусть  $x_1$  и  $x_2$  имеют  $n_1$  и  $n_2$  верных знака соответственно. Тогда:  
 $\delta U = \frac{1}{2} \left( \frac{1}{\alpha_1} * 10^{-n_1+1} + \frac{1}{\alpha_2} * 10^{-n_2+1} \right), w = \frac{1}{2}$ .



Пусть  $n = \min(n_1, n_2)$ , тогда  $\delta U \leq \frac{1}{2} * \left( \frac{1}{\alpha_1} + \frac{1}{\alpha_2} \right) * 10^{-n+1}$ , т. е. число верных знаков (в узком смысле) частного, по крайней мере, не меньше  $n$ , так как:

$$\delta U \leq \frac{10^{-n+1}}{\alpha_m},$$

где  $\alpha_m = \min(\alpha_1, \alpha_2)$ .

### 6.3. Относительная погрешность корня

Пусть  $U = x^{\frac{1}{m}}$ , тогда:

$$\delta U = \frac{1}{m} * \delta x. \quad (6.11)$$

То есть относительная погрешность корня  $m$ -ой степени в  $m$  раз меньше относительной погрешности подкоренного числа.

Пример 4. Определить с какой относительной погрешностью и со сколькими верными цифрами можно найти сторону квадрата, если его площадь  $S = 12,34$  известно с абсолютной погрешностью  $\Delta_S = 0,01$ .

Решение. Сторона квадрата

$$a = \sqrt{S} = 3,5128, \quad \delta_S = \frac{0,01}{12,34} \approx 0,0008, \quad \delta_a = \frac{1}{2} * \delta_S = 0,0004.$$

Воспользуемся формулой

$$\delta \leq \frac{1}{\alpha_m} * \left( \frac{1}{10} \right)^{\tilde{n}-1}, \quad \delta * \alpha_m = \left( \frac{1}{10} \right)^{\tilde{n}-1}, \quad \lg(\delta * \alpha_m) = 1 - \tilde{n},$$

$$\tilde{n} = 1 - \lg(\delta * \alpha_m),$$

$$\tilde{n} = 1 - \lg(3 * 0,0004) = 3,9 \approx 4 \quad (\text{ближайшее целое к } n).$$

## § 7. Общая формула для погрешности

Пусть задана дифференцируемая функция  $U = f(x_1, x_2, \dots, x_n)$  и  $\Delta_i = |\Delta x_i|$  – абсолютные погрешности аргументов функции. Тогда абсолютная погрешность функции:

$$\Delta U = |\Delta u| \approx |df(x_1, x_2, \dots, x_n)| = \left| \sum_{i=1}^n \frac{\partial f}{\partial x_i} * \Delta x_i \right| \leq \sum_{i=1}^n \left| \frac{\partial f}{\partial x_i} \right| * |\Delta x_i|$$

или

$$\Delta U \leq \sum_{i=1}^n \left| \frac{\partial f}{\partial x_i} \right| \Delta_i. \quad (7.1)$$

Поделив (7.1) на  $U$ , получим относительную погрешность:

$$\delta U \approx \sum_{i=1}^n \left| \frac{\partial}{\partial x_i} \ln U \right| \Delta_i. \quad (7.2)$$

Пример. Найти абсолютную погрешность и относительную погрешность шара  $V = \frac{1}{6}\pi d^3$ , если  $d = 3,7 \pm 0,05$  см,  $\pi = 3,14$ .

Решение.

$$\Delta V = \frac{\partial V}{\partial \pi} |\Delta \pi| + \frac{\partial V}{\partial d} |\Delta d|,$$

где

$$\frac{\partial V}{\partial \pi} = \frac{d^3}{6} = \frac{3,7^3}{6} = \frac{50,65}{6} = 8,44, \quad \frac{\partial V}{\partial \pi} |\Delta \pi| = 8,44 * 0,01 = 0,0844,$$

$$\frac{\partial V}{\partial d} = \frac{1}{2}\pi d^2 = \frac{3,14}{2} * 13,69 = 21,49, \quad \frac{\partial V}{\partial d} |\Delta d| = 21,49 * 0,05 = 1,075,$$

$$\Delta V = 0,0844 + 1,075 = 1,16,$$

$$V = \frac{1}{6} * \pi d^3 = 26,5 \pm 1,2 \text{ см}^3,$$

$$\delta V = \frac{\Delta V}{V} = \frac{1,16}{26,5} \approx 4\%.$$

## § 8. Погрешность функции

### 8.1. Погрешность функции многих переменных

Пусть  $f(x) = f(x_1, x_2, x_3, \dots, x_n)$  – дифференцируемая в области  $G$  функция  $n$  переменных, вычисление которой производится при приближенно заданных значениях аргументов  $x_1^*, x_2^*, x_3^*, \dots, x_n^*$ . Такая ситуация возникает, например, всякий раз, когда на ЭВМ производятся рас-

четы по формуле. Важно знать, какова величина неустранимой ошибки, вызванной тем, что вместо значения  $y = f(x)$  в действительности вычисляется значение  $y^* = f(x^*)$ , где  $x^* = (x_1^*, x_2^*, \dots, x_n^*)$ .

Введем обозначения: пусть  $[x, x^*]$  – отрезок, соединяющий точки  $x$ , и

$$x^*, \quad f'_{x_i} = \frac{\partial f}{\partial x_i}.$$

Утверждение. Для абсолютной погрешности значения  $y^* = f(x^*)$  справедлива следующая оценка:

$$\Delta(y^*) \leq \sum_{i=1}^n \max_{[x, x^*]} |f'_{x_i}| \Delta(x_i^*). \quad (8.1)$$

Доказательство. Оценка (8.1) вытекает из формулы конечных приращений Лагранжа:

$$f(x) - f(x^*) = \sum_{i=1}^n f'_{x_i}(\tilde{x})(x_i - x_i^*), \quad \tilde{x} \in [x, x^*].$$

Следствие. Если  $x^* \approx x$ , то в силу (8.1) можно положить

$$\bar{\Delta}^*(y^*) \approx \sum_{i=1}^n |f'_{x_i}(x^*)| * \bar{\Delta}(x_i^*), \quad (8.2)$$

$$\bar{\Delta}(\bar{y}^*) \approx \sum_{i=1}^n |f'_{x_i}(x)| * \bar{\Delta}(x_i^*). \quad (8.3)$$

Равенство (8.2) удобно для практических оценок, а равенство (8.3) – для теоретических построений. Из формул (8.2) и (8.3) вытекают приближенные равенства для оценки границ относительных погрешностей:

$$\bar{\delta}^*(y^*) \approx \sum_{i=1}^n v_i^* \bar{\delta}(x_i^*), \quad \bar{\delta}(\bar{y}^*) \approx \sum_{i=1}^n v_i \bar{\delta}(x_i^*). \quad (8.4)$$

Здесь

$$v_i^* = \frac{|x_i^*| |f'_{x_i}(x^*)|}{|f(x^*)|}, \quad v_i = \frac{|x_i| |f'_{x_i}(x)|}{|f(x)|}. \quad (8.5)$$

## 8.2. Погрешность функции одной переменной

Формулы для границ погрешностей функции  $f(x)$  одной переменной являются частным случаем формул (8.2) – (8.4) при  $n = 1$ :

$$\bar{\Delta}^*(y^*) \approx |f'(x^*)| \bar{\Delta}(x^*), \quad \bar{\Delta}(\bar{y}^*) \approx |f'(x)| * \bar{\Delta}(x^*), \quad (8.6)$$

$$\bar{\delta}^*(y) \approx v^* \bar{\delta}(x^*), \quad \bar{\delta}(y^*) \approx v \bar{\delta}(x^*), \quad (8.7)$$

где

$$v^* = \frac{|x^*| |f'(x^*)|}{|f(x^*)|}, \quad v = \frac{|x| |f'(x)|}{|f(x)|}.$$

### 8.3. Погрешность неявной функции

Нередко приходится сталкиваться с ситуацией, когда функция  $y = f(x_1, x_2, \dots, x_n)$  задается не явной формулой, а как решение нелинейного уравнения  $F(y, x_1, x_2, \dots, x_n) = 0$ , т.е. неявно.

Если для такой неявной функции воспользоваться известными формулами вычисления производных:

$$f'_{x_i}(x) = \left( -\frac{F'_{x_i}}{F'_y} \right) = f(x), \quad (8.8)$$

при  $y=f(x), i = \overline{1, n}$ ,

то исследование неустранимой погрешности неявной функции сразу же сводится к рассмотренному выше случаю.

## § 9. Общие правила проведения вычислений

При массовых вычислениях рекомендуется пользоваться следующими правилами:

1) при сложении, вычитании, умножении и делении приближенных чисел в результате следует оставить столько значащих цифр, сколько их имеет приближенное данное с наименьшим числом верных цифр;

2) при возведении в степень нужно сохранять столько значащих цифр, сколько их имеет основание;

3) если некоторые данные имеют излишние десятичные младшие разряды (при сложении и вычитании) или больше значащих цифр, чем другие (при умножении, делении, возведения в степень, извлечения

корня), то их предварительно нужно округлить, сохраняя одну запасную цифру;

4)если данные можно брать с произвольной точностью, то для получения результата с  $n$  верными цифрами исходные данные следует брать с таким числом цифр, чтобы обеспечить в результате  $n + 1$  цифру. Затем результат округляется на одну цифру.

## § 10. Обратная задача теории погрешностей

Какова должны быть абсолютные погрешности аргументов функции, чтобы абсолютная погрешность функции не превышала заданной величины.

Эта задача математически не определена, так как заданную предельную абсолютную погрешность  $\Delta_U$  функции  $U = f(x_1, x_2, \dots, x_n)$  можно обеспечить, устанавливая по разному предел абсолютной погрешности  $\Delta_i$  ее аргументов.

Простейшее решение обратной задачи дается принципом равных влияний. Согласно этому принципу предполагается, что все слагаемые в сумме погрешностей одинаково влияют на образование общей абсолютной погрешности  $\Delta_U$ .

Пусть  $\Delta_U$  задана. Тогда имеем:

$$\Delta_U = \sum_{i=1}^n \left| \frac{\partial U}{\partial x_i} \right| \Delta_i.$$

Полагая, что все слагаемые равны между собой будем иметь:

$$\left| \frac{\partial U}{\partial x_1} \right| \Delta_1 = \left| \frac{\partial U}{\partial x_2} \right| \Delta_2 = \dots = \left| \frac{\partial U}{\partial x_n} \right| \Delta_n = \frac{\Delta_U}{n}.$$

Отсюда

$$\Delta_i = \frac{1}{n} * \frac{\Delta_U}{\left| \frac{\partial U}{\partial x_i} \right|}, i = \overline{1, n}.$$

Пример. Радиус основания цилиндра  $R \approx 2\text{м}$ ; высота  $H = 3\text{м}$ . С какими абсолютными погрешностями нужно определить  $R$  и  $H$ , чтобы его объем можно было вычислить с точностью до  $0,1\text{м}^3$ .

Решение. Объем цилиндра

$$V = \pi R^2 * H.$$

Вычисляем:  $\frac{\partial V}{\partial \pi} = R^2 H = 12$ ;  $\frac{\partial V}{\partial R} = 2\pi R H = 37,7$ ;  $\frac{\partial V}{\partial H} = \pi R^2 = 12,6$ ,  $n = 3$  — количество слагаемых.

$$\Delta \pi = \frac{1}{3} * \frac{0,1}{\frac{\partial V}{\partial \pi}} = \frac{0,1}{3,12} \approx 0,003; \quad \Delta R = \frac{1}{3} * \frac{0,1}{\frac{\partial V}{\partial R}} = \frac{0,1}{3 * 37,7} \approx 0,001;$$

$$\Delta H = \frac{1}{3} * \frac{0,1}{\frac{\partial V}{\partial H}} = \frac{0,1}{3 * 12,6} \approx 0,003.$$

## § 11. Погрешности вычислений на ЭВМ

Диапазон чисел  $M$ , с которыми оперирует ЭВМ, принадлежит некоторому интервалу  $(M_0, M_\infty)$ ,  $M_0 > 0$ ,  $M_\infty < \infty$ , где  $M_0$  — машинный ноль,  $M_\infty$  — машинная бесконечность.

Если  $|M| < \infty$  в процессе вычисления нарушается, то происходит аварийный останов ЭВМ вследствие переполнения разрядной сетки.

Если решение исходной задачи выражается через очень большие (очень малые) числа  $|M| > M_\infty$  ( $|M| < M_0$ ), то как правило путем изменения масштаба можно привести задачу к виду, содержащему только величины  $M \in (M_0, M_\infty)$ . Иногда возможность авоста можно устранить путем изменения порядка действий.

Пример 1. Пусть  $M_\infty = 10^p, M_0 = 10^{-p}, p = 2^n, n$  — целое. Требуется вычислить произведение чисел  $10^{\frac{p}{2}}, 10^{\frac{p}{4}}, 10^{-\frac{p}{2}}, 10^{\frac{3p}{4}}, 10^{-\frac{3p}{4}}$ .

1 способ. Пронумеруем числа в порядке убывания  $q_1 = 10^{\frac{3p}{4}}$ ,

$q_2 = 10^{\frac{p}{2}}, q_3 = 10^{\frac{p}{4}}, q_4 = 10^{-\frac{p}{2}}, q_5 = 10^{-\frac{3p}{4}}$  образуем произведение  $S_{k+1} = S_k * q_{k+1}, S_1 = q_1$ . Тогда уже на первом шаге мы получим авост, так как  $S_2 = q_1 * q_2 > M_{\infty}$ .

2 способ. Пронумеруем числа в порядке возрастания

$$q_1 = 10^{-\frac{3p}{4}}, q_2 = 10^{-\frac{p}{2}}, q_3 = 10^{\frac{p}{4}}, q_4 = 10^{\frac{p}{2}}, q_5 = 10^{\frac{3p}{4}}.$$

В этом случае получим на первом шаге  $S_2 = q_1 * q_2 < M_0$ , т. е.

$S_2$  – машинный нуль. Нулю будут равны и все последующие произведения  $S_3, S_4, S_5$ . Таким образом, здесь происходит полная потеря точности.

3 способ. Перемешаем числа

$$q_1 = 10^{-\frac{3p}{4}}, q_2 = 10^{\frac{p}{2}}, q_3 = 10^{\frac{3p}{4}}, q_4 = 10^{-\frac{p}{2}}, q_5 = 10^{\frac{p}{4}}.$$

Тогда получим последовательно:

$$S_2 = q_1 * q_2 = 10^{-\frac{p}{4}}, S_3 = S_2 * q_3 = 10^{\frac{p}{2}},$$

$$S_4 = S_3 * q_4 = 10^0, S_5 = S_4 * q_5 = 10^{\frac{p}{4}}.$$

Такой алгоритм называется без авостным.

При каждом такте вычислений появляются погрешность округления (вычислительная погрешность). В зависимости от алгоритма эти погрешности могут нарастать, либо затухать. Если в процессе вычислений погрешности округлений неограниченно нарастают, то такой алгоритм называют неустойчивым. Если погрешности не накапливаются, то алгоритм называется устойчивым.

Пример 2. Пусть требуется найти  $y_i (0 \leq i \leq i_0)$  по формуле  $y_{i+1} = y_i + d (i \geq 0)$  при заданных  $y_0$  и  $d$ . Предположим, что при вычислении  $y_1$  внесена погрешность  $\delta_1$ , т.е. вместо точного  $y_1$  получим  $\tilde{y}_1 = y_0 + d + \delta_1 = y_1 + \delta_1$ . Тогда, вместо  $y_2$  получим  $\tilde{y}_2 = \tilde{y}_1 + d + \delta_2 = y_2 + \delta_1 + \delta_2$ . Для  $y_i$  следует

$$\tilde{y}_i = \tilde{y}_{i-1} + d + \delta_i = y_i + \delta_1 + \delta_2 + \dots + \delta_i = y_i + \sum_{k=1}^i \delta_k \leq y_i + i * \delta_m,$$

где  $\delta_m$  – максимальная ошибка округления. В этом примере идет очень медленное накопление ошибок округления.

Пример 3. Рассмотрим соотношение  $y_{i+1} = q * y_i$  ( $i \geq 0$ ),  $y_0$  и  $q$  заданы. Пусть вместо  $y_1 = q * y_0$  мы получили  $\tilde{y}_1 = y_1 + \delta$ . Тогда даже если дальнейшие вычисления будут точными, мы получим

$$\begin{aligned}\tilde{y}_2 &= q * (y_1 + \delta) = y_2 + q\delta, \tilde{y}_3 = q * (y_2 + q\delta) = \\ &= y_3 + q^2\delta, \dots, \tilde{y}_{i+1} = y_i + q^i\delta.\end{aligned}$$

Отсюда следует  $\delta_{i+1} = q^i\delta$ ,  $i = 0, 1, \dots$ . Если  $|q| > 1$ , то в процессе вычислений погрешность будет быстро возрастать (алгоритм не устойчив). Если  $|q| < 1$ , то погрешность не возрастает (алгоритм устойчив).

Если  $M_\infty = 10^p$ ,  $\delta = 10^{-k}$ , то при некотором  $i = i_0$ , удовлетворяющем неравенству  $|q|^i * \delta \geq M_\infty$  наступает авост. Отсюда  $i_0 = \frac{p+k}{\lg|q|}$ . Таким образом, вычисления необходимо закончить пока  $i < \frac{p+q}{\lg|q|}$ .

Пусть в процессе вычислений погрешность растет по степенному закону  $|\delta_i| = i^n \delta$  ( $n \geq 1$ ). Тогда авост наступит при  $i^n * \delta \geq M_\infty$ , т. е.  $i_0 \geq \left(\frac{M_\infty}{\delta}\right)^{\frac{1}{n}} = 10^{\frac{p+k}{n}}$ . Отсюда видно, что при  $n = 1$  авоста не будет, так как для этого надо, чтобы  $i_0$  удовлетворяло неравенству  $i_0 \geq 10^{p+k}$ , что на практике не выполняется.

Пусть задана точность  $\delta_0 = 10^{-k_0}$  и мы хотим обеспечить  $|\delta_i| = i^n * \delta < \delta_0$ , тогда  $i \leq i_0 = \left(\frac{\delta_0}{\delta}\right)^{\frac{1}{n}} = 10^{\frac{k-k_0}{n}}$ . Последнее неравенство определяет ограничение на число итераций  $i \leq i_0$ . Так при  $k = 12$ ,  $k_0 = 6$  имеем  $i_0 = 10^{\frac{6}{n}}$ , при  $n = 1$  получим  $i \leq 10^6$ , а при  $n = 2$ ,  $i \leq 10^3$ .

При уменьшении  $n$  число допустимых шагов  $i_0$  будет уменьшаться. На практике  $n$  обычно не велико.



## Литература

- 1.Амосов А. А, Дубинский Ю. А, Копченова Н. В. Вычислительные методы для инженеров. – М.: Высшая школа, 1994. – 544 с.
- 2.Бахвалов Н. С, Жидков Н. С, Кобельков Г. М. Численные методы. – М.: Бином, 2003. -632 с.
- 3.Воробьева Г. Н, Данилова А. Н. Практикум по вычислительной математике. – М.: Высшая школа, 1990. – 208 с.
- 4.Демидович Б. П, Марон И .А., Основы вычислительной математики – М.: Наука, 1966. – 664 с.
- 5.Калиткин Н. Н. Численные методы. – М.: Наука, 1978. – 512 с.
- 6.Каханер Д, Моулер К., Нэш С. Численные методы и программное обеспечение. – М.: Мир, 2001. – 575с.
- 7.Мицель А. А. Вычислительная математика. Учебное пособие. – Томск: Томский межвузовский центр дистанционного образования, 2001. – 228 с.
- 8.Охлопков Н. М. Методологические и технологические вопросы прикладной и вычислительной математики. – Якутск: ЯГУ, 1991. – 202 с.
9. Охлопков Н. М. Численные методы и вычислительные алгоритмы. Часть 1. – Якутск: ЯГУ, 1994 – 108 с.
10. Охлопков Н. М, Охлопков Г. Н. Введение в специальность “прикладная математика”, ч. 1. – Якутск: ЯГУ, 1997. – 93 с.

# Глава 3. ВЫЧИСЛИТЕЛЬНАЯ ЗАДАЧА И ВЫЧИСЛИТЕЛЬНЫЙ АЛГОРИТМ

## § 1. Вычислительная задача

К вычислительным задачам относим те задачи, решение которых находится путем вычисления с применением ЭВМ: прямые задачи; обратные задачи; задачи оптимизации; задачи идентификации и т. д. Все величины, включенные в математическую модель, условно разобьем на три группы:

- 1) входные данные  $x$ ,
- 2) параметры модели  $P$ ,
- 3) искомое решение (выходные данные)  $y$ .

Вычислительную задачу запишем символически в виде:

$$y = f(x; p), \quad x \in X, y \in Y. \quad (1.1)$$

Пример 1. Пусть имеем зависимость

$$y = ax^2 + bx + c. \quad (1.2)$$

1. Прямая задача. В этом примере  $x \in X$  – входные данные задачи, которые задаются. Параметрами задачи являются  $a, b, c$  которые известны. Требуется найти  $y \in Y$ .
2. Обратная задача. При известном значении  $y \in Y$  требуется найти соответствующее значение  $x \in X$  при заданных значениях  $a, b, c$ . Для нахождения  $x$  имеем квадратное уравнение относительно  $x$ :

$$ax^2 + bx + d = 0, \quad d = c - y.$$

3. Оптимизационная задача. Требуется найти экстремальные значения функции  $y$  на некотором множестве  $x \in X = [x_1, x_2]$  при заданном значении параметров  $a, b, c$ . Функция (1.2) является непрерывной и дифференцируемой. Поэтому воспользуемся аппаратом математического анализа. В данном случае мы имеем задачу нахождения наибольшего или

наименьшего значений функции в отрезке  $[x_1, x_2]$ . Находим  $y' = 2ax + b = 0$ ,  $x = -\frac{b}{2a}$ . Пусть  $a = 3$ ,  $b = 2$ ,  $c = 4$ ,  $x_1 = -1$ ,  $x_2 = 0$  тогда получаем  $x = -\frac{1}{3}$ ,  $y(0) = 4$ ,  $y(-1) = 5$ ,  $y(-\frac{1}{3}) = 3\frac{2}{3}$ . Отсюда находим

$$y_{\text{наиб.}}(-1) = 5, y_{\text{наим.}}(-\frac{1}{3}) = 3\frac{2}{3}.$$

4. Задача идентификации. Предположим, что в результате эксперимента получены значения переменных:

|     |       |       |     |       |
|-----|-------|-------|-----|-------|
| $x$ | $x_1$ | $x_2$ | ... | $x_n$ |
| $y$ | $y_1$ | $y_2$ | ... | $y_n$ |

Пусть мы каким-то образом определили структуру математической модели в виде (1.2). Надо определить параметры  $a, b, c$  модели (1.2). Таким образом, мы имеем задачу параметрической идентификации модели (1.1). Для определения параметров модели  $\tilde{y} = \tilde{f}(x; a, b, c)$

(1.3)

можно использовать методы: выбранных точек; средних; наименьших квадратов [12]. Идея метода средних состоит в следующем. Пусть структура модели (1.1) имеет вид (1.3). Если в модели (1.3) поставить исходные данные  $(x_i, y_i)$ ,  $i = \overline{1, 9}$ , то левая часть модели (1.3) не будет равна точно правой части, в силу неизбежной погрешности в определении  $(x_i, y_i)$ . Разность (невязка)  $\varepsilon_i = \tilde{f}(x_i; a, b, c) - y_i$ ,  $i = \overline{1, 9}$  называется уклонением, Для нахождения параметров модели (1.3) необходимо иметь три уравнения. Для этого все уклонения  $\varepsilon_i, i = \overline{1, 9}$  разобьем на три группы (по числу параметров), содержащих по три уклонения, Приравнявая к нулю алгебраическую сумму  $E_j, j = \overline{1, 3}$

$$\left( E_j = \sum_{i=1}^9 \varepsilon_i = 0 \right) \text{ уклонений, входящих в каждую из этих групп,}$$

получим систему, содержащую три уравнения с тремя неизвестными

$a, b, c$ . Решая эту систему, находим неизвестные параметры

$$a, b, c, (E_1 = \sum_{i=1}^3 \varepsilon_i = 0, E_2 = \sum_{i=4}^6 \varepsilon_i = 0, E_3 = \sum_{i=7}^9 \varepsilon_i = 0).$$

## § 2. Корректность вычислительной задачи

В абстрактной и прикладной математике задачи ставятся по разному. Теоретическая вычислительная задача

$$y = f(x, p) \tag{2.1}$$

называется корректной по Адамару – Петровскому, если выполнены следующие требования:

- 1) её решения  $y \in Y$  существует при любых допустимых входных данных  $x \in X$ ;
- 2) это решение единственно;
- 3) решение устойчиво по отношению к малым возмущениям входных данных.

Если не выполнено хотя бы одно из этих условий, то теоретическая вычислительная задача считается некорректно поставленной.

Устойчивость теоретической вычисляемой задачи по входным данным  $x$  означает непрерывную зависимость решения  $y$  от входных данных  $x$ . Это означает, что для любого сколь угодно малого  $\varepsilon > 0$  существует сколь угодно малое  $\delta = \delta(\varepsilon) > 0$  такое, что всякому исходному данному  $x^*$ , удовлетворяющему условию  $\Delta x^* = \|x - x^*\| < \delta$ , отвечает приближенное решение  $y^*$  для которого  $\Delta y^* = \|y - y^*\| < \varepsilon$ . Неустойчивость решения  $y$  означает, что существует такое  $\varepsilon_0$ , что какое бы малое  $\delta > 0$  ни было задано, найдутся такие исходные данные  $x^*$ , что  $\Delta(x^*) < 0$ , но  $\Delta(y^*) \geq \varepsilon_0$ . Таким образом, для устойчивой теоретической вычислительной задачи ее решение теоретически можно найти со сколь

угодно высокой точностью  $\varepsilon$ , если обеспечена достаточно высокая точность  $\delta$  входных данных.

Прикладная вычислительная задача

$$y^* = f(x^*, x^*) \quad (2.2)$$

считается поставленной корректно, если выполнены следующие условия:

- 1) её решение  $y^* \in Y$  существует при любых допустимых входных данных  $x^*$ ;
- 2) любое решение, дающее решение исходной задачи в пределах заданной точности, будем считать "приемлемым" решением;
- 3) решение устойчиво по отношению к малым погрешностям входных данных.

Пример 1. Рассмотрим квадратное уравнение

$$x^2 + px + q = 0. \quad (2.3)$$

Если считать входными данными пару коэффициентов  $(p, q)$  и искать решение во множестве вещественных чисел, то решение

$$x_1 = \frac{-p + \sqrt{p^2 - 4q}}{2}, x_2 = \frac{-p - \sqrt{p^2 - 4q}}{2} \quad (2.4)$$

существует при выполнении условия  $p^2 - 4q \geq 0$ .

Если допустить, что  $p$  и  $q$  могут принимать и комплексные значения, то множество возможных решений будет расширено и  $x_1, x_2$  будут принимать комплексные значения.

Единственность решения прямой и обратной задач является естественным свойством. Для задачи оптимизации не единственность решения можно рассматривать как благоприятный фактор. В данном случае имеется выбор и можно оптимизировать решение задачи еще и по другим параметрам.

Не единственность решения задачи может быть вызвана: неудачным выбором математической модели; неправильной постановкой исходной прикладной проблемы; неоднозначности ее решения и т.д.

Пример 2. Покажем, что задача вычисления определенного интеграла

$$I = \int_a^b f(x) dx$$

устойчива.

Пусть  $f^*(x)$  – приближенно заданная интегрируемая функция и

$$I^* = \int_a^b f^*(x) dx. \text{ Определим абсолютную погрешность функции } f^*(x)$$

с помощью равенства  $\Delta(f^*) = \sup_{x \in [a, b]} |f(x) - f^*(x)|$ , если  $f$  и  $f^*$  непре-

рывны, то можно положить  $\Delta(f^*) = \max_{x \in [a, b]} |f(x) - f^*(x)|$ .

Так как

$$\Delta(I^*) = |I - I^*| = \left| \int_a^b (f(x) - f^*(x)) dx \right| \leq (b - a) \Delta(f^*) \quad (2.5)$$

то для любого  $\varepsilon > 0$  неравенство  $\Delta(I^*) < \varepsilon$  будет выполнено, если потребовать выполнения условия  $\Delta(f^*) < \delta = \frac{\varepsilon}{b-a}$ .

Пример 3. Покажем, что задача вычисления производной  $u(x) = f'(x)$  приближенно заданной функции  $f^*(x)$  является неустойчивой.

Пусть функция  $f^*(x)$  – непрерывно дифференцируема и  $u^*(x) = (f^*)'(x)$ . Определим абсолютные погрешности с помощью равенств:

$$\Delta(f^*) = \max_{x \in [a, b]} |f(x) - f^*(x)|, \Delta(u^*) = \max_{x \in [a, b]} |u(x) - u^*(x)|.$$

Пусть  $f^*(x) = f(x) + a \sin\left(\frac{x}{a^2}\right)$  где  $0 < a \ll 1$ .

Тогда  $u^*(x) = u(x) + a^{-1} \cos\left(\frac{x}{a^2}\right)$  и  $\Delta(u^*) = a^{-1}$ ,

в то время как  $\Delta(f^*) = a$ . Таким образом, сколь угодно малой погрешности задания функции  $f(x)$  может отвечать сколь угодно большая погрешность производной  $f'(x)$ .

Может случиться и так, что одна и та же задача будет как устойчивой, так и неустойчивой в зависимости от выбора способа вычисления абсолютных погрешностей  $\Delta(x^*)$ ,  $\Delta(y^*)$ .

Понятие относительной устойчивости решения вычислительной задачи вводится, так же как и абсолютная устойчивость, где  $\Delta(x^*)$ ,  $\Delta(y^*)$  соответственно заменяются на  $\delta(x^*)$  и  $\delta(y^*)$ .

Пример 4. Пусть имеем сходящийся ряд

$$S = \sum_{k=0}^{\infty} a_k.$$

Предположим, что члены ряда заданы приближенно, т.е.  $a_k^* = a_k$ . Надо вычислить сумму ряда

$$S^* = \sum_{k=0}^{\infty} a_k^*.$$

Если гарантируется малость  $\Delta(a_k^*)$  для всех  $k$ , то для последовательности  $a^* = \{a_k^*\}_{k=0}^{\infty}$  естественно положить,  $\Delta a_k^* = \sup_{k \geq 0} |a_k - a_k^*|$ . Покажем,

что при таком способе вычисления  $\Delta(a_k^*)$ , задача неустойчива. Для этого положим:  $a_k^* = a_k + \delta$  для  $k < N$  и  $a_k^* = a_k$  для  $k \geq N$ . Тогда для

$$S^* = \sum_{k=0}^{\infty} a_k^* \text{ имеем } \Delta(S^*) = N \cdot \delta. \text{ Отсюда видно, что при любом малом}$$

$\Delta(a_k^*) = \delta$ , абсолютную погрешность суммы ряда  $S^*$  с помощью выбора  $N$  можно сделать сколь угодно большой. Если же положить  $a_k^* = a_k + \delta$  для всех  $k$ , то сумма ряда  $S^*$  станет бесконечной, т.е. ряд станет расходящимся.

Однако, если можно задавать  $a_k^*$  так, чтобы оказалось малой величиной

$$\Delta(a_k^*) = \sum_{k=0}^{\infty} |a_k - a_k^*|, \text{ то } \Delta(S^*) = \left| \sum_{k=0}^{\infty} (a_k - a_k^*) \right| \leq \Delta(a^*) \text{ и в такой}$$

постановке задача устойчива. Здесь речь шла об абсолютной устойчивости.

Рассмотрим относительную устойчивость задачи. Предположим, что  $a_k \neq 0$  для всех  $k$ . Часто можно гарантировать малость величины

$$\Delta(a^*) = \sup_{k \geq 0} \{|a_k - a_k^*|/|a_k|\}. \text{ Тогда } \Delta(a_k^*) \leq |a_k| \cdot \delta(a^*) \text{ и поэтому}$$

$$\Delta(S^*) \leq \sum_{k=0}^{\infty} |a_k| \cdot \delta(a^*).$$

Отсюда

$$\delta(S^*) \leq \left[ \sum_{k=0}^{\infty} |a_k| / \sum_{k=0}^{\infty} |a_k| \right] \cdot \delta(a^*). \quad (2.6)$$

Таким образом, задача вычисления суммы сходящегося ряда  $S$  относительно устойчива, если он сходится абсолютно (т. е. сходится ряд

$$\sum_{k=0}^{\infty} |a_k|). \text{ Если же ряд сходится только условно, т. е. } \sum_{k=0}^{\infty} |a_k| = \infty, \text{ то}$$

задача не является относительно устойчивой.

### § 3. Обусловленность вычислительной задачи

В классической математике исходные данные задачи задаются абсолютно точно и вычисления проводятся без потери информации, а следовательно, и результаты будут точными. Долгое время предполагалось, что переход к решению задач практики (прикладной математики) со сколь угодно точными входными данными и соответствующей точности вычислений принципиальных изменений не произойдет в постановке и решении задачи. Такое неверное представление считалось справедли-



вым, хотя математикам были известны примеры задач, в которых очень малая погрешность во входных данных задачи может играть принципиальную роль. Как влияют малые, но конечные погрешности входных данных на решение, как сильно они могут исказить желаемый результат?

Под обусловленностью вычислительной задачи понимают чувствительность её решения к малым погрешностям входных данных.

Задачу называют хорошо обусловленной, если малым погрешностям входных данных отвечают малые погрешности решения, и плохо обусловленной, если возможны сильные изменения решения.

Под числом обусловленности понимают коэффициент возможного возрастания погрешностей в решении по отношению к вызвавшим их погрешностям входных данных.

Если между абсолютными погрешностями входных данных  $x$  и решения  $y$  установлено неравенство

$$\Delta(y^*) = \|y - y^*\| \leq \vartheta_{\Delta} \Delta(x^*) = \vartheta_{\Delta} \|x - x^*\|, \quad (3.1)$$

то величина  $\vartheta_{\Delta}$  называется абсолютным числом обусловленности. Если же установлено неравенство между относительными погрешностями данных и решения

$$\delta(y^*) = \frac{\|y - y^*\|}{\|y^*\|} \leq \vartheta_{\delta} \delta(x^*) = \frac{\vartheta_{\delta} \|x - x^*\|}{\|x^*\|}, \quad (3.2)$$

то величину  $\vartheta_{\delta}$  называют относительным числом обусловленности. В неравенствах (3.1) и (3.2) вместо  $\Delta$  и  $\delta$  можно взять предельные погрешности  $\bar{\Delta}$  и  $\bar{\delta}$ . Часто под числом обусловленности понимают относительное число обусловленности. Для плохо обусловленной задачи  $\vartheta \gg 1$ . Неустойчивость задачи – это крайнее проявление плохой обусловленности, отвечающее значению  $\vartheta = \infty$ . Например,  $\vartheta = 10^N$ , где  $\vartheta$  – относительное число обусловленности, то порядок  $N$  показывает число верных

цифр, которое может быть утеряно в входных данных по сравнению с числом верных цифр входных данных. Например, если требуется найти решение с точностью 0,1%, а входная информация задается с точностью 0,02%, то уже значение  $\vartheta = 10$  близко к плохой обусловленности. Если исходные данные заданы с точностью не ниже 0,0001%, то и  $\vartheta = 10^3$  означает хорошую обусловленность задачи.

Таким образом, каково, то значение  $\vartheta$ , при котором следует признать задачу плохо обусловленной? Ответ на этот вопрос существенно зависит, с одной стороны, от предъявляемых требований к точности решения и, с другой – от уровня обеспечиваемой точности исходных данных. Грубо говоря если  $\vartheta \sim 10^N$ , где  $\vartheta$  – относительное число обусловленности, то порядок  $N$  показывает число верных цифр, которое может быть утеряно в результате  $y$  по сравнению с числом верных цифр входных данных  $x$ .

Подчеркнем, что потеря точности объективно обусловлена погрешностью задания входных данных и не связана с используемым алгоритмом.

Пример1. Пусть окончательный результат решения прикладной задачи сводится к формуле  $y = 1 - x$ , где  $x$  определяется предварительно. Предположим, что найденное приближение  $x^* = 0,999997$  к значению  $x$  содержит шесть верных значащих цифр. Тогда  $y^* = 1 - 0,999997 = 0,000003$  и в процессе вычисления оказались потерянными пять цифр.

Здесь  $\delta(x^*) = \frac{0.000001}{0.999997} * 100\% = 0.0001\%$ , а

$$\delta(y^*) = \frac{0,000001}{0,000003} \cdot 100\% = 0,33 \cdot 100\% = 33\%.$$

Отсюда видно, что произошла катастрофическая потеря точности. Здесь произошло вычитание близких чисел одного знака.

Пусть имеем точные числа  $a$  и  $b$  и их приближенные значения  $a^*$  и  $b^*$ . Тогда имеем

$$|a \pm b| \delta(a^* \pm b^*) = \Delta(a^* \pm b^*) \leq \Delta(a^*) + \Delta(b^*) = |a| \delta(a^*) + |b| \delta(b^*) \leq (|a| + |b|) \delta_{max} = |a + b| \delta_{max}.$$

Отсюда следует оценка

$$\delta(a^* + b^*) \leq \delta_{max}, \quad \delta(a^* - b^*) \leq \vartheta \delta_{max}, \quad (3.3)$$

где

$$\vartheta = \frac{|a + b|}{|a - b|}, \quad \delta_{max} = \max\{\delta(a^*), \delta(b^*)\}.$$

Первое из неравенств (3.3) означает, что при суммировании чисел одного знака не происходит потеря точности, если оценивать точность в относительных единицах. Совсем иначе обстоит дело при вычитании чисел одного знака. Здесь граница относительной ошибки возрастает в  $\vartheta > 1$  раз и возможна существенная потеря точности. В нашем случае имеем:

$$\vartheta = \frac{|1 + x^*|}{|1 - x^*|} = \frac{1 + 0,999997}{1 - 0,999997} = \frac{1,999997}{0,000003} \approx 666666 \approx 7 \cdot 10^5,$$

что и свидетельствует о потере пяти верных знаков. Задача очень плохо обусловлена.

Пример2. Пусть имеем уравнение  $(x - 1)^4 = 0$  с кратным корнем. Если допустить в младшем коэффициенте ошибку, равную  $10^{-8}$ , то она приведет к уравнению  $(x - 1)^4 = 10^{-8}$ . Нетрудно проверить, что это уравнение имеет корни  $x_{1,2} = 1 \pm 10^{-2}$ ,  $x_{3,4} = 1 \pm 10^{-2} \cdot i$ . Ошибка в  $10^{-6}\%$  в младшем коэффициенте привела к погрешности решения в 1%, что показывает о плохой обусловленности задачи.

Пример 3. Пусть  $f(x) = f(x_1, x_2, \dots, x_n)$  – дифференцируемая в области  $G$  функция  $n$  переменных, вычисление которой производится при приближенно заданных значениях аргументов  $x^* = (x_1^*, x_2^*, \dots, x_n^*)$ . Рассмотр-

рим обусловленность задачи вычисления значения дифференцируемой функции  $y = f(x)$ . Из главы 1, § 8, формул (8.2) - (8.7) имеем:

1) для функции многих переменных –

$$\vartheta_{\Delta_t}^* = |f'_{x_i}(x^*)|, \vartheta_{\Delta_t} = |f'_{x_i}(x)|, i = \overline{1, n}, \quad (a)$$

$$(3.4)$$

$$\vartheta_{\delta_i}^* = \frac{|x_i^*| |f'_{x_i}(x^*)|}{|f(x^*)|}, \vartheta_{\delta_i} = \frac{|x_i| |f'_{x_i}(x)|}{|f(x)|}; \quad (b)$$

2) для функции одной переменной –

$$\vartheta_{\Delta}^* = |f'(x^*)|, \vartheta_{\Delta} = |f'(x)|, \quad (a)$$

$$(3.5)$$

$$\vartheta_{\delta}^* = \frac{|x^*| |f'_x(x^*)|}{|f(x^*)|}, \vartheta_{\delta}^* = \frac{|x| |f'_x(x)|}{|f(x)|}. \quad (b)$$

В качестве примера рассмотрим конкретные функции.

1. Рассмотрим функцию  $y = e^x$ . Для этой функции, в силу формулы (3.5 b), относительное число обусловленности  $\vartheta_{\delta}$  приближенно равно  $|x|$  и при реальных вычислениях эта величина не может быть очень большой. Таким образом, задача вычисления этой функции хорошо обусловлена. Например, при  $10 \leq x \leq 10^2$  следует ожидать потери 1–2 верных значащих цифр по сравнению с числом верных цифр аргумента  $x$ . Этот факт связан с погрешностью задания аргумента и не связан с используемым алгоритмом.
2. Если имеем функцию  $y = \sin x$ , то по формуле (3.5 a) имеем  $\vartheta_{\Delta} = |\cos x| \leq 1$ . Это говорит о хорошей абсолютной обусловленности этой задачи при всех  $x$ . Если важен результат с определенным числом верных знаков, то нужно исследовать относительную обусловленность. Согласно формуле (3.5 b) имеем  $\vartheta_{\delta} = |x \operatorname{ctg} x|$ . Отсюда видно, что  $\vartheta_{\delta} \rightarrow \infty$  при  $x \rightarrow \pi k$

( $k = \pm 1, \pm 2, \dots$ ) и при  $x = \pi k$  задача обладает плохой относительной обусловленностью. Если же значение  $|x|$  очень велико, то  $\vartheta_\delta \gg 1$  и вычислять значение синуса просто бессмысленно. При использовании функции  $y = \sin x$  желательно проводить вычисления так, чтобы аргумент находился в диапазоне  $|x| \leq 2$ , где  $\vartheta_\delta \leq 1$ .

Пример 4. Рассмотрим обусловленность задачи вычисления интеграла  $I = \int_a^b f(x) dx$ .

Из (2.5) следует, что абсолютное число обусловленности имеет вид  $\vartheta_\Delta = b - a$ . Рассмотрим относительное число обусловленности. Для это-

го рассмотрим  $\delta(f^*) = \sup_{x \in [a, b]} \frac{|f^*(x) - f(x)|}{|f(x)|}$  для тех  $x$ , где  $f(x) \neq 0$  и используя неравенство:

$$\Delta(I^*) \leq \int_a^b |f^*(x) - f(x)| dx \leq \int_a^b |f(x)| dx \cdot \delta(f^*),$$

получим оценку

$$\delta(I^*) \leq \vartheta_\delta \delta(f^*), \tag{3.6}$$

где

$$\vartheta_\delta = \int_a^b \frac{|f(x)| dx}{\left| \int_a^b f(x) dx \right|}.$$

Если подынтегральная функция знакопостоянна, то  $\vartheta_\delta = 1$  и задача хорошо обусловлена. Если же функция  $f$  на  $[a, b]$  принимает значение разных знаков, то  $\vartheta_\delta > 1$ . Для некоторых сильно колеблющихся около нуля функций может оказаться, что  $\vartheta_\delta \gg 1$  и тогда задача вычисления интеграла является плохо обусловленной.

Пример 5. Рассмотрим задачу вычисления абсолютно сходящегося ряда с ненулевыми слагаемыми. В силу оценки (2.4) эта задача устойчива, а за относительное число обусловленности следует принять величину

$$\vartheta_{\delta} = \sum_{k=0}^{\infty} |a_k| / \left| \sum_{k=0}^{\infty} a_k \right|.$$

Заметим, что для ряда с положительными слагаемыми имеем

$$\vartheta_{\delta} = 1,$$

т.е. задача хорошо обусловлена. Если же ряд знакопостоянный, то  $\vartheta_{\delta} > 1$  и при  $\vartheta_{\delta} \gg 1$  задача оказывается плохо обусловленной.

## § 4. Об алгоритмах вычислительной математики

### 4.1. Общие вопросы

Алгоритмы применялись в математике с древнейших времен для решения самых разнообразных задач математики. Понятие алгоритма развивалось в самой тесной связи с потребностями практики. Оно связано с развитием математики в целом с древнейших времен до сегодняшнего дня. Алгоритм является мощным средством для расширения приложений математики и развития её теоретической части. Понятие алгоритма изменилось с развитием математики в сторону все большей общности и приобретало все более конкретное содержание. Результат применения алгоритма зависит от исходных данных и от всех операций, производящихся согласно правилу, как над исходными, так и над промежуточными данными.

В истории математики были известны многочисленные попытки создания универсального алгоритма. Использование алгоритмов более общего назначения должны были потребовать уточнения понятия алгоритма. Над решением этой проблемы работали математики в различных направлениях, используя при этом различные подходы. Результатом этой работы явилось введение в математику понятий нормального алгоритма (А. А. Марков), функциональной схемы машины Тьюринга (А. Тьюринг) и рекурсивной функции, которые оказались равносильны-

ми по своему содержанию и явились уточнением понятия алгоритма. Математики убедились, опираясь на уточненное понятие алгоритма, что построение универсального алгоритма возможно не для всякого класса задач. В этом случае речь может идти о создании алгоритмов для решения отдельных задач данного класса. Если признать существование такого универсального алгоритма, решающего любую задачу единообразно, то это означало бы существование универсальной абсолютной истины, исчерпывающее математическое познание мира, что невозможно. Это обстоятельство заставляет математиков более конкретно подходить к решению задач с учетом особенностей решаемых задач.

В связи с парадоксами в теории множеств возникали различные направления в математике, отрицавшие неоправданно широкое применение теоретико-множественного подхода. Конструктивисты считали, что в понятие функции необходимо включить требование потенциальной осуществимости, "конструктивности", т. е. должны быть описаны отчётливые правила (алгоритмы), позволяющие по заданному  $x$  отыскивать нужное  $y$ .

Рекурсивная функция является одним из наиболее распространенных вариантов математического уточнения понятия вычислимой арифметической функции [7] (аргументы и значения – натуральные числа).

Рекурсивная функция, определенная при любых значениях аргумента называется общерекурсивной функцией, а если она определена не во всех значениях аргумента, то она называется частично рекурсивной функцией.

Соглашение, согласно, которому, если для любого алгоритма  $A$  в каком-либо алфавите может быть построен тьюринговский алгоритм [9], дающий при одинаковых входных данных те же самые результаты, называется в теории алгоритмов тезисом Тьюринга. Тезис Тьюринга равносителен тезису Чёрча [14] для частично рекурсивных функций или принципа нормализации А. А. Маркова-младшего [8]. Согласно тезису Чёрча класс функций, вычисляемых с помощью алгоритмов в широком

интуитивном смысле, совпадает с классом частично рекурсивных функций. Все используемые в математике алгоритмы удовлетворяют тезису Чёрча. Были попытки опровергнуть тезиса Чёрча, однако они к успеху не привели. Следует отметить, что тезис Чёрча не может быть строго математически доказан, так как в его формулировке участвует неточное понятие "алгоритма в интуитивном смысле". Исследования специалистов показали, что все известные уточнения общего понятия алгоритма взаимно моделируют друг друга и ведут к одному и тому же понятию вычислимой функции [5], совпадающему с понятием рекурсивной функции [7], что подтверждает общезначимость тезиса Чёрча. Поэтому принятие тезиса Чёрча полезно в теории алгоритмов и многочисленных её приложениях. В частности, при доказательстве существования тех или иных конкретных алгоритмов можно, опираясь на тезисы Чёрча, интуитивно понятными построениями и не выписывать соответствующие формальные схемы.

Алгоритмическая проблема [1] – проблема нахождения единого метода (алгоритма) для решения бесконечной серии однотипных конкретных задач. Эта проблема решалась в различных областях математики на протяжении всей ее истории. Некоторые из них не поддавались решению. Только в 30-х годах XX века выработано решение этого вопроса после того, как в математической логике было установлено точное определение понятия алгоритма. Выяснилось, что алгоритмические проблемы могут быть неразрешимыми (не существовать). Теперь алгоритмические проблемы стали формулировать как проблемы решения вопроса о существовании алгоритма для решения данной бесконечной серии однотипных задач и нахождения такого алгоритма в случае, если он существует. После того, как строго доказано, что эта проблема не может быть решена в рамках того или иного уточнения понятия алгоритма, тезис Чёрча является основанием для вывода о неразрешимости данной алгоритмической проблемы.



Алгоритм выражает некоторый общий закон, связывающий отдельные операции, блоки в единую схему действий. Вся структура алгоритма не оставляет места субъективному произволу при его применении, ибо вычисления, производимые согласно данному алгоритму, не зависят от произвола вычисляющего лица и таким же успехом могут быть повторены сколько угодно раз с теми же результатами. В теории алгоритмов полностью исключается произвол субъекта. Понятие алгоритма занимает одно из центральных мест в современной математике, прежде всего вычислительной.

В любой решаемой задаче должна быть известна исходная ситуация и указана, какая цель ставится. Для перехода от исходной ситуации к желаемой цели составляют алгоритм решения задачи.

С современной точки зрения алгоритм – это строгая и чёткая (конечная) система правил, которая определяет последовательность действий над некоторыми объектами и после конечного числа шагов приводит к достижению поставленной цели. Алгоритмы, в соответствии с которыми решение поставленных задач сводится к арифметическим действиям, называются численными алгоритмами. Алгоритмы, в соответствии с которыми решение поставленных задач сводится к логическим действиям, называются логическими алгоритмами. Реально решаемые на ЭВМ задачи содержат как арифметические, так и логические действия и являются смешанными алгоритмами.

Создание любого алгоритма проходит в три стадии. На первой стадии разрабатывают алгоритм. На второй стадии доказывают, что он действительно "работает", т. е. решает поставленную задачу. На третьей стадии математик описывает свой алгоритм так, чтобы его мог выполнить любой другой человек.

Выделяют три крупных класса алгоритмов.

1. Вычислительные алгоритмы, работающие со сравнительно простыми видами данных, такими как числа, матрицы и т. д., хотя сам процесс

вычисления может быть долгим и сложным (алгоритмы вычислительной математики).

2. Информационные алгоритмы, представляющие набор сравнительно простых процедур, работающих с большими объёмами информации (алгоритмы баз данных, алгоритмы информатики).

3. Управляющие алгоритмы, генерирующие различные управляющие воздействия на основе данных, полученных от внешних процессов, которыми алгоритм управляет (алгоритмы кибернетики).

Под вычислительными (численными) методами подразумеваются приближенные процедуры, позволяющие получить решение вычислительной задачи в виде конкретных числовых значений. Вычислительные методы, как правило, реализуются на ЭВМ. Вычислительный метод, доведенный до степени детализации, позволяющий реализовать его на ЭВМ, принимает форму вычислительного алгоритма.

Вычислительный алгоритм – точное предписание действий над входными данными, задающее вычислительный процесс, направленный на преобразование произвольных данных  $x$  из множества допустимых для данного алгоритма входных данных  $X$  в полностью определяемый этими входными данными результат  $y \in Y$ .

#### 4.2. Корректность вычислительного алгоритма

Вычислительный алгоритм называют корректным, если выполнены следующие условия:

1) он позволяет после выполнения конечного числа элементарных для вычислительной машины операций преобразовать любое входное данное  $x \in X$  в результат  $y \in Y$ ;

2) результат  $y$  устойчив по отношению к малым возмущениям входных данных  $x$ ;

3) результат  $y$  обладает вычислительной устойчивостью. Если хотя бы одно из этих условий не выполнено, то вычислительный алгоритм считается некорректным.

Алгоритм называют вычислительно устойчивым, если вычислительная погрешность стремится к нулю при  $\varepsilon_\mu \rightarrow 0$ , где  $\varepsilon_\mu$  – машинная точность. Обычно вычислительный алгоритм называют устойчивым, если он устойчив по входным данным и вычислительно устойчив, и неустойчивым, если хотя бы одно из этих условий не выполнено.

Если для получения результата требуется выполнить бесконечное число операций или нереализуемые на ЭВМ операции, то алгоритм следует признать некорректным. Например: в итерационных процессах не указан критерий окончания итераций; алгоритмы, допускающие деление на нуль; извлечения квадратного корня из отрицательного числа, являются некорректными.

Устойчивость алгоритма по входным данным означает, что результат непрерывным образом зависит от входных данных при отсутствии вычислительной погрешности. Отсутствие такой устойчивости делает алгоритм непригодным для использования на практике. Следует отметить, что в это определение устойчивости по входным данным, вместе со входными данными  $x \in X$ , входят и все близкие к  $x$  приближенные входные данные  $x^*$ .

Если в процессе вычислений ошибки округления неограниченно нарастают, то такой алгоритм называют вычислительно неустойчивым. Если ошибки округления не накапливаются, то алгоритм является вычислительно устойчивым.

По устойчивости алгоритмы классифицируются на:

- абсолютно устойчивые;
- условно устойчивые;
- абсолютно не устойчивые;

Алгоритмы являются абсолютно устойчивыми, если на параметры задачи не налагаются ни какие ограничения. Алгоритм является условно устойчивым, если на параметры задачи налагаются некоторые ограничения (условия). Алгоритм является абсолютно неустойчивым, если имеет место неустойчивость при любых значениях параметров задачи.

В вычислительной математике одно из центральных мест занимает понятие реального вычислительного алгоритма. Реальный вычислительный алгоритм складывается из двух частей:

1) абстрактного (или собственно) вычислительного алгоритма, который не связан с конкретной ЭВМ и записывается в общепринятых математических терминах или на каком – либо алгоритмическом языке. Под алгоритмическим языком понимают формальный язык программирования, предназначенный для описания вычислительных процессов или записи алгоритмов, подлежащих выполнению на ЭВМ;

2) программы, которые организуют реализацию вычислительного процесса в конкретной ЭВМ. Реальный вычислительный алгоритм перерабатывает числовую и символьную информацию и, как правило, это происходит с потерей информации и точности.

В реальных вычислениях потеря точности происходит в результате влияния различных погрешностей в процессе вычислений. Источники появления погрешностей в задачах теоретической и прикладной математики различны. В задачах теоретической математики входные данные задаются точно без погрешностей. Основными источниками появления погрешностей будут погрешности метода и округления чисел в процессе решения задачи. В задаче прикладной математики кроме погрешности метода и округления появляются погрешности входных данных и математической модели. Погрешность входных данных появляется вследствие ошибок наблюдения, измерения и т. д. и может включать в себе погрешность округления входных данных. Задача прикладной математики является продуктом отражения реального объекта в математической модели, которое всегда является гомоморфным, так как матема-

тические модели отражают действительность в упрощенной форме. Возникшая при этом погрешность – погрешность математической модели – уже не может быть устранена в процессе последующих вычислений.

Рассмотрим примеры.

Пример 1. Необходимо вычислить корни уравнения

$$x^2 + px + q = 0$$

с коэффициентами, удовлетворяющими условию  $d = p^2 - 4q \geq 0$ . Если для вычисления корней уравнения используются формулы

$$x_1 = \frac{(-p + \sqrt{p^2 - 4q})}{2}, \quad x_2 = \frac{(-p - \sqrt{p^2 - 4q})}{2},$$

то этот алгоритм некорректен. Так как, значение  $d^*$ , отвечающее приближенно заданным коэффициентам  $p^*$  и  $q^*$ , может оказаться отрицательным,  $d \approx 0$ . Тогда вычисления завершатся аварийным остановом при попытке извлечь квадратный корень из отрицательного числа. Алгоритм становится корректным, если  $d$  заменить на  $\max\{d, 0\}$ .

Вычислительные погрешности появляются:

при вводе входных данных в ЭВМ; при выполнении арифметических операций для фиксированного алгоритма в основном величина погрешности определяется машинной точностью  $\varepsilon_\mu$ .

Пример 2. Пусть величины  $y_i$ ,  $i = 1, 2, \dots$  вычисляются по рекуррентной формуле

$$y_i = \alpha_i y_{i-1} + \beta_i, \tag{4.1}$$

а величина  $y_0$  задана. Пусть  $y_0^*$  - заданное приближенное значение величины  $y_0$ . Тогда определенные по формуле (4.1) приближенные значения содержат погрешности, связанные равенством  $y_i - y_i^* = \alpha_i (y_{i-1} - y_{i-1}^*)$ , при условии, если вычисления ведутся абсолютно точно. Отсюда  $\Delta(y_i^*) = |\alpha_i| \Delta(y_{i-1}^*)$  и при выполнении условия

$|\alpha_i| \leq 1$  алгоритм устойчив по входным данным, поскольку  $\Delta(y_i^*) \leq \Delta(y_0^*)$  для всех  $i$ . Если же  $|\alpha_i| \geq q > 1$ , то  $\Delta(y_i^*) \geq q^i \Delta(y_0^*)$  и абсолютная погрешность неограниченно возрастает при  $i \rightarrow \infty$ . В этом случае алгоритм неустойчив по входным данным, а потому и вычислительно неустойчив. Алгоритм (4.1) признан неустойчивым в случае  $|\alpha_i| \geq q > 1$  в предположении о неограниченной продолжительности вычислительного процесса ( $i \rightarrow \infty$ ), что невозможно на практике. Если погрешности растут очень быстро, то вычисления довольно скоро завершатся аварийным остановом. Устойчивость зависит и от выбранной меры погрешности. Вместо абсолютной погрешности можно было рассмотреть относительную погрешность. Если точное решение возрастает быстро и при этом относительная погрешность остается малой, то алгоритм можно признать относительно устойчивым. При анализе вычислительной устойчивости более естественным является рассмотрение относительных погрешностей.

Пример 3. Пусть в формуле (4.1) все  $\beta_i = 0$ ,  $\alpha_i \neq 0$ . Тогда

$$\delta(y_i^*) = \frac{\Delta(y_i^*)}{|y_i|} = \frac{|\alpha_i| \Delta(y_{i-1}^*)}{|\alpha_i y_{i-1}|} = \delta(y_{i-1}^*)$$

Следовательно,  $\delta(y_i^*) = \delta(y_0^*)$  и при любых значениях  $\alpha_i \neq 0$  алгоритм относительно устойчив по входным данным.

Неустойчивость обычно связывают со свойством экспоненциального нарастания ошибки округления. Если же ошибка округления нарастает по степенному закону при переходе с одной операции к другой ("от шага к шагу"), то алгоритм считают условно устойчивым (условным при некоторых ограничениях на объем вычислений и требуемую точность).

Если ошибка округления  $\varepsilon_0$  нарастает от шага к шагу по экспоненциальному закону, то это приводит, как правило, к авосту на промежуточном этапе вычислений.

Таким образом, устойчивость вычислительного алгоритма определяется как свойство вычислительного алгоритма, позволяющее судить о скорости накопления суммарной вычислительной погрешности. Устойчивость является внутренним свойством абстрактного вычислительного алгоритма. Таким образом, устойчивость вычислительного алгоритма означает чувствительность решения задачи по отношению к суммарной вычислительной погрешности (погрешности округления) входных данных. Чем лучше свойства устойчивости, тем меньше, при заданном абстрактном вычислительном алгоритме, результаты вычислений зависят от выбора ЭВМ и эквивалентных преобразований абстрактного вычислительного алгоритма. Определение устойчивости абстрактного вычислительного алгоритма можно вводить различными способами, но сущность определений одна – непрерывная зависимость решения от входных данных, равномерная относительно параметров задачи.

Укажем еще на одно требование, предъявляемое к вычислительным алгоритмам – отсутствие аварийного останова (авоста) ЭВМ в процессе вычислений. Следует иметь в виду, что ЭВМ оперирует с числами, имеющими конечное число значащих цифр и принадлежащими (по модулю) не всей числовой оси, а некоторому интервалу,  $(M_0, M_\infty)$ ,  $M_0 > 0$ ,  $M_\infty < \infty$ , где  $M_0$  – машинный ноль,  $M_\infty$  – машинная бесконечность. Если условие  $|M| < \infty$  в процессе вычислений нарушается, то происходит аварийный останов ЭВМ вследствие переполнения разрядной сетки, и вычисления прекращаются. Возможность авоста зависит от алгоритма и от исходной задачи. Часто возможность авоста может быть устранена путем изменения порядка действий. Если решение исходной задачи выражается через очень большие (очень малые) числа  $|M| > M_\infty$  ( $|M| < M_0$ ), то путем изменения масштаба можно привести задачу к виду, содержащему только величины  $|M| \in (M_0, M_\infty)$ .

Пример 4. Пусть  $M_\infty = 10^p$ ,  $M_0 = 10^{-p}$ ,  $p = 2^n$ ,  $n$ -целое число. Требуется вычислить произведение чисел  $10^{\frac{p}{2}}, 10^{\frac{p}{4}}, 10^{-\frac{p}{2}}, 10^{\frac{3p}{4}}, 10^{-\frac{3p}{2}}$

Способ 1. Пронумеруем числа в порядке убывания

$$q_1 = 10^{\frac{3p}{4}}, q_2 = 10^{\frac{p}{2}}, q_3 = 10^{\frac{p}{4}}, q_4 = 10^{-\frac{p}{2}}, q_5 = 10^{-\frac{3p}{4}}$$

и образуем произведение  $S_{k+1} = S_k \cdot q_{k+1}$ ,  $S_1 = q_1$ .

Тогда уже на первом шаге получим авост, так как

$$S_2 = q_1 \cdot q_2 = 10^{\frac{5p}{4}} \rightarrow M_\infty$$

Способ 2. Пронумеруем числа в порядке возрастания

$$q_1 = 10^{-\frac{3p}{4}}, q_2 = 10^{-\frac{p}{2}}, q_3 = 10^{\frac{p}{4}}, q_4 = 10^{\frac{p}{2}}, q_5 = 10^{\frac{3p}{4}}$$

В этом случае получим на первом шаге

$S_2 = q_1 \cdot q_2 = 10^{-\frac{5p}{4}} < M_0$ , т. е.  $S_2$  – машинный нуль. Нулю будут равны и все последующие произведения  $S_3, S_4, S_5$ . Таким образом, в этом случае происходит полная потеря точности.

Способ 3. Перемешаем числа

$$q_1 = 10^{-\frac{3p}{4}}, q_2 = 10^{\frac{p}{2}}, q_3 = 10^{\frac{3p}{4}}, q_4 = 10^{-\frac{p}{2}}, q_5 = 10^{\frac{p}{4}}$$

Тогда получим последовательно

$$S_2 = q_1 \cdot q_2 = 10^{-\frac{p}{4}}, S_3 = q_2 \cdot q_3 = 10^{\frac{p}{4}},$$

$$S_4 = S_3 q_4 = 10^0, S_5 = S_4 \cdot q_5 = 10^{\frac{p}{4}}.$$

Такой алгоритм называется без авостным.

Пример 5. Пусть требуется найти  $y_i$  по формуле  $y_{i+1} = y_i + d$  ( $i \geq 0$ ) при заданных  $y_0$  и  $d$ . Предположим, что при вычислении  $y_i$  внесена погрешность  $\delta_i$ , т. е. вместо точного  $y_1$  получим  $\widetilde{y}_1 = y_0 + d + \delta_1$ .

Тогда, вместо  $y_2$  получим  $\widetilde{y}_2 = \widetilde{y}_1 + d + \delta_2 = y_2 + \delta_1 + \delta_2$ . Для  $y_i$  имеем

$$\widetilde{y}_i = \widetilde{y}_{i-1} + \delta_i = y_i + \delta_1 + \delta_2 + \dots + \delta_i = y_i + \sum_{k=1}^i \delta_k \leq y_i + i \cdot \delta_m,$$



где  $\delta_m$  – максимальная ошибка округления.

В данном случае идет очень медленное накопление ошибок округления.

Пример 6. Рассмотрим соотношение  $y_{i+1} = q \cdot y_i$  ( $i \geq 0$ ,  $y_0$  и  $d$  заданы).

Пусть вместо  $y_1 = q \cdot y_0$  получено приближенное значение  $\widetilde{y}_1 = y_1 + \delta$ .

Тогда даже если дальнейшие вычисления будут точными, мы получим

$$\widetilde{y}_2 = q \cdot (y_1 + \delta) = y_2 + q\delta, \widetilde{y}_3 = q \cdot (y_2 + q \cdot \delta) =$$

$$y_3 + q^2\delta, \dots, \widetilde{y}_{i+1} = y_{i+1} + q^i\delta.$$

Отсюда следует  $\delta_{i+1} = q^i\delta$ ,  $i = 0, 1, \dots$ . Если  $|q| > 1$ , то в процессе вычисления погрешность будет быстро возрастать (алгоритм неустойчив).

Если  $|q| < 1$ , то погрешность не возрастает (алгоритм устойчив).

Если  $M_\infty = 10^p$ ,  $\delta = 10^{-4}$  то при некотором  $i = i_0$ , удовлетворяющем

неравенству  $|q|^i \cdot \delta \geq M_\infty$  наступает авост. Отсюда  $i_0 = \frac{(p+k)}{\lg(|q|)}$ .

Таким образом, вычисления необходимо закончить пока  $i < \frac{(p+k)}{\lg(|q|)}$ .

Пусть в процессе вычислений погрешность растет по степенному закону

$|\delta_i| = i^n \cdot \delta$  ( $n \geq 1$ ). Тогда авост наступит при  $i^n \cdot \delta \geq M_\infty$ , т. е.

$$i_0 \geq \left(\frac{M_\infty}{\delta}\right)^{\frac{1}{n}} = 10^{\frac{p+k}{n}}.$$

Отсюда видно, что при  $n = 1$  авоста не будет, так как для этого надо, чтобы  $i_0$  удовлетворяло неравенству  $i_0 \geq 10^{(p+k)}$ , что на практике не выполняется.

Пусть задана точность  $\delta_0 = 10^{-k_0}$  и мы хотим обеспечить

$|\delta_i| = i^n \cdot \delta < \delta_0$ , тогда  $i \leq i_0 = \left(\frac{\delta_0}{\delta}\right)^{\frac{1}{n}} = 10^{\frac{k-k_0}{n}}$ . Последнее неравенство

определяет ограничение на число шагов  $i \leq i_0$ . Так при

$k = 12, k_0 = 6$  имеем  $i_0 = 10^{\frac{6}{n}}$  при  $n = 1$  получим  $i < 10^6$ , а при  $n = 2$ ,  $i \leq 10^3$ . При уменьшении  $n$  число допустимых шагов  $i_0$  будет уменьшаться. На практике  $n$  обычно не велико.

Одной из важных характеристик абстрактного вычислительного алгоритма является экономичность. Вопрос об экономичности вычислительного алгоритма особо важно в решении больших и сложных математических задач. В реальных вычислениях наибольший интерес представляют те вычислительные алгоритмы, которые допускают наименьшее количество арифметических операций  $Q(\varepsilon)$  для получения решения заданной точности  $\varepsilon$ . Одним из основных критериев оптимальности в реальном вычислительном алгоритме является требование минимума арифметических операций. Для любой задачи можно предложить много алгоритмов, дающих одинаковую по порядку

(при  $\varepsilon \rightarrow 0$ ) точность  $\varepsilon > 0$ , но за разное число действий  $Q(\varepsilon)$ .

Среди таких, как говорят, эквивалентных по порядку точности алгоритмов надо выбирать тот, который дает решение задачи с затратой наименьшего машинного времени (число действий  $Q(\varepsilon)$ ). Такие алгоритм называют экономичными. К рассмотренному выше вопросу тесно примыкают проблемы минимизации вычислительной работы и оптимизации вычислительного алгоритма. В случае, когда исследование проблемы оптимизации вычислительного алгоритма имеет своей целью решение задач на ЭВМ, должны учитываться вычислительная устойчивость алгоритма и объем разных видов используемой памяти.

В реальных вычислительных алгоритмах немаловажное значение имеет требование универсальности. Вычислительные алгоритмы должны быть ориентированы для решения широкого класса задач. В качестве примера можно указать на метод конечных разностей. Этим методом решаются многие математические задачи: обыкновенные дифференциальные уравнения; уравнения с частными производными; интегральные

уравнения; интегро-дифференциальные уравнения и т. д. В этом случае метод конечных разностей является одним из универсальных методов решения широкого класса математических задач.

Другим требованием, предъявляемым к вычислительным алгоритмам, является требование реализуемости, т. е. давать решение задачи за доступное машинное время. Для большинства алгоритмов время решения задачи (объем вычислений  $Q(\epsilon)$ ) возрастает при повышении точности вычислений, т. е. при уменьшении  $\epsilon$ . Можно задать  $\epsilon$  настолько малым, что время решения задачи станет недопустимо большим. Существенно знать, что алгоритм дает принципиальную возможность получить решение с любой заданной точностью. На практике  $\epsilon$  выбирают, учитывая возможность реализуемости алгоритма на данной ЭВМ. Для каждой задачи, алгоритма и ЭВМ есть свое характерное значение  $\epsilon$ .

К вычислительному алгоритму наряду с обычными требованиями, которые нами рассмотрены выше, еще предъявляют требования параллелизуемости, т. е. возможность распараллеливания вычислительного алгоритма. Численные методы параллельных вычислений базируются на параллельных концепциях вычислительных машин. Эволюционный путь развития ЭВМ последовательного действия привел к созданию параллельных вычислительных систем, оказывающих все большее влияние на развитие вычислительных методов, которое повлекло за собой развития параллельной вычислительной математики, призванной максимально использовать возможность и преимущества принципа параллельного выполнения операций.

### **4.3. Обусловленность вычислительного алгоритма**

Обусловленность вычислительного алгоритма отражает чувствительность результата работы алгоритма к малым, но неизбежным ошибкам округления.

Вычислительно устойчивый алгоритм называют хорошо обусловленным, если малые относительные погрешности округления, характеризуемое числом  $\varepsilon_M$ , приводит к малой относительной погрешности  $\delta(y^*)$  результата  $y^*$ , и плохо обусловленным, если вычислительная погрешность может быть недопустимо большой.

Если  $\delta(y^*)$  и  $\varepsilon_M$  (машинная точность) связаны неравенством  $\delta(y^*) \leq \vartheta_A \cdot \varepsilon_M$ , то число  $\vartheta_A$  называется числом обусловленности вычислительного алгоритма. Для плохо обусловленного алгоритма  $\vartheta_A \gg 1$ . При очень большом  $\vartheta_A$  алгоритм можно считать практически неустойчивым. Поэтому существенным требованием к вычислительным алгоритмам является требование хорошей обусловленности. В процессе решения задачи на ЭВМ постоянно идет процесс округления чисел. Независимо от количества разрядности ЭВМ выполнение большого объема вычислений приведет к накоплению погрешности, способной значительно или даже полностью исказить вычисляемый результат. Эта ситуация может иметь места и при небольшом объеме вычислений, если алгоритм слишком чувствителен к ошибкам округления.

Конкретные вычислительные алгоритмы решения одной и той же задачи отличаются друг от друга порядком выполнения операций. Если вычисления производятся точно (как в абстрактной математике), то при любом способе вычислений, будут приводить к одному результату. Вычисления на ЭВМ таким свойством не обладает, поэтому результаты каждый раз будут разными. В некоторых ситуациях неудачно выбранной порядок выполнения операций приводит либо к полной потере точности, либо к авосту.

Иногда от исходных данных, заданных высокой точностью, после незначительного объема вычислений, получаются результаты, содержащие мало верных цифр или ни одной верной цифры. В этом случае говорят о катастрофической потере точности.

Если алгоритм, предназначенный для решения хорошо обусловленной задачи, оказался плохо обусловленным, то его следует признать неудовлетворительным и попытаться построить более качественный алгоритм. Для плохо обусловленной задачи дело обстоит иначе. Здесь требуется серьезное переосмысления постановки вычислительной задачи.

Пример 7. Пусть на ЭВМ типа IBM PC требуется вычислить произведение  $U = a_0 \cdot a_1 \cdot \dots \cdot a_{50}$ , где  $a_i = 10^{25-i}$ . Если производить вычисления в естественном порядке, то уже  $a_0 \cdot a_1 = 10^{49}$  даст аварийный останов ЭВМ. Вычисления произведения в обратном порядке сразу же даст исчезновение порядка, так как  $a_{50} \cdot a_{49} = 10^{-49}$ . В результате  $a_{50} \cdot a_{49} = 0$ . Окончательный результат  $U = 0$ . В данном случае можно произвести умножение в следующем порядке:

$$U = a_0 \cdot a_{50} \cdot a_{49} \cdot \dots \cdot a_{24} \cdot a_{26} \cdot a_{25},$$

исключающий возможность переполнения или антипереполнения.

Пример 8. Функция может быть представлена в виде сходящегося степенного ряда

$$e^x = \sum_{k=0}^{\infty} \frac{x^k}{k!} = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \dots + \frac{x^k}{k!} + \dots \quad (4.2)$$

Пусть для вычислений используется 6-разрядная десятичная ЭВМ. Возьмем  $x = -8.1$  и проведем вычисления значения частичных сумм до тех пор, пока добавление очередного слагаемого еще меняет значение суммы, получим  $e^{-8.1} \approx 0,000649915$ . Сравнение с истинным значением  $e^{-8.1} = 0,000303539$  показывает, что найденное значение не содержит ни одной верной цифры. В этом случае переход к вычислениям с удвоенной длиной мантиссы позволит получить  $e^{-8.1}$  с шестью верными значащими цифрами. Заметим, что на ЭВМ элементарные функции вычисляются по другому алгоритму.

Пример 9. Пусть при  $x = \frac{1}{490}$  на 6-разрядной ЭВМ вычисляется значение функции

$$y = \cos x - \cos 2x \quad (4.3)$$

При  $x \approx 0$  величины  $C_1 = \cos x \approx 1 - \frac{x^2}{2}$  и  $C_2 = \cos 2x \approx 1 - 2x^2$  близки.

Приближенные значения  $C_1^*$  и  $C_2^*$  будут содержать погрешности, то возможна серьезная потеря точности. Действительно,  $C_1^* = 0,999998$ ,  $C_2^* = 0,999992$  и  $y^* = C_1^* - C_2^* = 0,000006$ . При вычитании старшие разряды оказались потерянными и в результате осталась только одна значащая цифра.

Вычисление по эквивалентной формуле  $y = 2 \sin \frac{x}{2} \cdot \sin \frac{3x}{2}$  даст значение  $y^* = 0,624741 \cdot 10^{-5}$  с шестью верными знаками.

Интересно отметить, что вычисление по функции  $y \approx 1,5x^2$  даёт 6 верных значащих цифр.

Вернемся к примеру № 8. Задача вычисления функции  $e^x$  хорошо обусловлена. Почему произошла катастрофическая потеря точности при вычислении значения  $e^{-8.1}$  прямым суммированием ряда (4.2)?

Рассмотрим задачу суммирования ряда

$$\sum_{k=0}^{\infty} a_k$$

со слагаемыми  $a_k = \frac{x^k}{k!}$ . каждая из этих слагаемых вычисляется с относительной погрешностью  $\vartheta(a_k^*) \geq \varepsilon_M$ . При  $x < 0$  формула

$$\vartheta_\delta = \frac{\sum_{k=0}^{\infty} |a_k|}{|\sum_{k=0}^{\infty} a_k|} \quad (4.4)$$

с учетом разложения (4.2) даёт значение

$$\vartheta_{\delta} = \frac{\sum_{k=0}^{\infty} \frac{|x|^k}{k!}}{\left| \sum_{k=0}^{\infty} \frac{|x|^k}{k!} \right|} = e^{2|x|}$$

Рост модуля  $x$  (для  $x < 0$ ) приводит к резкому ухудшению обусловленности вычислений. Для  $x = -8,1$ , как в примере № 8, имеем  $\vartheta_{\delta} = e^{16.2} \approx 10^7$ . Поэтому не удивительна полная потеря точности при вычислениях на 6-разрядной ЭВМ.

Рассмотрим теперь обусловленность алгоритма прямого вычисления по формуле (4.3). Если величина  $x$  не слишком мала

( $2x^2 \geq \varepsilon_M$ ), то значения  $C_1^* \approx 1 - \frac{x^2}{2}$  и  $C_2^* \approx 1 - 2x^2$  будут содержать по-

грешности порядка  $\varepsilon_M$ . Поэтому  $\bar{\Delta}(y^*) \approx 2\varepsilon_M$ . Учитывая, что

$y = 1,5x^2$ , найдем оценку границы относительной погрешности

$\bar{\delta}(y^*) \approx x^{-2}\varepsilon_M$ . Число обусловленности  $\vartheta \approx x^{-2}$  растет с уменьшением  $|x|$ . В случае, когда  $2x^2 \leq \varepsilon_M$  в результате вычислений будут получены значения

$$C_1^* = 1, C_2^* = 1 \text{ и } y^* = C_1^* - C_2^* = 0.$$

Здесь  $\delta(y^*) = \frac{|y-y^*|}{|y|} = 1$  и происходит полная потеря точности.

В рассмотренных выше примерах удалось построить более качественный алгоритм. Для плохо обусловленной задачи дело обстоит иначе. Здесь требуется серьезное переосмысление постановки вычислительной задачи.

## Литература

1. Алгоритмическая проблема // Матем. энцикл. Словарь. Гл. ред. Ю. В. Прохоров. – М.: Советская энциклопедия, 1988. – С. 134-135.

- 2.Амосов А. А., Дубинский Ю. А., Копченова Н. В. Вычислительные методы для инженеров. Учебное пособие. М.: Высшая школа, 1994. – 544 с.
- 3.Арушанян О. Б., Залёткин С. Ф. Численное решение обыкновенных дифференциальных уравнений на фартране. – М.: Изд-во МГУ, 1990. – 336 с.
4. Бахвалов Н. С., Жидков Н. П., Кобельков Г. М. Численные методы. – М.: Бином. Лаборатория знаний, 2003. – 632 с.
- 5.Вычислимая функция. // Матем. энцикл. словарь. Гл. ред. Ю. В. Прохоров. – М.: Советская энциклопедия, 1988. – с 132.
- 6.Каханер Д., Моулер К., Нэш С. Численные методы и программное обеспечение Пер. с англ. – изд. второе, стереотип. – М.: Мир, 2001. – 575 с.
- 7.Нагорный Н. М. Рекурсивная функция // Матем. энцикл. словарь. Гл. ред. Ю.В. Прохоров – М.: Советская энциклопедия, 1988. – с. 525-526.
- 8.Нагорный Н. М. Нормальный алгоритм // Матем. энцикл. словарь. Гл. ред. Ю. В. Прохоров – М.: Советская энциклопедия, 1988. – с 418.
- 9.Нагорный Н. М., Марченков С. С. Тьюринга машина // Матем. энцикл. словарь. Гл. ред. Ю. В. Прохоров – М.: Советская энциклопедия, 1988. – с 630.
- 10.Охлопков Н. М., Охлопков Г. Н. Введение в специальность "Прикладная математика". Часть 1. Учебное пособие. Якутск: Изд-во ЯГУ, 1977. – 93 с.
- 11.Охлопков Н. М., Охлопков Г. Н. Вычислительные алгоритмы решения некоторых задач алгебры. Якутск: Изд-во ЯГУ, 1996. – 41с
- 12.Охлопков Н. М. Численные методы и вычислительные алгоритмы. Часть 3. Якутск: Изд-во ЯГУ, 1996. – 116 с.
- 13.Тихонов А. Н., Костомарев Д. П. Вводные лекции по прикладной математике. – М.: ФМЛ, 1984. – 192 с.
14. Чёрча тезис // Матем. энцикл. словарь. Гл. ред. Ю. В. Прохоров – М.: Советская энциклопедия, 1988. – С. 630.



## Глава 4. ОБУСЛОВЛЕННОСТЬ ВЫЧИСЛИТЕЛЬНОЙ ЗАДАЧИ

### § 1. Обусловленность задачи решения системы линейных алгебраических уравнений

Пусть имеем систему линейных алгебраических уравнений

$$Ax = b, \quad (1.1)$$

где  $A = (a_{ij})$  – квадратная матрица коэффициентов при неизвестных.

Система (1.1) имеет единственное решение, если определитель системы  $\det(A)$  отличен от нуля, т.е. матрица  $A$  системы (1.1) является невырожденной. Если  $\det(A) = 0$ , то в этом случае матрица  $A$  является вырожденной: система либо не имеет решения (при  $b \neq 0$ ), либо имеет неединственное решение (при  $b = 0$ ). В практических вычислениях существуют “почти невырожденные системы” – системы, определитель которых близок к нулю, но отличен от нуля (рис. 1б). Небольшие изменения коэффициентов матрицы системы или правых частей системы в “почти невырожденных системах” могут привести к большим погрешностям решения. Иллюстрируем эти случаи для системы

$$\begin{cases} a_{11}x_1 + a_{12}x_2 = b_1 \\ a_{21}x_1 + a_{22}x_2 = b_2. \end{cases}$$

Каждому уравнению соответствует прямая на плоскости  $x_1x_2$ , а точка пересечения этих прямых есть решение системы (1.1) (рис. 1).

Если  $\det(A) = 0$ , то наклоны прямых равны и они либо параллельны, либо совпадают (рис. 1в). При  $\det(A) \approx 0$  небольшие погрешности в коэффициентах и правых частях могут привести к большим погрешностям в решении, т.е. к неточному определению положения точки пересечения. Системы такого типа называются плохо обусловленными (рис. 1б).

Плохо обусловленная система геометрически соответствует почти параллельным прямым. Случай а) из рисунка 1 соответствует случаю хорошей обусловленности системы.




Рис 1.

### 1.1. Нормы векторов и матриц

Пусть имеем систему линейных алгебраических уравнений  
 $Ax = \beta.$  (1.1)

Матрица  $A$  – невырожденная, т.е.  $\det(A) \neq 0$ . В этом случае решение задачи (1.1) существует, единственно и устойчиво по входным данным, т.е. задача корректна.

Пусть  $x^* = (x_1^*, x_2^*, \dots, x_n^*)$  – приближенное решение задачи (1.1).

Вектор  $x = (x_1, x_2, \dots, x_n)^T$  – решение системы (1.1),  $x \in R^n$ . Приближенное решение  $x^* = (x_1^*, x_2^*, \dots, x_n^*)$  и погрешность  $x - x^* = (x_1 - x_1^*, x_2 - x_2^*, \dots, x_n - x_n^*)$  также являются элементом пространства  $R^n$ .

Для анализа метода решения системы (1.1) требуется количественно оценивать «величины» векторов  $x^*$  и  $x - x^*$ , а также векторов  $b$  и  $b - b^*$ , где  $b^* = (b_1^*, b_2^*, \dots, b_n^*)$  – вектор приближенного задания правых частей. С этой целью вводят понятие нормы вектора.

Определение. Говорят, что в  $R^n$  задана норма вектора  $x$ , если каждому вектору  $x$  из  $R^n$  сопоставлено вещественное число  $\|x\|$ , называемое нормой вектора  $x$  и обладающее следующими свойствами:

- 1)  $\|x\| \geq 0$ , причем  $\|x\| = 0$ , при  $x = 0$ ;
- 2)  $\|\alpha x\| = |\alpha| \|x\|$ ,  $\alpha$  – вещественное число;
- 3)  $\|x + y\| \leq \|x\| + \|y\|$ ,  $x, y \in R^n$ .

В вычислительной практике наиболее употребительными являются следующие три нормы:

$$\|x\|_1 = \sum_{i=1}^n |x_i|, \|x\|_2 = \left( \sum_{i=1}^n |x_i|^2 \right)^{1/2} = \|x\|, \|x\|_\infty = \max_{1 \leq i \leq n} |x_i|. \quad (1.2)$$

Первые две из них являются частными случаями более общей нормы:

$$\|x\|_p = \left( \sum_{i=1}^n |x_i|^p \right)^{1/p}, p \geq 1, \quad (1.3)$$

а последняя норма из (1.2) получается из нормы (1.3) предельным переходом при  $p = \infty$ .

Замечание 1. Норма  $\|x\|_2$  является евклидовой нормой вектора.

Замечание 2. Справедливы неравенства

$$\|x\|_\infty \leq \|x\|_2 \leq n \|x\|_\infty. \quad (1.4)$$

Пусть в пространстве  $R^n$  введена и фиксирована некоторая норма  $\|x\|$ . Тогда для меры близости векторов  $x$  и  $x^*$  используем величину  $\|x - x^*\|$ , являющаяся аналогом расстояния между точками  $x$  и  $x^*$ .

Абсолютную и относительную погрешности вектора  $x^*$  определяем как

$$\Delta(x^*) = \|x - x^*\|, \quad \delta(x^*) = \frac{\|x - x^*\|}{\|x\|}. \quad (1.5)$$

Говорят, что последовательность векторов  $x^{(k)}$  сходится к вектору  $x$  при  $k \rightarrow \infty$  ( $x^{(k)} \rightarrow x$  при  $k \rightarrow \infty$ ), если  $\Delta(x^{(k)}) = \|x^{(k)} - x\| \rightarrow 0$  при  $k \rightarrow \infty$ .

Сходимость по норме в  $R^n$  эквивалентна покомпонентной (покоординатной) сходимости, т.е.  $x_i^{(k)} \rightarrow x_i$  при  $k \rightarrow \infty$ .

Величина

$$\|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|}. \quad (1.6)$$

называется нормой матрицы  $A$ , подчиненной норме векторов, введенной в  $R^n$ .

Можно показать, что введенная в пространстве  $R^n$  по формуле (1.6) норма обладает следующими свойствами:

- 1)  $\|A\| \geq 0$ , причем  $\|A\| = 0$ , при  $A = 0$ ;
- 2)  $\|\alpha A\| = |\alpha| \|A\|$ , для любой матрицы  $A$  и любого числа  $\alpha$ ;
- 3)  $\|A + B\| \leq \|A\| + \|B\|$  для любых матриц  $A$  и  $B$ ;
- 4)  $\|A * B\| \leq \|A\| * \|B\|$  для любых матриц  $A$  и  $B$ ;
- 5) Для любой матрицы и любого вектора  $x$  справедливо неравенство  $\|A * x\| \leq \|A\| * \|x\|$ . (1.7)

Как следует из определения (1.6), каждой из векторных норм  $\|x\|$  соответствует своя подчиненная норма матрицы  $A$ . Нормам  $\|x\|_1$ ,  $\|x\|_2$  и  $\|x\|_\infty$  подчинены нормы  $\|A\|_1$ ,  $\|A\|_2$ ,  $\|A\|_\infty$ , вычисляемые по формулам:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{ij}|;$$

$$\|A\|_2 = \max_{1 \leq j \leq n} \sqrt{\lambda_j(A^T A)},$$

где  $\lambda_j(A^T A)$  – собственные числа матрицы  $A^T A$ ;

$$\|A\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{ij}|.$$

Нормы  $\|A\|_1$  и  $\|A\|_\infty$  вычисляются просто. Вычислить значение нормы  $\|A\|_2$  бывает трудно, так как требуется найти собственные числа  $\lambda_j$ .

Для оценки величины  $\|A\|_2$  можно, например, использовать неравенство

$$\|A\|_2 \leq \|A\|_E, \quad (1.8)$$

где

$$\|A\|_E = \sqrt{\sum_{i,j=1}^n |a_{ij}|^2} - \text{евклидова норма матрицы } A.$$

## 1.2. Обусловленность задачи решения системы линейных алгебраических уравнений

Решения систем линейных алгебраических уравнений обладает разной чувствительностью к погрешностям входных данных. Решение системы

$$Ax = b \quad (1.1)$$

может быть как хорошо, так и плохо обусловленной.

Пусть элементы матрицы  $A$  заданы точно, а вектор-столбец в правой части – приближенно.

Лемма. Для погрешности приближенного решения системы (1.1) справедлива оценка

$$\Delta(x^*) \leq \|A^{-1}\| * \|r\|, \quad (1.9)$$

где  $r = \mathcal{B} - Ax^*$  - невязка, отвечающая  $x^*$ ,  $e = x - x^*$  - погрешность решения. Тогда для невязки  $r$  имеем  $r = Ax - Ax^* = A(x - x^*)$  и поэтому погрешность и невязка связаны равенством

$$e = x - x^* = A^{-1}r. \quad (1.10)$$

Доказательство. Вычисляем норму в левой и правой части (1.10)

$$\|x - x^*\| = \|A^{-1}r\|$$

и воспользуемся неравенством  $\|A * x\| \leq \|A\| * \|x\|$ ,

$$\|x - x^*\| = \Delta(x^*) \leq \|A^{-1}\| * \|r\|.$$

Лемма доказана.

Теорема 1. Пусть  $x^*$  - точное решение системы  $Ax^* = \mathcal{B}^*$ , в которой правая часть  $\mathcal{B}^*$  является приближением к  $\mathcal{B}$ . Тогда верны следующие оценки абсолютной и относительной погрешностей:

$$\Delta(x^*) \leq \vartheta_{\Delta} * \Delta(\mathcal{B}^*), \quad (1.11)$$

$$\delta(x^*) \leq \vartheta_{\delta} * \delta(\mathcal{B}^*), \quad (1.12)$$

где  $\vartheta_{\Delta} = \|A^{-1}\|$ ,  $\vartheta_{\delta} = \frac{\|A^{-1}\| * \|\mathcal{B}\|}{\|x\|}$ .

Доказательство. В этом случае  $r = \mathcal{B} - Ax^* = \mathcal{B} - \mathcal{B}^*$  и неравенство (1.2) принимает вид (1.11), т.е.

$$\|x - x^*\| = \Delta(x^*) \leq \|A^{-1}\| * \|r\| = \|A^{-1}\| * \|\mathcal{B} - \mathcal{B}^*\| = \|A^{-1}\| * \Delta(\mathcal{B}^*).$$

Разделив теперь обе части неравенства (1.11) на  $\|x\|$  и записав его в виде

$$\frac{\Delta(x^*)}{\|x\|} \leq \frac{\|A^{-1}\| * \|\mathcal{B}\|}{\|x\|} * \frac{\Delta(\mathcal{B}^*)}{\|\mathcal{B}\|},$$

приходим к оценке  $\delta(x^*) \leq \frac{\|A^{-1}\| * \|\mathcal{B}\|}{\|x\|} * \delta(\mathcal{B}^*)$ , где

$$\vartheta_{\delta} = \frac{\|A^{-1}\| * \|\mathcal{B}\|}{\|x\|}.$$

Теорема доказана.

Замечание 1. Величина  $\vartheta_{\Delta}$  для задачи (1.1) играет роль абсолютного числа обусловленности.

Замечание 2. Величина  $\vartheta_\delta = \delta_\delta(x) = \frac{\|A^{-1}\| * \|b\|}{\|x\|}$  называется естественным числом обусловленности (относительное число обусловленности).

Вычислим максимальное значение естественного числа обусловленности, используя определение нормы матрицы

$$\left( \|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} \right) \max_{x \neq 0} \vartheta_\delta(x) = \max_{x \neq 0} \frac{\|A^{-1}\| * \|Ax\|}{\|x\|} = \|A^{-1}\| * \|A\|.$$

Полученную величину принято называть стандартным числом обусловленности (или просто числом обусловленности) матрицы  $A$  и обозначают через  $\vartheta(A)$  или  $Cond(A)$ . Таким образом,

$$\vartheta(A) = Cond(A) = \|A^{-1}\| * \|A\|. \quad (1.13)$$

Следствие 1. В условиях теоремы 1 справедлива оценка  $\delta(x^*) \leq Cond(A) * \delta(b^*)$ .

$$(1.14)$$

Величина  $Cond(A)$  является широко используемой количественной мерой обусловленности системы  $Ax = b$ . Систему и матрицу  $A$  принято называть плохо обусловленной, если  $Cond(A) \gg 1$ . ( $Cond(A) \geq 10^3$ ). Если  $Cond(A) < 10^2$  - то матрица хорошо обусловлена.

Свойства числа обусловленности:

1) Для единичной матрицы  $Cond(E) = 1$ . Пользуясь тем, что  $E^{-1} = E$  и  $\|E\| = 1$ , получим  $Cond(E) = \|E^{-1}\| * \|E\| = 1$ .

2) Справедливо неравенство  $Cond(A) \geq 1$ . Из равенства  $E = A * A^{-1}$ , свойства норм матрицы  $\|A * B\| \leq \|A\| * \|B\|$  и равенства  $\|E\| = 1$  следует, что  $1 = \|E\| \leq \|A^{-1}\| * \|A\| = Cond(A)$ .

3) Число обусловленности матрицы  $A$  не меняется при умножении матрицы на произвольное число  $\alpha \neq 0$ .

Заметим, что  $(\alpha A)^{-1} = \alpha^{-1} A^{-1}$ .

## Замечания

1. Норма матрицы  $A$  имеет простую геометрическую интерпретацию. Для этого заметим, что операцию умножения матрицы  $A$  на вектор  $x$  можно рассматривать как преобразование, которое переводит вектор  $x$  в новый вектор  $y = Ax$ . Если значение  $\|x\|$  интерпретировать как длина вектора  $x$ , то величина  $\frac{\|Ax\|}{\|x\|}$  есть коэффициент растяжения вектора  $x$  под действием матрицы  $A$ . Таким образом, величина

$$K_{max} = \|A\| = \max_{x \neq 0} \frac{\|Ax\|}{\|x\|} \quad (1.15)$$

представляет собой максимальный коэффициент растяжения векторов под действием матрицы  $A$ . Для невырожденной матрицы  $A$  минимальный коэффициент растяжения  $K_{min}$  отвечает норме обратной матрицы и вычисляется по формуле

$$K_{min} = \|A^{-1}\|^{-1} = \min_{x \neq 0} \frac{\|Ax\|}{\|x\|}. \quad (1.16)$$

В случае  $\|A\| < 1$  происходит сжатие векторов под действием матрицы  $A$ .

2. Число обусловленности можно интерпретировать как отношение максимального коэффициента растяжения векторов под действием матрицы  $A$  к минимальному коэффициенту:

$$Cond(A) = \frac{K_{max}}{K_{min}}.$$

Теорема 2. Пусть  $x^*$  — точное решение системы  $A_* x^* = b$  с приближенно заданной матрицей  $A_*$ . Тогда верна следующая оценка относительной погрешности:

$$\delta^*(x^*) \leq Cond(A) * \delta(A_*), \quad (1.17)$$

где  $\delta^*(x^*) = \frac{\|x - x^*\|}{\|x^*\|}, \quad \delta(A_*) = \frac{\|A - A_*\|}{\|A\|}.$



Доказательство. В данном случае  $r$  имеет вид

$$r = \mathcal{B} - Ax^* = A_*x^* - Ax^* = (A_* - A) * x^*.$$

Применяя неравенство  $\Delta(x^*) \leq \|A^{-1}\| * \|r\|$ , получим цепочку неравенств

$$\begin{aligned} \delta^*(x^*) &= \frac{\|x - x_*\|}{\|x^*\|} \leq \|A^{-1}\| * \frac{\|(A_* - A) * x^*\|}{\|x^*\|} \leq \\ &\frac{\|A^{-1}\| * \|(A_* - A)\| * \|x^*\| * \|A\|}{\|A\| * \|x^*\|} = \text{Cond}(A) * \delta(A_*). \end{aligned}$$

Теорема доказана.

Следствие. В условиях теоремы 2 справедливо приближенное неравенство  $\delta(x^*) \lesssim \text{Cond}(A) * \delta(A_*)$ .

Замечание 1. В случае, когда с погрешностью заданы как правая часть системы, так и матрица, т.е.  $x^*$  является решением системы  $A_*x^* = \mathcal{B}^*$ , причем  $\text{Cond}(A) * \delta(A_*) \ll 1$ , можно доказать справедливость неравенства

$$\delta(x^*) \lesssim \text{Cond}(A) * (\delta(\mathcal{B}^*) + \delta(A_*)).$$

Замечание 2. Вычисление  $A^{-1}$  трудоемко. Поэтому можно ограничиться грубой оценкой числа обусловленности с точностью до порядка. Для этого задачу решить несколько раз с близкими к  $\mathcal{B}$  правыми частями

$\mathcal{B}^{(1)}, \mathcal{B}^{(2)}, \dots, \mathcal{B}^{(k)}$ . Можно ожидать, что величина  $\widetilde{\vartheta}_\delta = \max_{1 \leq l \leq k} \frac{\delta(x^{(l)})}{\delta(\mathcal{B}^{(l)})}$  дает

оценку значения  $\vartheta_\delta$ . Эта величина дает оценку снизу, так как

$$\widetilde{\vartheta}_\delta \leq \vartheta_\delta \leq \text{Cond}(A).$$

Для решения плохо обусловленных систем уравнений применяют регуляризацию, т.е. решают вместо системы (1.1) другую систему:

$$(A_*^T A_* + \alpha E)x = A_*^T \mathcal{B}_*, \quad (1.18)$$

где  $A_* = A + \delta A$ ,  $b_* = b + \delta b$ ,  $\alpha > 0$  – малое число, называемое параметром регуляризации. При  $\alpha = 0$  получим исходную систему, приведенную к нормальному виду:

$$A_*^T A_* x = A_*^T b_*.$$

Если известны погрешности  $\|\delta A\|$  и  $\|\delta b\|$ , то параметр  $\alpha$  находят из условия согласования с погрешностью  $\|\delta A\|$  и  $\|\delta b\|$

$$\|r_\alpha\| = \|b_* - A_* x_\alpha\| = \|\delta b - \delta A * x_\alpha\| \leq \|\delta b\| + \|\delta A\| * \|x_\alpha\|,$$

где  $x_\alpha$  – решение системы (1.18).

### 1.3. Примеры обусловленности систем линейных алгебраических уравнений

Пример 1. Вычислить  $Cond_\infty(A)$  для матрицы

$$A = \begin{pmatrix} 1.03 & 0.991 \\ 0.991 & 0.943 \end{pmatrix}. \quad (1.19)$$

Решение. Найдем обратную матрицу  $A^{-1}$ .

$$A^{-1} = \begin{pmatrix} -85.7 & 90.1 \\ 90.1 & -93.6 \end{pmatrix},$$

$$Cond_\infty(A) = \|A\|_\infty * \|A^{-1}\|_\infty = 2.021 * 183.7 \approx 371.3.$$

Если входные данные для системы уравнений с матрицей (1.19) содержат относительную погрешность порядка 0,1 – 1%, то систему можно расцепить как плохо обусловленную.

Пример 2. Рассмотрим систему уравнений

$$\begin{cases} 1.03x_1 + 0.991x_2 = 2.51 \\ 0.991x_1 + 0.943x_2 = 2.41. \end{cases}$$

с матрицей (1.19). Ее решением является  $x_1 \approx 1.981, x_2 \approx 0.4735$ . Правая часть системы известна в лучшем случае с точностью до 0.005, если считать, что числа 2.51 и 2.41 получены округлением “истинных” значений при вводе в память трехзначной десятичной ЭВМ. Как влияет по-

грешность во входных данных такого уровня на погрешность решения? Возмутим каждую из компонент вектора правой части  $b = (2.51, 2.41)^T$  на величину 0.005, взяв  $b^* = (2.505, 2.415)^T$ . Решением системы, отвечающим  $b^*$ , является теперь  $x_1^* \approx 2.877$ ,  $x_2^* \approx -0.4629$ . Таким образом, решение оказалось полностью искаженным. Относительная погрешность задания правой части  $\delta(b^*) = \frac{\|b - b^*\|_\infty}{\|b\|_\infty} = \frac{0.005}{2.51} \approx 0.2\%$  привела к относительной погрешности решения  $\delta(x^*) = \frac{\|x - x^*\|_\infty}{\|x\|_\infty} \approx \frac{0.9364}{1.981} \approx 47.3\%$ . Погрешность возросла примерно в 237 раз. Можно ли ввести в правую часть системы такую погрешность, чтобы получить существенно больше, чем 237 раз, значение коэффициента роста ошибки. Вычислим естественное число обусловленности, являющееся максимальным значением рассматриваемого коэффициента, отвечающим решению  $x = (1.981, 0.4735)^T$  и получим  $\vartheta_\delta(x) = \frac{\|A^{-1}\|_\infty * \|b\|_\infty}{\|x\|_\infty} = \frac{187.2 * 2.51}{1.981} \approx 237$ . Таким образом, на поставленный вопрос следует ответить отрицательно.

Пример 3. Решить систему

$$\begin{cases} x + 2y = 1 \\ x + 2.005y = -1. \end{cases}$$

Решением системы является  $x = 801, y = -400$ . Предположим, что за счет погрешности коэффициентов при  $y$  во втором уравнении изменится на 0.01 и станет равным 1.995. Тогда решением измененной системы будут  $x = -799, y = 400$ . Изменение коэффициента при  $y$  во втором уравнении всего на 0.5% изменило решение на 200%. Система плохо обусловлена.

Вычислим  $Cond_\infty(A) = \|A^{-1}\| * \|A\|$ .

Имеем

$$A = \begin{pmatrix} 1 & 2 \\ 1 & 2.005 \end{pmatrix}, \quad A^{-1} = \begin{pmatrix} 401 & -400 \\ -200 & 200 \end{pmatrix},$$

$$\|A\|_{\infty} = 3.005, \quad \|A^{-1}\|_{\infty} = 801,$$

$Cond_{\infty}(A) \approx 2400$ . Система очень плохо обусловлена.

Пример 4. Решить систему

$$\begin{cases} 2x_1 + 3x_2 + x_3 = 11 \\ x_1 \quad \quad \quad 2x_3 = 7 \\ -x_1 + 3x_2 - 2x_3 = -1. \end{cases}$$

Эту систему можно решить любым методом: Крамера, обратной матрицы, Гаусса и т.д., так как матрица системы хорошо обусловлена. Решение системы являются числа  $x_1 = 1, x_2 = 2, x_3 = 3$ . Найдем число обу-

словленности матрицы

$$A = \begin{pmatrix} 2 & 3 & 1 \\ 1 & 0 & 2 \\ -1 & 3 & -2 \end{pmatrix}.$$

Обратная матрица

$$A^{-1} = \begin{pmatrix} \frac{2}{3} & -1 & -\frac{2}{3} \\ 0 & \frac{1}{3} & \frac{1}{3} \\ -\frac{1}{3} & 1 & \frac{1}{3} \end{pmatrix},$$

$$\|A\|_{\infty} = 6, \|A^{-1}\|_{\infty} = \frac{7}{3}, Cond_{\infty}(A) = 14.$$

Матрица хорошо обусловлена.

Классические методы решения систем линейных алгебраических уравнений не работают для систем с плохо обусловленными матрицами. Такие системы решаются различными методами регуляризации.

Пример 5. Решим систему

$$\begin{cases} 0.780x + 0.563y = 0.217 \\ 0.457x + 0.330y = 0.127. \end{cases} \quad (1.20)$$

Используя стандартный метод в трехразрядной десятичной арифметике, найдем решение  $x = 1.71, y = -1.98$ . Невязка при этом равна

$r_1 = 0.00206, r_2 = 0.00107$ , т.е. она мала. В то же время точное решение системы имеет вид:

$$x = 1.000, y = -1.000$$

Этот пример показывает, что вычисленное решение может сильно отличаться от точного и в то же время вести себя примерно так же, как точное решение, т.е. вычисленные значения «почти решают» уравнения.

Метод использованный для решения системы (1.20), считается высококачественным и тем не менее вычисленное решение оказалось неточным. В этом нет вины алгоритма. Данная задача плохо обусловлена, сверхчувствительна. Это означает, что ничтожно малые изменения коэффициентов задачи способны привести к большим изменениям ее решения. Не следует ожидать от алгоритма, что он будет давать хорошие результаты, если задача плохо обусловлена.

Пример 6. Рассмотрим линейную систему  $Ax = b$ , где

$$A = \begin{pmatrix} 9.7 & 6.6 \\ 4.1 & 2.8 \end{pmatrix}, b = \begin{pmatrix} 9.7 \\ 4.1 \end{pmatrix}, x = \begin{pmatrix} 1 \\ 0 \end{pmatrix}.$$

$$\Delta = 0.100, A^{-1} = \begin{pmatrix} 28 & -66 \\ -41 & 97 \end{pmatrix}.$$

Вектор  $x = (1, 0)^T$  является ее решением. При этом

$$\|b\|_1 = 13.8, \|x\|_1 = 1.$$

$$\|A\|_1 = 13.8, \|A^{-1}\|_1 = 163. \text{Cond}_1(A) = 163 * 13.8 = 2249.400$$

1. Вычислим точное значение числа обусловленности  $\text{Cond}(A) = 2249.4$ .

Это означает, что относительное изменение решения превышает относительное изменение правой части, грубо говоря, на четыре порядка. Для проверки изменим правую часть на

$$b^* = \begin{pmatrix} 9.70 \\ 4.11 \end{pmatrix}.$$

Новым решением будет вектор

$$x^* = \begin{pmatrix} 0.34 \\ 0.97 \end{pmatrix}.$$

Положим  $\Delta b = b - b^*$ ,  $\Delta x = x - x^*$ . Тогда  $\|\Delta b\|_1 = 0.01$ ,  $\|\Delta x\|_1 = 1.63$ .

Малое возмущение  $b$  сильно изменило  $x$ . Относительные изменения равны

$$\frac{\|\Delta b\|}{\|b\|} = 0.00072464, \quad \frac{\|\Delta x\|}{\|x\|} = 1.63.$$

Их отношение есть  $\frac{1.63}{0.00072464} = 2249.4$ , т.е. совпадает с  $Cond(A)$ . Система очень плохо обусловлена. Справедливо практическое правило: при решении системы линейных уравнений относительная погрешность решения пропорциональна относительным погрешностям матрицы коэффициентов системы и ее правой части, причем константа пропорциональности равна числу обусловленности.

#### 1.4. Решение переопределенной системы линейных алгебраических уравнений

Пусть дана система

$$Ax = b, \tag{1.1}$$

где  $A - (n * m)$  – матрица, причем  $n \geq m$ ;

$x - m$  – мерный вектор неизвестных;

$b - n$  мерный вектор правой части.

Если  $n > m$ , то есть число уравнений больше числа неизвестных, то говорят, что система (1.1) переопределена.

Для решения переопределенной системы используют метод наименьших квадратов (МНК). Идея его состоит в минимизации суммы квадратов невязок.

Суть МНК заключается в том, чтобы неизвестные  $x_j$  находить из условия

$$R = r^2 = \sum_{i=1}^n r_i^2 = \sum_{i=1}^n (\sum_{j=1}^m a_{ij}x_j - b_i)^2 \rightarrow \min.$$

Необходимое условие минимума

$$\frac{\partial R}{\partial x_j} = 0; j = \overline{1, m}$$

приводит к системе, в которой количество уравнений будет равно  $m$ , то есть совпадает с числом неизвестных. Взяв производные по  $x_j$  от функции  $R(x_1, \dots, x_m)$  получим следующую систему

$$\sum_{j=1}^m c_{lj} x_j = g_l, l = \overline{1, m}, \quad (1.21)$$

где

$$g_l = \sum_{k=1}^n a_{kl} \theta_k, \quad c_{lj} = c_{jl} = \sum_{i=1}^n a_{ij} a_{il}.$$

В матричном виде система (1.21) запишется так

$$Cx = g, \quad (1.22)$$

где  $C = A^T A, \quad g = A^T \theta$ .

В системе (1.22) матрица  $C$  – квадратная, симметричная размерности  $m * m$ . Для решения системы (1.22) можно использовать любой метод.

### 1.5. Методы решения плохо обусловленной системы линейных алгебраических уравнений

Пусть имеем систему уравнений

$$Ax = \theta. \quad (1.1)$$

Предположим, что матрица  $A$  системы плохо обусловлена. В этом случае решение задачи (1.1) будет неустойчивым, т.е. задача практически будет некорректной.

Некорректные задачи создают значительные трудности при их приближенном решении. Как правило, исходные данные прикладных задач известны с некоторой погрешностью. Отыскание неустойчивых решений прикладных задач приводит к тому, что классические методы вы-

числительной математики могут дать результат, сколь угодно сильно отличающийся от точного решения, при условии, что исходные данные отличаются сколь угодно мало.

Применим к обеим частям уравнения (1.1), сопряженный к  $A$  оператор  $A^*$ , приходим к уравнению

$$A^*Ax = A^*b. \quad (1.23)$$

Симметризация Гаусса. Оператор  $A^*A$  – самосопряжен и неотрицателен.

Метод М. М. Лаврентьева применяют для решения некорректно поставленных задач с самосопряженными неотрицательными операторами.

Будем считать, что в уравнении (1.1)  $A = A^* \geq 0$ .

Метод М. М. Лаврентьева заключается в переходе к регуляризованному уравнению

$$\alpha x + Ax = b, \quad (1.24)$$

где  $\alpha$  – малый положительный параметр, параметр регуляризации. Задача (1.24) корректна и некорректная задача (1.1) вкладывается в семейство корректных как предельный случай при  $\alpha \rightarrow 0$ . Задачу (1.24) можно решить любым прямым методом с итерационным уточнением.

Можно использовать итеративную модификацию метода М. М. Лаврентьева. Зафиксируем натуральное число  $p \geq 1$ . Пусть  $x_0$  – некоторое априори известное приближение к решению уравнения (1.1).

Положим  $x_{0,\alpha} = x_0$ , последовательно вычислим  $x_{1,\alpha}, x_{2,\alpha}, \dots, x_{p,\alpha}$  как решения уравнений

$$\alpha x_{s,\alpha} + Ax_{s,\alpha} = \alpha x_{s-1,\alpha} + b, s = \overline{1, p}. \quad (1.25)$$

В качестве приближенного решения уравнения (1.1) примем элемент  $x_{p,s}$ . Заметим, что в случае  $p = 1, x_0 = 0$  имеем дело с методом (1.24).

Метод А. Н. Тихонова применим к задаче (1.1) в ее общей постановке (без условия самосопряженности).



В общей постановке некорректной задачи (1.1) рассмотрим как совместную неопределенную систему линейных уравнений.  $A = (a_{ij}^m)_n^m$ ,  $x = (x_j)^n$ ,  $b = (b_i)^m$ . Такая система имеет бесконечно много решений, поэтому надо ввести дополнительное условие, чтобы система стала определенной.

Во многих прикладных задачах таким условием является требование, чтобы длина вектора решения  $x$  была минимальной среди всех решений этой системы, т.е. чтобы скалярное произведение  $(x, x)$  было минимальным. Такое решение системы (1.1) называется нормальным и обозначается  $x_H$ .

Вычисление на ЭВМ минора матрицы  $A$ , равного нулю, обычно приводит к результату отличному от нуля даже при малых ошибках округления. В такой ситуации совершенно не ясно, какой минор нужно считать базисным минором матрицы  $A$ . Алгоритм становится некорректным. Для решения некорректных математических задач предложен А. Н. Тихоновым метод регуляризации. Применительно к этой задаче метод регуляризации основан на решении не исходной задачи, которая является неустойчивой (или неопределенной), а близкой к ней вспомогательной, содержащей некоторый положительный параметр регуляризации  $\alpha$ . После этого новая задача оказывается устойчивой (или однозначно разрешимой) для любого выбора положительного параметра  $\alpha$ . Предполагая, что в линейном пространстве  $R^n$  и  $R^m$  введено скалярное произведение, перепишем систему (1.1) в эквивалентной форме:

$$(Ax - b, Ax - b) = 0. \quad (1.26)$$

Регуляризованная задача формируется так:

найти решение  $x_\alpha$ , зависящее от  $\alpha$ , при котором функционал

$$F_\alpha(x) = (Ax - b, Ax - b) + \alpha(x, x), \quad (1.27)$$

где  $\alpha > 0$ , является минимальным, а выбрать параметр  $\alpha$  так, чтобы регуляризованное значение  $x_\alpha$  было «наиболее близким» к нормальному решению  $x_H$  системы (1.1). Регуляризирующий функционал  $F_\alpha(x)$  запишем, вычисляя скалярное произведение в ортонормированном базисе,

$$F_\alpha(x) = \sum_{i=1}^n (a_j^i x^j - \theta^i)^2 + \alpha \sum_{j=1}^n (x^j)^2. \quad (1.28)$$

Должно выполняться необходимое условие минимума функции:

$$F_\alpha(x) = F_\alpha(x^1, x^2, \dots, x^n),$$

поэтому имеем

$$\frac{\partial F_\alpha}{\partial x^j} = 2 \sum_{i=1}^n (a_j^i x^j - \theta^i) a_j^i + 2\alpha x^j = 0, \quad j = \overline{1, n}. \quad (1.29)$$

Равенство (1.28) в матричной форме имеет вид:

$$(A^T A + \alpha E)x = A^T \theta, \quad \alpha > 0. \quad (1.30)$$

Таким образом, решение неопределенной системы (1.1) сведено к решению однозначно разрешимой системы (1.30). Решение этой системы можно найти, используя прямые или итерационные методы решения корректных задач.

Значит, простейший вариант метода А. Н. Тихонова заключается в отыскании точки минимума функционала

$$F_\alpha(x) = \alpha \|x\|_{R^n}^2 + \|Ax - \theta\|_{R^n}^2, \quad x \in R^n, \quad (1.31)$$

где  $\alpha$  – малый положительный параметр.

Эта задача на минимум равносильна определению  $x$  из уравнения  $\alpha x + A^* A x = A^* \theta$ . (1.32)

Наряду с описанным вариантом метода А. Н. Тихонова (1.32) можно применять его итерационный вариант. Зададим начальное прибли-

жение  $x_{0,\alpha} = x_0 \in R^n$  и натуральное число  $p \geq 1$  и последовательно вычислим  $x_{1,\alpha}, x_{2,\alpha}, \dots, x_{p,\alpha}$  по формулам:

$$\alpha x_{s,\alpha} + A^* A x_{s,\alpha} = \alpha x_{s-1,\alpha} + A^* \theta, \quad s = \overline{1, p}. \quad (1.33)$$

Элемент  $x_{p,\alpha}$  примем за приближенное решение уравнения (1.1).

Выше регуляризация некорректной задачи достигалась ее включением, как некоторого предельного случая ( $\alpha = 0$ ), в семейство корректно поставленных задач. Теперь обратимся к итерационным методам регуляризации. Параметром регуляризации в них является номер итерации. Дадим описание простейших итерационных методов сперва в самосопряженном случае, т.е.  $A = A^* \geq 0$ . Зададимся начальным приближением  $x_0 \in R$ , его разумно брать ближе к искомому точному решению (1.1). При отсутствии всякой информации о точном решении можно положить  $x_0 = 0$ . По  $x_0$  последовательно вычислим

$$x_s = x_{s-1} - \mu(Ax_{s-1} - \theta), \quad (1.34)$$

где  $\mu > 0$  — постоянная.

Другая итерационная схема:

$$\alpha x_s + Ax_s = \alpha x_{s-1} + \theta, \quad s = 1, 2, \dots (\alpha = \text{const} > 0). \quad (1.35)$$

Каждый шаг итерации заключается в решении корректно поставленной задачи. Постоянная  $\alpha$  здесь не обязательна мала. Регуляризация достигается за счет многократного итерирования.

Стоит обратить внимание на формальное сходство итерационного метода (1.35) с итерационным вариантом метода М. М. Лаврентьева (1.35). Однако регуляризация в этих двух методах достигается по-разному: в итерационном варианте метода М. М. Лаврентьева за счет малости  $\alpha$  при фиксированном числе итераций, а в итерационном методе (1.35) — за счет большого числа итераций при фиксированном  $\alpha$ .

В общем случае несамосопряженную задачу (1.1) предварительно симметризируем (переходим от задачи (1.1) к задаче (1.23)) и затем применим те же итерационные схемы, что и выше. Таким образом, приходим к итерационным схемам:

$$x_s = x_{s-1} - \mu A^*(Ax_{s-1} - \theta), \quad s = 1, 2, \dots, \quad (1.36)$$

$$0 < \mu < \frac{2}{\|A\|^2},$$

$$\alpha x_s + A^*Ax_s = \alpha x_{s-1} + A^*\theta, \quad s = 1, 2, \dots (\alpha = \text{const} > 0). \quad (1.37)$$

Схемы (1.34) и (1.36) называются явными итерационными схемами, а схемы (1.35) и (1.37) – неявными.

## § 2. Чувствительность интерполяционного многочлена к погрешностям входных данных

Пусть заданные в узлах  $x_i$  значения  $y_i^*$  содержат погрешности  $\varepsilon_i$ . Тогда вычисляемый по этим значениям многочлен

$$P_n^*(x) = \sum_{j=0}^n y_j^* L_{n_j}(x)$$

содержит погрешность

$$P_n(x) - P_n^*(x) = \sum_{j=0}^n \varepsilon_j L_{n_j}(x). \quad (2.1)$$

Например, при линейной интерполяции по приближенно заданным значениям справедливо равенство  $P_1(x) - P_1^*(x) = \varepsilon_0 L_{10}(x) + \varepsilon_1 l_{11}(x)$ , где  $L_{10}(x) = \frac{x-x_1}{x_0-x_1}, l_{11}(x) = \frac{x-x_0}{x_1-x_0}$ .

Воспользуемся тем, что  $|L_{10}(x)| + |l_{11}(x)| = 1$  для  $x \in [x_0, x_1]$ . Следовательно,  $\max_{[x_0, x_1]} |P_1(x) - P_1^*(x)| \leq \max\{|\varepsilon_0|, |\varepsilon_1|\}$ . Таким образом, при линейной интерполяции погрешность, возникающая вследствие по-

погрешности значений функции не превосходит верхней границы погрешности этих значений.

Рассмотрим общий случай. Пусть известно, что верхняя граница погрешности значений  $y_i^*$  равна  $\bar{\Delta}(y^*)$ , т.е.  $|\varepsilon_i| \leq \bar{\Delta}(y^*)$  для всех  $i = \overline{0, n}$ . Тогда для верхней границы соответствующей погрешности многочлена  $\bar{\Delta}(P_n^*) = \max_{[a,b]} |P_n(x) - P_n^*(x)|$  в силу равенства (2.1) справедлива оценка

$$\bar{\Delta}(P_n^*) \leq \Lambda_n \bar{\Delta}(y^*), \quad (2.2)$$

где  $\Lambda_n = \max_{[a,b]} \sum_{j=0}^n |L_{nj}(x)|$  – величина, которая называется константой Лебега. В задаче интерполирования константа Лебега играет роль абсолютного числа обусловленности.

В вычислениях не следует использовать интерполяционные многочлены высокой степени с равностоящими узлами.

### § 3. Обусловленность задачи минимизации

Пусть  $\bar{x}$  – точка строгого локального минимума функции  $f$ , вычисляемой с погрешностью. Будем считать, что в некоторой окрестности точки  $\bar{x}$  вычисляемые приближенные значения  $f^*(x)$  удовлетворяют неравенству  $|f(x) - f^*(x)| \leq \bar{\Delta} = \bar{\Delta}(f^*)$ , т.е. имеют границу абсолютной погрешности, равную  $\bar{\Delta}$ . Существует малая окрестность  $(\bar{x} - \bar{\varepsilon}, \bar{x} + \bar{\varepsilon})$  точки минимума  $\bar{x}$ , для которой нельзя достоверно определить ту точку, в которой действительно достигается минимум функции  $f$ . Интервал  $(\bar{x} - \bar{\varepsilon}, \bar{x} + \bar{\varepsilon})$  называется интервалом неопределенности точки  $\bar{x}$  локального минимума.

Пусть функция  $f(x)$  дважды непрерывно дифференцируема и выполнено условие  $f''(\bar{x}) > 0$ . Оценим величину  $\bar{\varepsilon}$  радиуса интервала неопреде-

ленности. С учетом того, что  $f'(\bar{x}) = 0$ , для значений функции  $f$  в точках  $x$ , близких к  $\bar{x}$ , справедливо приближенное равенство

$$f(x) \approx f(\bar{x}) + \frac{f''(\bar{x})}{2}(x - \bar{x})^2.$$

Оценим минимальное расстояние между точками  $x$  и  $\bar{x}$ , начиная с которого заведомо будет выполнено неравенство  $f^*(x) > f^*(\bar{x})$ , т.е. точка  $x$  перестанет попадать в интервал неопределенности. Имеем

$$\begin{aligned} f^*(x) - f^*(\bar{x}) &= f(x) - f(\bar{x}) + (f^*(x) - f(x)) - (f^*(\bar{x}) - f(\bar{x})) \geq \\ &= f(x) - f(\bar{x}) - 2\bar{\Delta} \approx \frac{f''(\bar{x})}{2}(x - \bar{x})^2 - 2\bar{\Delta} \end{aligned}$$

Следовательно,  $f^*(x) - f^*(\bar{x}) \gtrsim \frac{f''(\bar{x})}{2}(x - \bar{x})^2 - 2\bar{\Delta}$  и неравенство  $f^*(x) > f^*(\bar{x})$  выполнено, если  $(x - \bar{x})^2 \gtrsim 4\bar{\Delta}/f''(\bar{x})$ . Таким образом,

$$\bar{\varepsilon} \approx 2 \sqrt{\bar{\Delta}/f''(\bar{x})}. \quad (3.1)$$

Любое приближение  $\bar{x}^*$  к  $\bar{x}$ , попавшее в интервал неопределенности, нельзя отличить от точного значения  $\bar{x}$  точки минимума, используя только вычисляемые значения  $f^*$  функции  $f$ . Поэтому

$$\bar{\Delta}(\bar{x}^*) \approx 2 \sqrt{\bar{\Delta}(f^*)/f''(\bar{x})}. \quad (3.2)$$

Таким образом, рассматриваемую задачу минимизации нельзя назвать хорошо обусловленной. Если задача хорошо масштабирована, т.е.  $\bar{x} \sim 1, |f(\bar{x})| \sim 1, f''(\bar{x}) \sim 1$ , то соотношение (3.2) можно записать в терминах относительных погрешностей:

$$\bar{\delta}(x^*) \sim \sqrt{\bar{\delta}(f^*)}.$$

Если  $\bar{\delta}(f^*) \sim 10^{-m}$ , то  $\bar{\delta}(x^*) \sim 10^{-\frac{m}{2}}$ . Это значит, если значения функции вычисляются с  $m$  верными значащими цифрами, то приближенное значение точки минимума можно найти примерно лишь с  $m/2$  верными значащими цифрами.

Для отыскания точки локального минимума можно использовать вычисляемые каким-либо образом приближенные значения  $(f')^*(x)$  производной функции  $f$ . В этом случае задача минимизации эквивалентна задаче отыскания корня  $\bar{x}$  нелинейного уравнения  $f'(x) = 0$ . Данная задача обладает значительно меньшей чувствительностью к ошибкам. Справедлива следующая оценка границы абсолютной погрешности:

$$\bar{\Delta}(\bar{x}^*) \approx \frac{1}{f''(\bar{x})} \bar{\Delta}((f')^*). \quad (3.3)$$

#### § 4. Обусловленность формул численного дифференцирования

Используемые при численном дифференцировании значения  $f^*(x)$  функции  $f(x)$  содержат ошибки. Поэтому к погрешности аппроксимации формул численного дифференцирования добавляется неустранимая погрешность, вызванная погрешностями вычисления функции  $f$ . Чтобы уменьшить погрешность аппроксимации требуется использование таблиц с малыми шагами  $h$ . Однако при малых шагах формулы численного дифференцирования становятся плохо обусловленными. Причина этого явления лежит не в несовершенстве предложенных методов вычисления производных, а в некорректности самой операции дифференцирования приближенно заданной функции.

Рассмотрим пример. Пусть имеем две функции:

$$u(x), \tilde{u}(x) = u(x) + \frac{1}{n} \sin n^2(x - a).$$

Если  $n$  достаточно большое, то расстояние между ними в  $C[a, b]$  равно

$$\rho(u, \tilde{u}) = \max_{[a, b]} |u(x) - \tilde{u}(x)| = \max_{[a, b]} \left| \frac{1}{n} \sin n^2(x - a) \right| = \frac{1}{n},$$

но при этом

$$\tilde{u}'_x = u'_x + n \cos n^2(x - a) \quad \text{и} \quad \rho(\tilde{u}'_x, u'_x) = \max_{[a, b]} |n \cos n^2(x - a)| = n.$$

Этот пример показывает, что для сколь угодно близких функций  $u(x), \tilde{u}(x) \in C[a, b]$  расстояние между их производными в  $C[a, b]$  может быть сколь угодно велико, т.е. нет устойчивости решения этой задачи.

Полная погрешность  $r^*(x, h) = f'(x) - \frac{f^*(x+h) - f^*(x)}{h}$  реально вычисляемого значения правой разностной производной представляет собой сумму погрешности аппроксимации

$$r_+(x, h) = f'(x) - \frac{f(x+h) - f(x)}{h}$$

и неустранимой погрешности

$$r_H(x, h) = \frac{1}{h} ((f(x+h) - f^*(x+h)) - (f(x) - f^*(x))).$$

Пусть  $\bar{\Delta}$  - верхняя граница абсолютной погрешности  $\Delta(f^*(x)) = |f(x) - f^*(x)|$  используемых значений функций. Тогда погрешность  $r_H$  оценивается так:

$$|r_H| \leq \frac{2\bar{\Delta}}{h}. \quad (4.1)$$

Оценка (4.1) означает, что чувствительность формулы правой разностной производной к погрешностям входных данных характеризуется

абсолютным числом обусловленности  $\nu_{\Delta} = \frac{2}{h}$ . Отсюда видно, что фор-



мула правой разностной производной при малых  $h$  становится очень плохо обусловленной. Хотя погрешность аппроксимации стремится к нулю при  $h \rightarrow 0$ , но полная погрешность будет неограниченно возрастать при  $h \rightarrow 0$ . Верхняя граница полной погрешности равна

$$\bar{r}(h) = \frac{1}{2} \mu_2 * h + \frac{2\bar{\Delta}}{h}, \quad \mu_2 = \max_x |f''(x)|.$$

Выберем оптимальное значение шага  $h$ , при котором величина  $\bar{r}(h)$  достигает минимального значения.

Приравняв производную  $\bar{r}'(h) = \frac{1}{2} \mu_2 - \frac{2\bar{\Delta}}{h^2}$  к нулю, получаем значение

$$h_{\text{опт}} = 2 \sqrt{\bar{\Delta} / \mu_2},$$

которому отвечает величина

$$\bar{r}_{\min} = \bar{r}(h_{\text{опт}}) = 2 \sqrt{\bar{\Delta} \mu_2}.$$

Отсюда видно, что даже при оптимальном выборе шага полная погрешность является величиной, пропорциональной лишь  $\sqrt{\bar{\Delta}}$ .

Формулы для вычисления производных порядка  $k > 1$  обладают еще большей чувствительностью к ошибкам задания функций.

Чтобы получить более точное приближение для производной, можно попытаться уменьшить либо неустранимую ошибку, либо ошибку округления. Для уменьшения ошибки округления можно использовать машину с меньшей константой  $\varepsilon_\mu$  (большей машинной точности), то мы можем провести вычисления при меньшем значении  $h$ . Тем самым неустранимая ошибка будет уменьшена, а вместе с нею и полная ошибка  $r(h)$ .

Другой способ получения лучшей аппроксимации состоит в том, чтобы снизить неустранимую ошибку при тех же значениях  $h$ . Если мы аппроксимируем производную центральным разностным отношением

$$\delta_h f(x) \equiv \frac{f(x+h) - f(x-h)}{2h},$$

то погрешность аппроксимации будет порядка  $O(h^2)$ .

Другим широко используемым приемом повышения порядка аппроксимации является экстраполяция. Центральное разностное отношение аппроксимирует первую производную функции  $f'(x)$  со вторым порядком, т. е.  $O(h^2)$ . Чтобы повысить порядок аппроксимации первую производную аппроксимируем на двух сетках с шагами  $h$  и  $\frac{h}{10}$  и их будем скомбинировать. Примем для  $\delta_h f(x)$  сокращенное обозначение  $\delta_h$ . Тогда

$$\begin{aligned}\delta_h &= f'(x) + \frac{h^2}{6} f'''(x) + \frac{h^4}{120} f^{(5)}(x) + \dots, \\ \delta_{\frac{h}{10}} &= f'(x) + \frac{1}{100} * \frac{h^2}{6} f'''(x) + \frac{1}{10000} * \frac{h^4}{120} f^{(5)}(x) + \dots\end{aligned}$$

Комбинируя эти приближения, получаем

$$\frac{100\delta_{\frac{h}{10}} - \delta_h}{99} = f'(x) - \frac{h^4}{100 \cdot 120} f^{(5)}(x) + \dots$$

Итак, взяв два приближения для различных значений  $h$  и скомбинировав их, мы получим третье приближение, более точное, чем два первоначальных. На практике левую часть формулы обычно вычисляют, представляя ее в виде

$$f'(x) = \delta_{\frac{h}{10}} + \frac{\delta_{\frac{h}{10}} - \delta_h}{99} + O(h^4).$$

## § 5. Обусловленность задачи вычисления корня

Пусть  $\bar{x}$  – корень уравнения

$$f(x) = 0, \quad (5.1)$$

подлежащий определению. Входными данными для задачи вычисления корня  $\bar{x}$  являются значения  $f(x)$  функции  $f$  в малой окрестности корня. В действительности задаваемые значения являются приближенными и их обозначим через  $f^*(x)$ . Ошибки в  $f^*(x)$  связаны не только с неизбежными ошибками округления, но и с используемым для вычисления значений функции  $f$  приближенных методов. Нельзя ожидать, что в окрестности корня относительная погрешность  $\delta(f^*)$  окажется малой. Реально можно ожидать, что малой окажется абсолютная погрешность вычисления значений функции. Предположим, что в достаточно малой окрестности корня выполняется неравенство  $|f(x) - f^*(x)| < \bar{\Delta} = \bar{\Delta}(f^*)$ .

Если функция  $f$  непрерывна, то найдется малая окрестность  $(\bar{x} - \bar{\varepsilon}, \bar{x} + \bar{\varepsilon})$  корня  $\bar{x}$ , имеющая радиус  $\bar{\varepsilon} > 0$ , в которой выполняется неравенство

$$|f(x)| < \bar{\Delta}. \quad (5.2)$$

Будем называть  $x \in (\bar{x} - \bar{\varepsilon}, \bar{x} + \bar{\varepsilon})$  интервалом неопределенности корня  $\bar{x}$ , так как невозможно определить, какое именно значение  $x$  из этого интервала обращает функцию  $f$  в нуль. Найдем оценку величины  $\bar{\varepsilon}$ . Пусть корень  $\bar{x}$  – простой. Для близких к  $\bar{x}$  значений  $x$  справедливо приближенное равенство

$$f(x) \approx f(\bar{x}) + f'(\bar{x})(x - \bar{x}) = f'(\bar{x})(x - \bar{x}).$$

Поэтому неравенство (5.2) примет вид

$$|f'(x)(x - \bar{x})| \lesssim \bar{\Delta}$$

откуда получаем

$$\bar{x} - \frac{\bar{\Delta}}{|f'(\bar{x})|} \lesssim x \lesssim \bar{x} + \frac{\bar{\Delta}}{|f'(\bar{x})|}.$$

Следовательно,

$$\bar{\varepsilon} \approx \nu_{\Delta} * \bar{\Delta}(f^*). \quad (5.3)$$

Здесь  $\nu_{\Delta} = \frac{1}{|f'(\bar{x})|}$  – число, которое в рассматриваемой задаче играет роль абсолютного числа обусловленности. Так как, если  $\bar{x}^*$  – корень уравнения  $f^*(x) = 0$ , то  $f(\bar{x}^*) < \bar{\Delta}$  и тогда выполнено неравенство  $|\bar{x} - \bar{x}^*| \leq \bar{\Delta}(x^*) \leq \bar{\varepsilon} \approx \nu_{\Delta} \bar{\Delta}(f^*)$ . (5.4)

Радиус интервала неопределенности возрастает (обусловленность задачи ухудшается) с уменьшением  $|f'(\bar{x})|$ .

Если  $f'(\bar{x}) = 0$  ( $\bar{x}$  – кратный корень), то формула (5.3) не верна. Пусть кратность корня равна  $m$ . Тогда в силу формулы Тейлора справедливо приближенное равенство

$$f(x) \approx f(\bar{x}) + f'(\bar{x})(x - \bar{x}) + \frac{f''(\bar{x})}{2!}(x - \bar{x})^2 + \dots + \frac{f^{(m)}(\bar{x})}{m!}(x - \bar{x})^m.$$

В последнем равенстве все слагаемые в правой части (кроме последнего), равны нулю:

Поэтому неравенство (5.2) имеет вид

$$\left| \frac{f^{(m)}(\bar{x})}{m!} (x - \bar{x})^m \right| \lesssim \bar{\Delta}.$$

Решая это неравенство, получаем оценку радиуса интервала неопределенности:

$$\bar{\varepsilon} \approx \left| \frac{m!}{f^{(m)}(\bar{x})} \right|^{1/m} * \bar{\Delta}^{\frac{1}{m}}.$$

Отсюда видно, что для корня кратности  $m$  радиус интервала неопределенности пропорционален  $\bar{\Delta}^{\frac{1}{m}}$ , что свидетельствует о плохой обусловленности задачи вычисления кратных корней.

Заменим уравнение (5.1) его равносильным уравнением

$$x = \varphi(x). \quad (5.5)$$

Уравнение (5.5) решаем методом простой итерации

$$x_{n+1} = \varphi(x_n). \quad (5.6)$$

Числовая последовательность (5.6) построена в предположении о возможности точного вычисления значений функции  $\varphi(x)$ . Реальные вычисления на ЭВМ дают приближенные значения  $\varphi^*(x)$ . Поэтому вместо последовательности  $x^{(n)}$  получается последовательность  $\tilde{x}^{(n)}$ , для которой

$$\tilde{x}^{(n+1)} = \varphi^*(\tilde{x}^{(n)}). \quad (5.7)$$

Преобразование уравнения (5.1) к виду (5.5) изменяет обусловленность задачи. Запишем это уравнение в виде  $\tilde{f}(x) = 0$ , где  $\tilde{f}(x) = x - \varphi(x)$ . Заметим, что  $\bar{\Delta}(\tilde{f}^*) = \bar{\Delta}(\varphi^*)$ , поскольку в действительности приближенно вычисляется только функция  $\varphi$ .

Поэтому справедлива оценка [1]:

$$\bar{\Delta}(\bar{x}^*) \leq \nu \bar{\Delta}(\varphi^*), \quad (5.8)$$

где  $\nu = \frac{1}{1 - \varphi'(\bar{x})}$  – абсолютное число обусловленности корня  $\bar{x}$ . Грубо оценив при выполнении условия  $|\varphi'| \leq q < 1$  величину  $\nu$  числом  $\bar{\nu} = \frac{1}{1 - q}$ , приходим к оценке

$$\bar{\Delta}(\bar{x}^*) \leq \frac{\bar{\Delta}(\varphi^*)}{1 - q}. \quad (5.9)$$

В случае, когда  $\varphi' \leq 0$  или  $\varphi' \approx 0$ , нетрудно установить  $\nu \lesssim 1$ , если  $\varphi' \lesssim 0$ . Поэтому имеем

$$\bar{\Delta}(\bar{x}^*) \leq \bar{\Delta}(\varphi^*). \quad (5.10)$$

В оценках (5.8) - (5.10) величины  $\bar{\Delta}(\bar{x}^*)$  и  $\bar{\Delta}(\varphi^*)$  можно заменить на  $\bar{\delta}(\bar{x}^*)$  и  $\bar{\delta}(\varphi^*)$ . Для этого достаточно разделить левую и правую части оценок на величины  $|\bar{x}|$  и  $|\varphi(\bar{x})|$ , которые равны между собой. Например, оценка (5.8) преобразуется к виду

$$\bar{\delta}(\bar{x}^*) \lesssim \nu \bar{\delta}(\varphi^*). \quad (5.11)$$

Замечания А.

1. Задача вычисления корня  $\bar{x}$  уравнения  $x = \varphi(x)$  плохо обусловлена, если  $\varphi'(\bar{x}) \approx 1$ .
2. Для радиуса интервала неопределенности  $\bar{\varepsilon} \approx \nu \bar{\Delta}(\varphi^*)$  корня  $\bar{x}$  в случае  $|\varphi'| \leq q < 1$  справедлива оценка  $\bar{\varepsilon} \leq \bar{\varepsilon}^* = \frac{\bar{\Delta}(\varphi^*)}{1-q}$ .
3. В случае, когда  $-1 < \varphi' \lesssim 0$  уточненная оценка такова:  $\bar{\varepsilon} \lesssim \bar{\varepsilon}^* = \bar{\Delta}(\varphi^*)$  здесь потери верных цифр не произойдет.

Замечания Б.

1. Отметим, что  $\bar{\varepsilon}$  не может быть меньше величины  $|x|\varepsilon_m$  – погрешности представления корня  $\bar{x}$  в ЭВМ.
2. Не имеет смысла ставить задачу о вычислении корня  $\bar{x}$  с точностью  $\varepsilon < \bar{\varepsilon}$ , ибо любое значение  $\bar{x}^* \in (\bar{x} - \bar{\varepsilon}, \bar{x} + \bar{\varepsilon})$  может быть с одной и той же степенью достоверности принять за решение уравнения.
3. Нельзя требовать от алгоритмов отыскания корня получения достоверных результатов после того, как очередное приближение попало в интервал неопределенности. В этом случае следует прекратить вычисления и считать, что получен максимум действительно возможного.
4. Для большинства итерационных методов вдали от интервала неопределенности величина

$$q^{(n)} = \frac{|x^{(n)} - x^{(n-1)}|}{|x^{(n-1)} - x^{(n-2)}|} \quad (5.12)$$

меньше единицы, то появление при некотором  $n$  значения  $q^{(n)} > 1$  свидетельствует о начале «разболтки». В этой ситуации вычисления имеет смысл прервать. Лучшим из полученных приближений следует считать  $x^{(n-1)}$ . Использование для контроля вычислений величины (5.12) называется правилом Гарвика.

## § 6. Распространение ошибок в начальных данных при решении обыкновенных дифференциальных уравнений

Рассмотрим задачу

$$y' = \lambda y, y(0) = y_0, \quad (6.1)$$

решением которой является функция

$$y(x) = y_0 * e^{\lambda x}. \quad (6.2)$$

Задачу (6.1) аппроксимируем явной схемой Эйлера

$$\begin{aligned} u_{n+1} &= u_n + hf(x_n, u_n) = (1 + h\lambda)u_n = \\ &= (1 + h\lambda)^2 u_{n-1} = \dots = (1 + h\lambda)^{n+1} u_0. \end{aligned} \quad (6.3)$$

Приближенное начальное значение  $u_0$  отличается от точного начального значения  $y_0$  либо из-за погрешностей в задании начальных данных, либо из-за ошибок округлений в представлении значения  $y_0$  в машине, либо по обеим причинам сразу. Пусть значение  $y_0$  непредставимо точно в виде машинного числа. Поэтому в реальном начальном значении  $u_0$  содержится ошибка  $e_0 = y_0 - u_0$ .

Выпишем выражение для определения глобальной ошибки  $E_{n+1}$  на  $(n+1)$  шаге интегрирования. Так как

$$\begin{aligned} u_{n+1} &= (1 + h\lambda)^{n+1} u_0 = (1 + h\lambda)^{n+1} (y_0 - e_0), \text{ то} \\ E_{n+1} &= y_{n+1} - u_{n+1} = y_0 * e^{(n+1)h\lambda} - (1 + h\lambda)^{n+1} (y_0 - e_0) = \\ &= (e^{(n+1)h\lambda} - (1 + h\lambda)^{n+1}) y_0 + (1 + h\lambda)^{n+1} e_0. \end{aligned}$$

Таким образом, глобальная ошибка состоит из двух компонент. Первая компонента представляет собой ошибку, вытекающую из аппроксимации значения  $e^{h\lambda}$  выражением  $1 + h\lambda$ , вторая компонента отражает распространение ошибки  $e_0$  в начальном условии. Если  $|1 + h\lambda| > 1$ , то вторая компонента растет при увеличении  $n$  и в конечном счете станет доминирующей частью глобальной ошибки  $E_{n+1}$ . Если  $\lambda < 0$ , то, для того чтобы ограничить распространение ошибки  $e_0$  необходимо обеспечить выполнение условия

$$|1 + h\lambda| < 1 \quad \text{или} \quad h < 2/|\lambda|.$$

Это условие является условием устойчивости явной схемы Эйлера.

Если же  $\lambda > 0$ , то неравенство  $1 + h\lambda > 1$  выполняется для любого  $h > 0$ , т.е. на каждом шаге процесса интегрирования наблюдается увеличение локальных ошибок. Однако на этот раз неустойчивость не столь очевидна, поскольку доминирующей является первая компонента глобальной ошибки  $E_{n+1}$ . Каким бы малым мы ни выбрали шаг  $h$ , разность  $e^{(n+1)h\lambda} - (1 + h\lambda)^{n+1}$  при достаточно большом  $n$  всегда будет превосходить  $(1 + h\lambda)^{n+1}$ . Такого рода задачи называют плохо обусловленными.

В данном случае лучше интегрировать в направлении уменьшения  $x$ , т.е. с отрицательным шагом.



## Литература

- 1.Амосов А. А., Дубинский Ю. А., Копченова Н. В. Вычислительные методы для инженеров. -М.: Высшая школа, 1990. -544с.
- 2.Арушанян О. Б., Залёткин С. Ф. Численное решение обыкновенных дифференциальных уравнений на фортране. -М.: Издательство МГУ, 1990. -336с.
- 3.Бахвалов Н. С., Жидков Н. П., Кобельков Г. М. Численные методы. –М.: БИНОМ. Лаборатория знаний, 2003. -632с.
- 4.Загускин В. Л. Численные методы решения плохо обусловленных задач. Ростов на Дону, издательство РГУ, 1976. -192с.
- 5.Охлопков Н. М., Охлопков Г. Н. Введение в специальность «Прикладная математика». Часть 1. Учебное пособие. –Якутск: издательство ЯГУ, 1997. -93с.
- 6.Охлопков Н. М., Охлопков Г. Н. Вычислительные алгоритмы решения некоторых задач алгебры. –Якутск: издательство ЯГУ, 1996. - 41с.
- 7.Охлопков Н. М., Охлопков Г. Н. Численные методы решения некорректных задач. –Якутск: 2002. -72с.
- 8.Самарский А. А., Вабищевич П. Н. Численные методы решения обратных задач математической физики. М.: Едиториал УРСС, 2004. - 480с.
- 9.Тихонов А. Н., Арсенин В. Я. Методы решения некорректных задач. –М.: Наука, 1974. -222с.
- 10.Тихонов А. Н., Костомаров Д. П. Вводные лекции по прикладной математике. –М.: ФМЛ, 1987. -192с.
- 11.Охлопков Н. М., Иванов Ф. В. Численные методы: теория и практика: учебное пособие. – Якутск: Издательский дом СВФУ. 2016. – 370 с.

## Глава 5. ЧИСЛЕННЫЕ МЕТОДЫ РЕШЕНИЯ НЕКОРРЕКТНЫХ ЗАДАЧ МАТЕМАТИЧЕСКОЙ ФИЗИКИ

### § 1. Понятие о корректно и некорректно поставленных задачах математической физики

#### 1.1. Понятие о корректно и некорректно поставленных задачах

Понятие корректности постановки математической задачи впервые было введено Ж. Адамаром [31] при рассмотрении краевых задач для уравнений с частными производными.

Пусть  $U$  и  $Z$  – некоторые полные метрические функциональные пространства, где введены расстояния:

$$\rho_U(u_1, u_2), \rho_Z(z_1, z_2), \quad u_1, u_2 \in U, z_1, z_2 \in Z.$$

Решение любой количественной задачи состоит в определении элемента  $Z$  (решения задачи) по входным данным и может быть записано в виде:

$$Z = R(u) \tag{1.1}$$

или

$$Az = u,$$

Где  $A$  – некоторый оператор.

Определение 1. Задача определения решения  $z \in Z$  по входным данным  $u \in U$  называется корректно поставленной (корректной по Адамару) на паре множеств  $(U, Z)$ , если выполняются следующие требования:

- 1) для любого  $u \in U$  решение задачи существует;
- 2) для любого  $u \in U$  решение задачи единственно;
- 3) решение задачи  $Z$  непрерывно зависит от входных данных  $U$ , т.е. для любого  $\varepsilon > 0$  можно указать такое  $\delta(\varepsilon)$ , что если

$\rho_U(u_1, u_2) \leq \delta$  и  $z_1 = R(u_1)$ ,  $z_2 = R(u_2)$ , то  $\rho_z(z_1, z_2) \leq \varepsilon$ .

Задачи, не удовлетворяющие этим условиям, называются некорректно поставленными.

Условия 1) и 2) характеризуют математическую определенность рассматриваемой задачи, а условие 3) – физическую детерминированность задачи.

Особенное значение имеет именно третье условие корректности, которое обеспечивает малость изменения решения при малом изменении входных данных. Входными данными выступают коэффициенты уравнения, правая часть, граничные и начальные данные, которые берутся из эксперимента и всегда известны с некоторой погрешностью. Устойчивость решения по отношению к малым возмущениям начальных и граничных условий, коэффициентов и правой части фактически оправдывает саму постановку задачи.

Адамаром и другими исследователями был сделан вывод, что задачи, в которых нарушается условие 3) корректности задачи, неинтересны, так как применение приближенных методов решения к этим задачам весьма затруднительно. Однако многие реальные задачи физики и техники сводятся к некорректно поставленным задачам математической физики.

Обратные задачи возникают при исследовании объектов или процессов, недоступных непосредственному экспериментальному исследованию или требующих материальных затрат. В качестве примера можно привести: астрофизические эксперименты по изучению звезд; исследование внутренних органов человека; эксперименты для проверки качества различных изделий; поиск полезных ископаемых в недрах Земли и т. д. Например, определить место и мощность произошедшего землетрясения по измерениям колебаний на поверхности Земли.

Таким образом, речь идет о задачах, в которых требуется определить причины, если известны полученные в результате наблюдений следствия.

## 1.2. Условная корректность задач

В работах А. Н. Тихонова [26-29] показано, что устойчивость обратной задачи достигается, если дополнительно требовать принадлежность решения к некоторому компактному множеству.

А. Н. Тихоновым введено понятие условной корректности задачи, и метода регуляризации некорректных задач. В определении условной корректности задачи изменяется понятие корректности.

Определение 2. Задачу  $Az = u$  называют условно корректно поставленной, если выполнены следующие условия:

1) априори известно, что решение задачи существует и принадлежит некоторому множеству  $K$  функционального пространства  $Z$ , т. е.

$$z \in K \subset Z;$$

2) решение задачи на множестве  $K$  единственно;

3) решение задачи на множестве  $K$  непрерывно зависит от входных данных  $u$ , т.е. бесконечно малым вариациям (изменениям данных) данных  $u$  задачи, не выводящим решение  $Z$  за пределы множества  $K$ , соответствуют бесконечно малые вариации (изменения) решения  $Z$ .

Множество  $K$  называют множеством корректности, во многом это множество является компактным.

В корректности по А. Н. Тихонову теорема существования не доказывается, существование решения предполагается заданным априори. Предполагается принадлежность решения к некоторому заданному множеству функционального пространства, которое является компактным подмножеством функционального пространства. Доказательство теоремы единственности является центральной задачей в исследовании условно-корректных задач.

Необходимо доказать устойчивость решения задачи, т. е. установить наличие непрерывной зависимости решения от данных на множе-

стве корректности и получить оценку нормы изменения решения через норму изменения данных.

### 1.3. Операторная формулировка некорректных задач

Пусть имеем операторное уравнение

$$Az = u, \quad (1.2)$$

где  $A$  – линейный оператор,  $z, u$  – элементы некоторых метрических пространств  $Z, U$ . Уравнение (1.2) называется операторным уравнением первого рода.

Если для любой функции  $v$  имеет место  $\|Av\| \leq c$ , где  $c$  – ограниченная константа, то говорят, что оператор  $A$  ограничен. Если оператор  $A$  ограничен, то он непрерывен. Норму линейного оператора  $A$  введем следующим образом:

$$\|A\| = \sup_{u \neq 0} \frac{\|Au\|}{\|u\|}, \quad u \in U.$$

Теорема 1. Если обратный оператор  $A^{-1}$  неограничен, то решение уравнения (1.2) неустойчиво.

Оператор  $A$  называется вполне непрерывным оператором, если он любое ограниченное множество переводит в компактное множество.

Множество  $K$  метрического пространства  $X$  называется компактным в пространстве  $X$ , если любое бесконечное подмножество  $K$  имеет хотя бы одну предельную точку, принадлежащую  $X$ . Если предельная точка принадлежит  $K$ , то  $K$  называется компактным в себе множеством.

Теорема 2. Для того чтобы операторное уравнение первого рода (1.2) было некорректным достаточно, чтобы оператор  $A$  был вполне непрерывным.

Теорема 3. Пусть  $A$  – вполне непрерывный оператор с областью определения  $Z$  и с областью значений из  $U$  и  $M \subset Z$  – компактное множество.

Тогда, если решение операторного уравнения (1.2) единственно, то она на множестве  $M$  непрерывно зависит от правой части, т. е. для любого  $\varepsilon > 0$  существует такое  $\delta > 0$ , что для любых  $z_1, z_2 \in Z$  таких, что  $\|Az_1 - Az_2\| \leq \delta$  имеет место оценка  $\|z_1 - z_2\| \leq \varepsilon$

#### 1.4. Понятие метода регуляризации

Некорректно поставленные задачи создают значительные трудности при их приближенном решении.

Как правило, исходные данные прикладных задач известны с некоторой погрешностью. Отыскание неустойчивых решений прикладных задач приводит к тому, что классические методы вычислительной математики могут дать результат, сколь угодно сильно отличающийся от точного решения, при условии, что исходные данные отличаются сколь угодно мало.

Одним из эффективных методов решения некорректно поставленных задач, является метод регуляризации А. Н. Тихонова [26].

Рассмотрим некорректную (в смысле Адамара) задачу

$$Az = u, \quad z \in Z, \quad u \in U \quad (1.3)$$

Пусть вместо точного значения правой части  $u$  имеем ее приближенное значение  $u_\delta$ , для которого  $\rho_U(u, u_\delta) \leq \delta$ . Тогда приближенное решение  $z_\delta$  уравнения

$$Az_\delta = u_\delta \quad (1.4)$$

не может быть определено как точное решение задачи (1.3) с правой частью  $u_\delta$ . Решение  $z_\delta$  может быть определено только с помощью оператора  $A_\alpha$  (зависящего от параметра  $\alpha$ ), значения которого следует взять согласованными с точностью  $\delta$ , входных данных  $u_\delta$ , т. е.  $u_\delta \xrightarrow{\delta \rightarrow 0} u$  приближенное решение  $z_\delta \rightarrow z$ . Задача сводится к решению уравнения

$$A_{\alpha} z_{\alpha\delta} = u_{\delta}, \quad (1.5)$$

т. е. имеем семейство задач, зависящее от параметра  $\alpha$ .

Определение 3. Семейство задач (1.5) называется регуляризованным семейством (регуляризованной задачей), если выполняются следующие условия:

1) для каждого фиксированного значения параметра  $\alpha$  задача (1.5) классически корректна;

2) если данные  $u_{\delta}$  таковы, что решение исходной некорректной задачи существует, то при  $\alpha \rightarrow a$  ( $a$  – некоторое число) последовательность решений задачи (1.5) с этими данными стремится к решению исходной (некорректной) задачи.

Если известно, что  $\rho_U u(u, u_{\delta}) \leq \delta$ , то значение параметра регуляризации  $\alpha$  следует выбрать так, чтобы при  $\delta \rightarrow 0$  регуляризации семейство решений  $z_{\alpha\delta} = R_{\alpha}(A)u_{\delta}$  стремилось к некоторому точному решению  $z$ , т. е.  $\lim z_{\alpha\delta} = z$  при  $\alpha \rightarrow a$  и  $\delta \rightarrow 0$  в метрике  $z$ .

Оператор  $R_{\alpha}(A)$  называется регуляризирующим оператором, а параметр  $\alpha$  – параметром регуляризации. Этот метод широко используется для решения линейных и нелинейных операторных уравнений 1-го рода.

Рассмотрим операторное уравнение 1-го рода

$$Az = u, \quad (1.6)$$

где  $A$  – линейный вполне непрерывный оператор, отображающий  $Z$  в  $U$  ( $Z$  и  $U$  – сепарабельные гильбертовы пространства).

Так как оператор  $A$  вполне непрерывен, то задача решения уравнения (1.6) некорректна.

Пусть для точной правой части  $\bar{u}$  уравнение (1.6) имеет единственное решение  $\bar{z}$ . Но элемент  $\bar{u}$  неизвестен, а имеем его приближен-

ное значение  $u_\delta$  и величину погрешности  $\delta$ :  $\|u_\delta - \bar{u}\| \leq \delta$ . Требуется, зная  $u_\delta$  и  $\delta$ , построить приближенное решение уравнения (1.6)  $z_\delta$ , которое бы сходилось к  $\bar{z}$  при  $\delta \rightarrow 0$ .

Рассмотрим функционал

$$M^\alpha(z) = \|Az - u\|^2 + \alpha\|z\|^2,$$

где  $\alpha$  - положительный параметр.

Справедливы теоремы.

Теорема 4. Для любых  $u \in U$  и  $\alpha > 0$  функционал  $M^\alpha(z)$  достигает своей нижней грани на единственном элементе.

Обозначим через  $z_{\alpha(\delta)}$  элемент, на котором достигается нижняя грань функционала

$$M^{\alpha(\delta)}(z) = \|Az - u_\delta\|^2 + \alpha(\delta)\|z\|^2,$$

где  $\alpha(\delta) > 0$  при  $\delta > 0$ . Из теоремы 4 следует, что элемент  $z_{\alpha(\delta)}$  существует и единственен.

Теорема 5. Если  $\alpha(\delta) > 0$  при  $\delta > 0$ ,  $\alpha(\delta) \rightarrow 0$  и  $\delta^2/\alpha(\delta) \rightarrow 0$  при  $\delta \rightarrow 0$ , то  $\|z_{\alpha(\delta)} - \bar{z}\| \rightarrow 0$  при  $\delta \rightarrow 0$ .

При согласовании скорости стремления к нулю параметра регуляризации  $\alpha(\delta)$  с величиной погрешности  $\delta$  приближенное решение  $z_{\alpha(\delta)}$  сходится к точному решению  $\bar{z}$  при  $\delta \rightarrow 0$ .

На практике погрешность  $\delta$  принимает вполне фиксированное значение. Поэтому важно иметь способ выбора  $\alpha(\delta)$  при заданной величине  $\delta$ , чтобы обеспечивал сходимость  $z_{\alpha(\delta)}$  к  $\bar{z}$  при  $\delta \rightarrow 0$ .

Параметр регуляризации  $\alpha(\delta)$  можно однозначно определить как корень уравнения

$$\|A\bar{z}_\alpha - u_\alpha\| = \delta,$$

где  $\bar{z}_\alpha$  - элемент, на котором достигается нижняя грань функционала



$$\|Az - u_\delta\|^2 + \alpha \|z\|^2.$$

Справедлива

Теорема 6. Для любого  $\delta \in (0, \|u_\delta\|)$  существует единственный корень уравнения

$$\varphi(\alpha) = \|A\bar{z}_\alpha - u_\delta\|^2 = \delta^2,$$

$$\alpha(\delta) \text{ и } \|\bar{z}_{\alpha(\delta)} - \bar{z}\| \rightarrow 0 \text{ при } \delta \rightarrow 0.$$

## § 2. Метод регуляризации М. М. Лаврентьева

Рассмотрим некорректную задачу:

$$\frac{\partial u}{\partial t} = a^2 \frac{\partial^2 u}{\partial x^2}, \quad 0 < x < \pi, \quad 0 \leq t \leq T, \quad (2.1)$$

$$u(x, t) = g(x), \quad 0 \leq x \leq \pi, \quad (2.2)$$

$$u(0, t) = u(\pi, t) = 0. \quad (2.3)$$

Для решения задачи (2.1) – (2.3) построим регуляризованное семейство задач.

Пусть

$$g(x) = \sum_{k=1}^{\infty} g_k \sin kx.$$

Если для функции  $g(x)$  решение задачи (2.1) – (2.3) существует, то оно имеет вид:

$$u(x, t) = \sum_{k=1}^{\infty} g_k e^{k^2 a^2 (T-t)} \sin kx \quad (2.4)$$

Рассмотрим семейство задач

$$\frac{\partial u_n}{\partial t} = a^2 \frac{\partial^2 u_n}{\partial x^2}, \quad (2.5)$$

$$u_n(x, T) = g^{(n)}(x), \quad (2.6)$$

$$u_n(0, t) = u_n(\pi, t) = 0, \quad (2.7)$$

где  $g^{(n)}(x) = \sum_{k=1}^{\infty} g_k \sin kx$ .

Покажем, что задача (2.5) – (2.7) – семейство регуляризованных задач и при каждом фиксированном значении параметра регуляризации  $n$  задача (2.5) – (2.7) классически корректна.

Существование и единственность решения задачи (2.5) – (2.7) следует из (2.4). Покажем устойчивость решения  $u_n(x, t)$ .

Для задачи (2.5) – (2.7), как и для задачи (2.1) – (2.3), получим

$$u(x, t) = \sum_{k=1}^n g_k e^{k^2 a^2 (T-t)} \sin kx. \quad (2.8)$$

Норму функции  $u(x, t)$  определим в виде

$$\|u(x, t)\| = \left\{ \int_0^\pi u^2(x, t) dx \right\}^{1/2}.$$

Тогда имеем

$$\begin{aligned} \|u_n(x, t)\|^2 &= \sum_{k=1}^n g_k^2 e^{2k^2 a^2 (T-t)} \leq \\ &e^{2n^2 a^2 (T-t)} \sum_{k=1}^n g_k^2 \leq e^{2n^2 a^2 (T-t)} \|g^{(n)}(x)\|^2. \end{aligned}$$

Поэтому

$$\|u_n(x, t)\| \leq e^{n^2 a^2 (T-t)} \|g^{(n)}(x)\|.$$

Из этого неравенства следует непрерывная зависимость решения  $u_n(x, t)$  от начального условия  $g^{(n)}(x)$ , т. е. задача (2.5) – (2.7) корректно поставлена. Из формул (2.4) и (2.8) следует сходимость семейства решений  $u_n(x, t)$  к  $u(x, t)$  при  $n \rightarrow \infty$ .

На неустойчивость решения влияют высокие гармоники в разложении

$$g(x) = \sum_{k=1}^{\infty} g_k \sin kx.$$

Смысл регуляризации данного метода заключается в искусственной фильтрации высоких гармоник. Поэтому на практике берут небольшие значения параметра регуляризации  $n$  ( $n = 3; 4; 5$ ).

### § 3. Метод квазиобращения

Рассмотрим семейство задач

$$\frac{\partial u_\alpha}{\partial t} = \frac{\partial^2 u_\alpha}{\partial x^2} - \alpha \frac{\partial^4 u_\alpha}{\partial x^4}, \quad \alpha > 0, \quad 0 < x < \pi, \quad 0 < t \leq T, \quad (3.1)$$

$$u_\alpha(x, T) = g(x), \quad (3.2)$$

$$u_\alpha(0, t) = u_\alpha(\pi, t) = 0, \quad \frac{\partial^2 u_\alpha(0, t)}{\partial x^2} = \frac{\partial^2 u_\alpha(\pi, t)}{\partial x^2} = 0. \quad (3.3)$$

Покажем, что это семейство является регуляризованным семейством задач.

Решение задачи (3.1) – (3.3) находим методом разделения переменных. Это решение имеет вид:

$$u_\alpha(x, t) = \sum_{k=1}^{\infty} g_k e^{(k^2 - \alpha k^4)(T-t)} \sin kx = R_\alpha(A)g(x). \quad (3.4)$$

Покажем, что при фиксированном значении  $\alpha$  норма  $\|R_\alpha(A)\|$  ограничена. Вычислим норму для  $u_\alpha(x, t)$ :

$$\|u_\alpha(x, t)\|^2 = \sum_{k=1}^{\infty} g_k^2 e^{2(k^2 - \alpha k^4)(T-t)}.$$

Найдем

$$\max_{k^2} f(k^2) = \max(k^2 - \alpha k^4) = \frac{1}{4\alpha}.$$

Тогда

$$\|u_\alpha(x, t)\|^2 = e^{\frac{T-t}{2\alpha}} \sum_{k=1}^{\infty} g_k^2 = e^{\frac{T-t}{2\alpha}} \|g(x)\|^2.$$

Отсюда

$$\|u_\alpha(x, t)\| \leq \|R_\alpha(A)\| \|g(x)\| = e^{\frac{T-t}{4\alpha}} \|g(x)\|.$$

Здесь норма  $\|R_\alpha(A)\| = e^{\frac{T-t}{4\alpha}}$  и ограничена, если  $\alpha$  - величина конечная.

Из (2.4) и (3.4) следует, что  $u_\alpha(x, t) \rightarrow u(x, t)$ , при  $\alpha \rightarrow 0$ .

Оптимальное значение  $\alpha_{\text{опт}} = \alpha_0$  выбирается из решения уравнения:

$$2 \cdot e^{\frac{T-t}{4\alpha_0}} \cdot \delta = \varepsilon$$

или

$$2 \frac{\alpha_0}{t} \cdot \frac{T-t}{t} = \varepsilon,$$

где  $\varepsilon$  - требуемая точность нахождения приближенного решения задачи (2.1) – (2.3),  $\delta$  - точность задания начального условия  $\|g_\alpha(x) - g(x)\| \leq \delta$ .

#### § 4. Приближенные методы решения некорректных задач

Некорректные задачи обычно рассматриваются применительно к линейному операторному уравнению первого рода

$$Au = f. \quad (4.1)$$

Пусть  $u \in H$ ,  $f \in F$  – гильбертовы пространства,  $A$  – вполне непрерывный оператор.

Некорректно поставленные задачи создают значительные трудности при их приближенном решении.

Как правило, исходные данные прикладных задач известны с некоторой погрешностью. Отыскание неустойчивых решений прикладных задач приводит к тому, что классические методы вычислительной математики могут дать результат, сколь угодно сильно отличающийся от точного решения, при условии, что исходные данные отличаются сколь угодно мало.

Применяя к обеим частям уравнения (4.1), сопряженный к  $A$  оператор  $A^*$ , приходим к уравнению

$$A^*Au = A^*f \quad (4.2)$$

(симметризация Гаусса). Оператор  $A^*A$  самосопряжен и неотрицателен.

Метод М. М. Лаврентьева применяют для решения некорректно поставленных задач с самосопряженными неотрицательными операторами. Будем считать, что в уравнении (4.1)  $A = A^* \geq 0$ . Метод М. М. Лаврентьева заключается в переходе к регуляризованному уравнению

$$\alpha u + Au = f, \quad (4.3)$$

где  $\alpha$  - малый положительный параметр, параметр регуляризации. Задача (4.3) корректна и некорректная задача (4.1) вкладывается в семейство корректных как предельный случай при  $\alpha \rightarrow 0$ .

Задачу (4.3) можно решить любым прямым методом с итерационным уточнением.

Можно использовать итеративную модификацию метода М. М. Лаврентьева. Зафиксируем натуральное число  $p \geq 1$ . Пусть  $u_0$  - некоторое априори, известное приближение к решению уравнения (4.1). Положим  $u_{0,\alpha} = u_0$ , последовательно вычислим  $u_{1,\alpha}, \dots, u_{p,\alpha}$  как решения уравнений

$$\alpha u_{s,\alpha} + Au_{s,\alpha} = \alpha u_{s-1,\alpha} + f \quad (s = \overline{1, p}). \quad (4.4)$$

В качестве приближенного решения уравнения (4.1) примем элемент  $u_{p,\alpha}$ . Заметим, что в случае  $p = 1, u_0 = 0$  имеем дело с методом (4.3).

Метод А. Н. Тихонова применим к системе линейных алгебраических уравнений в ее общей постановке (без условия самосопряженности)

$$Ax = b. \quad (4.5)$$

В общей постановке некорректной задачи (4.1) рассмотрим как совместную неопределенную систему линейных уравнений  $A = (a_i^j)_n^m$ ,  $x = (x_j)_n$ ,  $b = (b^i)_m$ . Такая система имеет бесконечно много решений. Поэтому надо ввести дополнительное условие, чтобы задача стала определенной.

Во многих прикладных задачах таким условием является требование, чтобы длина вектора решения  $x$  была минимальной среди всех решений этой системы, т. е. чтобы скалярное произведение  $(x, x)$  было минимальным. Такое решение системы (4.5) называется нормальным и обозначается  $x_H$ . Вычисление на ЭВМ минора матрицы  $A$ , равного нулю, обычно приводит к результату отличному от нуля даже при малых ошибках округления. В такой ситуации совершенно не ясно, какой минор нужно считать базисным минором матрицы  $A$ . Алгоритм становится некорректным.

Для решения некорректных математических задач предложен А. Н. Тихоновым метод регуляризации. Метод регуляризации основан на решении не исходной задачи, которая является неустойчивой (или неопределенной), а близкой к ней вспомогательной, содержащей некоторый положительный параметр регуляризации  $\alpha$ . После этого новая задача оказывается устойчивой (или однозначно разрешимой) для любого выбора положительного параметра  $\alpha$ . Предполагая, что в линейном пространстве  $R^n$  и  $R^m$  введено скалярное произведение, перепишем систему (4.5) в эквивалентной форме:

$$(Ax - b, Ax - b) = 0. \quad (4.6)$$

Регуляризованная задача формулируется так:

найти решение  $x_\alpha$ , зависящее от  $\alpha$ , при котором функционал

$$F_\alpha(x) = (Ax - b, Ax - b) + \alpha(x, x), \quad (4.7)$$

где  $\alpha > 0$ , является минимальным, и выбрать параметр  $\alpha$  так, чтобы регуляризованное значение  $x_\alpha$  было «наиболее близким» к нормальному решению  $x_H$  системы (4.5). Регуляризирующий функционал  $F_\alpha(x)$  запишем, вычисляя скалярное произведение в ортонормированном базисе

$$F_\alpha(x) = \sum_{i=1}^m (a_i^j x^j - b^i)^2 + \alpha \sum_{j=1}^n (x^j)^2. \quad (4.8)$$

Должно выполняться необходимое условие минимума функции:

$$F_\alpha(x) = F_\alpha(x^1, x^2, \dots, x^n),$$

поэтому имеем

$$\frac{\partial F_\alpha}{\partial x^j} = 2 \sum_{i=1}^m (a_i^j x^j - b^i) a_i^j + 2\alpha x^j = 0, \quad j = \overline{1, n}. \quad (4.9)$$

Равенство (4.9) в матричной форме имеет вид:

$$(A^T A + \alpha E)x = A^T b, \quad \alpha > 0. \quad (4.10)$$

Таким образом, решение неопределенной системы (4.5) сведено к решению однозначно разрешимой системы (4.10). Решение этой системы можно найти, используя прямые или итерационные методы решения корректных задач.

Таким образом, простейший вариант метода А. Н. Тихонова заключается в отыскании точки минимума функционала

$$F_\alpha(x) = \alpha \|x\|_{R^n}^2 + \|Ax - b\|_{R^n}^2, \quad x \in R^n, \quad (4.11)$$

где  $\alpha$  - малый положительный параметр.

Эта задача на минимум равносильна определению  $x$  из уравнения  $\alpha x + A^* A x = A^* b$ .

$$(4.12)$$

Рассмотрим исходную некорректную задачу (4.1). Предположим, что правая часть уравнения (4.1) задана с погрешностью

$$\|f_\delta - f\| \leq \delta. \quad (4.13)$$

Ей соответствует некоторое приближенное решение, которое обозначим  $u_\delta$ , причем  $\alpha = \alpha(\delta)$ .

Для приближенного решения задачи (4.1) используются вариационные методы. В соответствии с методом регуляризации А. Н. Тихонова вводится сглаживающий функционал

$$J_\alpha(v) = \|Av - f_\delta\|^2 + \alpha\|v\|^2. \quad (4.14)$$

Приближенное решение исходной задачи (4.1), (4.13) есть экстремаль этого функционала

$$J_\alpha(u_\alpha) = \min_{v \in H} J_\alpha(v). \quad (4.15)$$

В (4.15)  $\alpha > 0$  – параметр регуляризации, величина которого согласуется с погрешностью задания правой части  $\delta$ .

Вместо экстремальной задачи (4.14), (4.15) можно решить соответствующее уравнение Эйлера. В этом случае приближенное решение определяется из решения уравнения второго порядка

$$A^*Au_\alpha + \alpha u_\alpha = A^*f_\delta. \quad (4.16)$$

Переход от некорректной задачи (4.1) к корректной задаче (4.16) осуществляется за счет перехода к задаче с самосопряженным оператором  $A^*A$ , доумножая (4.1) слева на  $A^*$ , и его последующим возмущением оператором  $\alpha I$ ,  $I$  – тождественный оператор. При  $A^* = A \geq 0$  можно ограничиться возмущением самого оператора:

$$Au_\alpha + \alpha u_\alpha = f_\delta \quad (4.17)$$

Задача (4.17) соответствует использованию упрощенной регуляризации. Таким образом, второй класс приближенных методов решения неустойчивых задач характеризуется возмущением оператора исходной или преобразованной задачи.

Наряду с описанным вариантом метода А. Н. Тихонова (4.16) можно применять его итерированный вариант. Зададим начальное при-



ближение  $u_{0,\alpha} = u_0 \in H$  где натуральное число  $p \geq 1$  и последовательно вычислим  $u_{1,\alpha}, \dots, u_{p,\alpha}$  по формулам:

$$\alpha u_{s,\alpha} + A^* A u_{s,\alpha} = \alpha u_{s-1,\alpha} + A^* f_\delta, \quad s = \overline{1, p}. \quad (4.18)$$

Элемент  $u_{p,\alpha}$  примем за приближенное решение уравнения (4.1).

Выше регуляризация некорректной задачи достигалась ее включением, как некоторого предельного случая ( $\alpha = 0$ ), в семейство корректно поставленных задач. Теперь обратимся к итерационным методам регуляризации. Параметром регуляризации в них является номер итерации. Дадим описание простейших итерационных методов сперва в самосопряженном случае, т. е.  $A = A^* \geq 0$ . Зададимся начальным приближением  $u_0 \in H$ , его разумно брать ближе к искомому точному решению (4.1). При отсутствии всякой информации о точном решении можно положить  $u_0 = 0$ . По  $u_0$  последовательно вычислим

$$u_s = u_{s-1} - \mu(Au_{s-1} - f_\delta), \quad (4.19)$$

где  $\mu > 0$  - постоянная.

Другая итерационная схема:

$$\alpha u_s + Au_s = \alpha u_{s-1} + f_\delta, \quad s = 1, 2, \dots \quad (\alpha = \text{const} > 0). \quad (4.20)$$

Каждый шаг итерации заключается в решении корректно поставленной задачи. Постоянная  $\alpha$  здесь не обязательно мала. Регуляризация достигается за счет многократного итерирования.

Стоит обратить внимание на формальное сходство итерационного метода (4.20) с итерационным вариантом метода М. М. Лаврентьева (4.4).

Однако регуляризация в этих двух методах достигается по-разному: в итерационном варианте метода М. М. Лаврентьева за счет малости  $\alpha$  при фиксированном числе итераций, а в итерационном методе (4.20) – за счет большого числа итераций при фиксированном  $\alpha$ .

В общем случае несамосопряженную задачу (4.1) предварительно симметризируем (переходим от задачи (4.1) к задаче (4.20) и затем применим те же итерационные схемы, что и выше. Таким образом, приходим к итерационным схемам:

$$u_s = u_{s-1} - \mu A^*(Au_{s-1} - f_\delta), \quad s = 1, 2, \dots$$

$$0 < \mu < 2/\|A\|^2, \quad (4.21)$$

$$\alpha u_s + A^*Au_s = \alpha u_{s-1} + A^*f_\delta, \quad s = 1, 2, \dots (\alpha = \text{const} > 0). \quad (4.22)$$

Схемы (4.19) и (4.21) называются явными итерационными схемами, а схемы (4.20) и (4.22) – неявными.

Рассмотренные выше итерационные алгоритмы можно трактовать как разностные схемы решения задачи Коши. В самосопряженном случае

$$(H = F, A = A^* \geq 0) \text{ речь идет о задаче Коши}$$

$$u'(t) + Au(t) = f, \quad u(0) = u_0. \quad (4.23)$$

Пусть  $\tau$  - шаг по времени,  $u_k = u(k\tau)$ ,  $k = 0, 1, \dots$ . Аппроксимируем производную  $u'(t)$  разностной производной  $\frac{u_k - u_{k-1}}{\tau}$ , можно написать следующие две разностные схемы для задачи (4.23):

$$\frac{u_k - u_{k-1}}{\tau} + Au_{k-1} = f, \quad k = 1, 2, \dots \text{ – явная схема Эйлера;}$$

$$\frac{u_k - u_{k-1}}{\tau} + Au_k = f, \quad k = 1, 2, \dots \text{ – неявная схема Эйлера.}$$

При  $\tau = \mu$  явная разностная схема Эйлера превращается в итерационную схему (4.19), а при  $\tau = \frac{1}{\alpha}$  неявная разностная схема – в итерационную схему (4.20).

В общем случае двухслойный итерационный метод для уравнения (4.1) записывается в виде:

$$B \frac{u_{k+1} - u_k}{\tau_{k+1}} + Au_k = f_\delta, \quad k = 0, 1, \dots, n(\delta). \quad (4.24)$$

Здесь  $B: H \rightarrow H$  и  $B^{-1}$  существует.

В итерационном алгоритме (4.24) эффект регуляризации при приближенном решении задачи (4.1), (4.13) достигается за счет согласования с погрешностью правой части  $\delta$  числа итераций  $n(\delta)$ . Таким образом, в качестве параметра регуляризации выступает число итераций итерационного алгоритма.

## § 5. Уравнение теплопроводности с обратным временем

Рассмотрим уравнение

$$\frac{\partial u}{\partial t} + \frac{\partial}{\partial x} \left( k(x) \frac{\partial u}{\partial x} \right) - C(x)u = 0, \quad 0 < x < l, t > 0, \quad (5.1)$$

с условиями

$$u(0, t) = 0, \quad u(l, t) = 0, \quad (5.2)$$

$$u(x, 0) = u_0(x) \quad (5.3)$$

Задачу (5.1) – (5.3) сформулируем в виде эволюционной обратной задачи для уравнения первого порядка для  $u(t) \in H = L_2(0, l)$

$$\frac{\partial u}{\partial t} - Au = 0, \quad 0 < t < T, \quad (5.4)$$

$$u(0) = u_0, \quad (5.5)$$

где  $A > 0$ . Задача (5.4), (5.5) некорректна в классическом смысле, т. е. нет устойчивости решения по начальным данным. Однако в классе ограниченных решений устойчивость уже имеет место.

Вариационному методу (4.14), (4.15) соответствует решение задачи оптимального управления для уравнения (5.4). Задача оптимального управления для задачи (5.4), (5.5) можно сформировать следующим образом.

Пусть  $v \in H$  - управление и ограничений на управление нет. Определим  $u_\alpha = u_\alpha(t; v)$  как решение корректной задачи

$$\frac{\partial u_\alpha}{\partial t} - Au_\alpha = 0, \quad 0 < t < T, \quad (5.6)$$

$$u_\alpha(T; v) = v. \quad (5.7)$$

Квадратичный функционал качества или сглаживающий функционал возьмем в виде:

$$J_\alpha(v) = \|u_\alpha(0; v) - u_0\|^2 + \alpha \|v\|^2, \quad (5.8)$$

который согласуется с (4.14).

Оптимальное управление  $\omega$  определяется как минимум функционала  $J_\alpha(v)$ :

$$J_\alpha(\omega) = \min_{v \in H} J_\alpha(v), \quad (5.9)$$

решение задачи (5.6), (5.7)  $u_\alpha(T, \omega)$  рассматривается как приближенное решение некорректной задачи (5.4), (5.5).

Для задачи (5.4), (5.5) отметим используемые варианты метода квазиобращения, основанные на возмущении исходного уравнения (5.4).

Распространенный вариант квазиобращения связан с определением приближенного решения  $u_\alpha(t)$  из уравнения

$$\frac{\partial u_\alpha}{\partial t} - Au_\alpha + \alpha A^* Au_\alpha = 0. \quad (5.10)$$

Другой вариант метода квазиобращения для задачи (5.4), (5.5) с  $A^* = A$  основан на псевдопараболическом возмущении уравнения

$$\frac{\partial u_\alpha}{\partial t} - Au_\alpha + \alpha A \frac{\partial u_\alpha}{\partial t} = 0. \quad (5.11)$$

Другой класс методов квазиобращения для приближенного решения некорректных эволюционных задач связан с возмущением не уравнения, а начальных условий. Локальное начальное условие заменяется нелокальным условием. Например, приближенное решение задачи (5.4), (5.5) определим как решение уравнения (5.6) с нелокальным начальным условием

$$u_\alpha(0) + \alpha u_\alpha(T) = u_0 \quad (5.12)$$

Введение в класс корректности осуществляется за счет связи решения на начальный и конечный моменты времени.

## § 6. Выбор параметра регуляризации

В теории методов приближенного решения некорректных задач вопросу выбора параметра регуляризации уделяется значительное внимание. Наибольшее распространение получили: выбор параметра регуляризации по невязке, обобщенной невязке, квазиоптимальный выбор и т. д.

Параметр регуляризации  $\alpha$  согласовывается с погрешностью входных данных и чем меньше погрешность, тем меньше берется параметр регуляризации, т. е.  $\alpha = \alpha(\delta)$ .

При выборе параметра регуляризации по невязке в качестве определяющего уравнения выступает равенство

$$\|Au_\alpha - f_\alpha\| = \delta. \quad (6.1)$$

Сходимость приближенного решения  $u_\alpha$  с  $\alpha = \alpha(\delta)$  при  $\delta \rightarrow 0$  к точному решению уравнения (4.1), дано для многих классов задач. Коротко рассмотрим только вычислительные особенности реализации такого способа определения параметра регуляризации.

Невязка зависит от параметра регуляризации  $\alpha$ . Обозначим  $\varphi(\alpha) = \|Au_\alpha - f_\alpha\|$ , тогда нахождение параметра регуляризации состоит в соответствии с принципом невязки (6.1) в решении уравнения

$$\varphi(\alpha) = \delta. \quad (6.2)$$

В достаточно общих условиях функция  $\varphi(\alpha)$  является неубывающей и уравнение (6.2) имеет решение.

Для приближенного решения уравнения (6.2) используются различные вычислительные процедуры. Например, используется последовательность

$$\alpha_k = \alpha_0 q^k, \quad q > 0 \quad (6.3)$$

и вычисления проводятся начиная с  $k = 0$  и до некоторого  $k = N$ , при котором равенство (6.2) с приемлемой точностью выполняется.

В данном случае требуется  $N + 1$  вычислений невязки (решений вариационных задач типа (4.14), (4.15) или уравнений Эйлера (4.16)).

Для приближенного решения уравнения (6.2) можно использовать и более быстро сходящиеся итерационные методы. Установлено, что

$$\psi(\beta) = \varphi(1/\beta)$$

функция является убывающей и выпуклой функцией. Поэтому для решения уравнения

$$\psi(\beta) = \delta$$

можно использовать итерационный метод Ньютона

$\beta_{k+1} = \beta_k - \frac{\psi(\beta_k) - \delta}{\psi'(\beta_k)}$ ,  $\beta_0 > 0$  - начальное приближение. Для того, чтобы не вычислять производную функции  $\psi(\beta)$ , можно использовать итерационный метод секущих

$$\beta_{k+1} = \beta_k - \frac{\beta_k - \beta_{k-1}}{\psi(\beta_k) - \psi(\beta_{k-1})} (\psi(\beta_k) - \delta),$$

где  $\beta_0, \beta_1$  – начальные приближения.

В силу того, что оценки погрешности задания входных данных (типа (4.13)) часто неизвестны, плохо контролируемы, использование хорошо апробированного и теоретически отработанного метода невязки затруднительно. Поэтому в вычислительной практике широкое распространение получил второй способ определения параметра регуляризации – квазиоптимальное значение параметра регуляризации. Такой выбор напрямую не связан с уровнем погрешностей  $\delta$ . Выбирается значение  $\alpha > 0$ , которое минимизирует функцию

$$\mathfrak{x}(\alpha) = \left\| \alpha \frac{du_\alpha}{d\alpha} \right\|. \quad (6.4)$$

Для нахождения квазиоптимального значения чаще всего используется последовательность (6.3). Минимизация (6.4) на таких значениях параметра регуляризации соответствует поиску минимума

$$\bar{\alpha}(\alpha_{k+1}) = \|u_{\alpha_{k+1}} - u_{\alpha_k}\|.$$

Тем самым необходимо проводить оценку лишь нормы разности приближенных решений на двух соседних итерациях. При каждом значении итерационного параметра решается задача (4.14), (4.15) или эквивалентное уравнение (4.16). При промежуточных значениях параметра регуляризации нет особого смысла в очень точном решении таких задач. Поэтому можно комбинировать нахождение решения задачи (4.14) с выбором параметра регуляризации. Близкая идея реализована в итерационных методах решения некорректных задач за счет объединения функций итерационного параметра и параметра регуляризации.

## § 7. Численная реализация метода квазиобращения

1. Постановка начальной обратной задачи для одномерного уравнения теплопроводности

$$\frac{\partial u}{\partial t} = a^2 \frac{\partial^2 u}{\partial x^2} + f(x, t), \quad 0 < x < l, \quad 0 < t \leq T, \quad (7.1)$$

с начальным условием

$$u(x, T) = u_T(x) \quad (7.2)$$

и краевыми условиями

$$u(0, t) = \mu_1(t), \quad u(l, t) = \mu_2(t). \quad (7.3)$$

Требуется восстановить начальное условие

$$u(x, 0) = u_0(x).$$

Задача (7.1) – (7.3) поставлена некорректно – нет устойчивости по начальным данным.

Построим разностную схему для исходной задачи (7.1) – (7.3). Уравнение (7.1) заменяем уравнением

$$\frac{\partial v}{\partial t} = a^2 \frac{\partial^2 v}{\partial x^2} + \varepsilon^2 \frac{\partial^4 v}{\partial x^4} + f(x, t), \quad 0 < x < l, \quad 0 < t \leq T \quad (7.4)$$

с дополнительным условием (7.2) и краевыми условиями (7.3) и

$$\frac{\partial^2 v}{\partial x^2} = 0, \quad x = 0, \quad \frac{\partial^2 v}{\partial x^2} = 0, \quad x = l, \quad (7.5)$$

$\varepsilon$  – малое положительное число.

Введем замену  $t_1 = T - t$ ,  $t = T - t_1$ .

Тогда имеем задачу:

$$\begin{aligned} \frac{\partial v}{\partial t_1} &= -a^2 \frac{\partial^2 v}{\partial x^2} - \varepsilon^2 \frac{\partial^4 v}{\partial x^4} - f(x, t), \\ v(x, 0) &= u_T(x), \quad v(0, t_1) = \mu_1, \quad u(l, t_1) = \mu_2(t_1), \\ \frac{\partial^2 v}{\partial x^2} &= 0, \quad x = 0; \quad \frac{\partial^2 v}{\partial x^2} = 0, \quad x = l. \end{aligned} \quad (7.6)$$

Для разностной аппроксимации этой задачи введем разностную сетку:

$$\begin{aligned} \bar{\omega}_h &= \{x_i = ih, \quad i = \overline{0, n}, \quad h = \frac{l}{n}\}, \quad \bar{\omega}_\tau = \{t_j = j\tau, \quad j = \overline{0, J_0}, \quad \tau = \frac{T}{J_0}\}, \\ \bar{\omega}_{h\tau} &= \bar{\omega}_h \times \bar{\omega}_\tau. \end{aligned}$$

Задача (7.6) аппроксимируется пятиточечной разностной схемой, которая решается пятиточечной прогонкой. Например, простейшая неявная схема имеет вид:

$$\begin{aligned} \frac{y_i^{j+1} - y_i^j}{\tau} &= -a^2 \Delta y^{j+1} - \varepsilon^2 \frac{y_{i-2}^{j+1} - 4y_{i-1}^{j+1} + 6y_i^{j+1} - 4y_{i+1}^{j+1} + y_{i+2}^{j+1}}{h^4} - f_i^{j+1}, \\ y_i^0 &= u_T(x_i), \quad y_0^{j+1} = \mu_1^{j+1}, \quad y_n^{j+1} = \mu_2^{j+1}, \\ y_0^{j+1} &= \mu_1^{j+1}, \quad y_n^{j+1} = \mu_2^{j+1}, \\ \frac{y_0^{j+1} - 2y_1^{j+1} + y_2^{j+1}}{h^2} &= 0, \quad \frac{y_{n-2}^{j+1} - 2y_{n-1}^{j+1} + y_n^{j+1}}{h^2} = 0. \end{aligned} \quad (7.7)$$

Схема (7.7) сводится к стандартному виду [24]:

$$\begin{aligned} c_0 y_0 - d_0 y_1 + e y_2 &= f_0, \quad i = 0, \\ -b_1 y_0 + c_1 y_1 - d_1 y_2 + e y_3 &= f_1, \quad i = 1, \\ a_i y_{i-2} - b_i y_{i-1} + c_i y_i - d_i y_{i+1} + e y_{i+2} &= f_i, \quad 2 \leq i \leq n-2, \\ a_{n-1} y_{n-3} - b_{n-1} y_{n-2} + c_{n-1} y_{n-1} - d_{n-1} y_n &= f_{n-1}, \quad i = n-1, \\ a_n y_{n-2} - b_n y_{n-1} + c_n y_n &= f_n, \quad i = n. \end{aligned} \quad (7.8)$$



Алгоритм правой прогонки имеет вид [24]:

1) по формулам:

$$\begin{aligned}
 \alpha_1 &= \frac{d_0}{c_0}, \quad \alpha_2 = \frac{1}{\Delta_1} (d_1 - \rho_1 b_1), \\
 \alpha_{i+1} &= \frac{1}{\Delta_i} [d_i + \beta_i (a_i \alpha_i - b_i)], \quad i = \overline{2, n-1}, \\
 \gamma_{i+1} &= \frac{1}{\Delta_i} [f_i - a_i \gamma_{i-1} - \gamma_i (a_i \alpha_{i-1} - b_i)], \quad i = \overline{2, n}, \\
 \gamma_1 &= \frac{t_0}{c_0}, \quad \gamma_2 = \frac{1}{\Delta_1} (t_1 + b_1 \gamma_1), \\
 \beta_{i+1} &= \frac{l_i}{\Delta_i}, \quad i = \overline{1, n-2}, \quad \beta_1 = \frac{l}{c_0},
 \end{aligned} \tag{7.9}$$

где  $\Delta_i = c_i - a_i \beta_{i-1} + \alpha_i (a_i \alpha_{i-1} - b_i)$ ,  $i = \overline{2, n}$ ,  $\Delta_i = c_i - b_i \alpha_1$

находятся прогоночные коэффициенты  $\alpha_i, \beta_i, \gamma_i$ ;

2) неизвестные  $y_i$  находятся последовательно по формулам

$$\begin{aligned}
 y_i &= \alpha_{i+1} y_{i+1} - \beta_{i+1} y_{i+2} + \gamma_{i+1}, \quad i = \overline{n-2, 0} \\
 y_{n-1} &= \alpha_n y_n + \gamma_n, \\
 y_n &= \gamma_{n+1}.
 \end{aligned} \tag{7.10}$$

Справедлива лемма [24]:

Пусть коэффициенты системы (7.8) удовлетворяют условиям

$$\begin{aligned}
 |a_i| &> 0, \quad 2 \leq i \leq n, \quad |b_i| > 0, \quad 1 \leq i \leq n, \\
 |d_i| &> 0, \quad 0 \leq i \leq n-1, \quad |e_i| > 0, \quad 0 \leq i \leq n-2,
 \end{aligned}$$

и условиям

$$\begin{aligned}
 |c_0| &\geq |d_0| + |e_0|, \quad |c_1| \geq |b_1| + |d_1| + |e_1|, \\
 |c_n| &\geq |a_n| + |b_n|, \quad |c_{n-1}| \geq |a_{n-1}| + |b_{n-1}| + |d_{n-1}|, \\
 |c_i| &\geq |a_i| + |b_i| + |d_i| + |e_i|, \quad 2 \leq i \leq n-2.
 \end{aligned}$$

причем хотя бы в одном из неравенств достигается строгое неравенство. Тогда алгоритм прогонки корректен и, кроме того, имеет место неравенство:

$$|d_i| + |\beta_i| \leq 1, \quad 1 \leq i \leq n-1, \quad |\alpha_n| \leq 1.$$

## § 8. Метод расщепления для схемы квазиобращения

Во избежание пятиточечной прогонки задачу (7.6) расщепим на две задачи [20]:

$$\begin{cases} \frac{\partial v_1}{\partial t_1} = -a^2 \frac{\partial^2 v}{\partial x^2} + f(x, t), \quad 0 < x < l, \quad t_j < t \leq t_{j+1}, \\ v_1(x, 0) = u_T(x), \quad v_1(x, t_j) = v_2(x, t_j), \\ v_1(0, t) = \mu_1(t), \quad v_1(l, t) = \mu_2(t); \end{cases} \quad (8.1_1)$$

$$\begin{cases} \frac{\partial v_2}{\partial t_1} = -\varepsilon^2 \frac{\partial^4 v_2}{\partial x^4}, \quad 0 < x < l, \quad t_j < t \leq t_{j+1}, \\ v_2(x, t_1^j) = v_1(x, t_1^{j+1}), \\ \frac{\partial^2 v_2}{\partial x^2} = 0, \quad x = 0; \quad \frac{\partial^2 v_2}{\partial x^2} = 0, \quad x = l, \\ v_2(0, t_1) = \mu_1(t_1), \quad v_2(l, t_1) = \mu_2(t_1). \end{cases} \quad (8.1_2)$$

Для разностной аппроксимации задачи (8.1<sub>1</sub>) – (8.1<sub>2</sub>) введем сетку:

$$\bar{\omega}_h = \left\{ x_i = i * h, \quad i = \overline{0, n}, \quad h = \frac{l}{n} \right\}, \quad \bar{\omega}_\tau = \left\{ t_j = j * \tau, \quad j = \overline{0, J_0}, \quad \tau = \frac{\tau}{j_0} \right\},$$

$$\bar{\omega}_{h\tau} = \bar{\omega}_h \times \bar{\omega}_\tau.$$

На этой сетке разностные схемы, аппроксимирующие задачи (7.9<sub>1</sub>) – (7.9<sub>2</sub>) имеют вид:

$$\begin{cases} \frac{y_i^{j+1} - y_i^j}{\tau} = -a^2 \Delta y^{j+1} + f(x_i, t_{j+1}), \\ y_i^0 = u_t(x_i), \quad y_i^j = z_i^j, \\ y_0^{j+1} = \mu_1^{j+1}, \quad y_n^{j+1} = \mu_2^{j+1}; \end{cases} \quad (8.2_1)$$

$$\begin{cases} \frac{z_i^{j+1} - z_i^j}{\tau} = -\frac{\varepsilon^2}{h^4} \delta^4 z_i^{j+1}, \\ z_0^{j+1} = \mu_1^{j+1}, \quad z_n^{j+1} = \mu_2^{j+1}, \quad z_i^j = y_i^{j+1}, \\ \frac{z_0^{j+1} - 2z_1^{j+1} + z_2^{j+1}}{h^2} = 0, \quad \frac{z_{n-2}^{j+1} - 2z_{n-1}^{j+1} + z_n^{j+1}}{h^2} = 0. \end{cases} \quad (8.2_2)$$

Схема (7.10<sub>1</sub>) реализуется трехточечной прогонкой, а схема (7.10<sub>2</sub>) – пятиточечной прогонкой.

Чтобы упростить реализацию схемы (7.10<sub>2</sub>), используем прием расщепления разностного оператора 4-го порядка на два оператора 2-го порядка [20]. После этого вычислительная схема имеет вид:

$$\begin{aligned} \tilde{z}_i^{j+1} &= y_i^{j+1} - \varepsilon \frac{\sqrt{\tau}}{h^2} (y_{i-1}^{j+1} - 2y_i^{j+1} + y_{i+1}^{j+1}), \\ z_j^{j+1} &= \tilde{z}_j^{j+1} - \varepsilon \frac{\sqrt{\tau}}{h^2} (\tilde{z}_{i-1}^{j+1} - 2\tilde{z}_i^{j+1} + \tilde{z}_{i+1}^{j+1}), \\ z_0^{j+1} &= \mu_1^{j+1}, \tilde{z}_n^{j+1} = \mu_2^{j+1}, z_0^{j+1} = \mu_1^{j+1}, z_n^{j+1} = \mu_2^{j+1}. \end{aligned} \quad (8.3)$$

Теперь не нужны дополнительные условия, используемые в методе квазиобращения. Схема (7.10<sub>1</sub>) реализуется трехточечной прогонкой, а схема (7.11) – явно.

Задача для тестовых расчетов.

$$\begin{aligned} f(x, t) &= ABe^{B(x+t)}[1 - a^2B], \quad a^2 > 0, \quad A = 2, \quad B = \{-1; 1\}, \\ T &= 1, \quad l = 1, \quad a = 10, \quad \mu_1 = Ae^{Bt}, \quad \mu_2 = Ae^{B(l+t)}, \quad u_T = Ae^{B(x+T)}. \end{aligned}$$

Точное решение:  $u = Ae^{B(x+t)}$ .

## § 9. Псевдопараболическая регуляризация

Второй рассматриваемый вариант метода квазиобращения связан с переходом к псевдопараболическому уравнению. Тогда уравнение

$$\frac{\partial u}{\partial t} = \frac{\partial^2 u}{\partial x^2}, \quad 0 < x < \pi, \quad 0 < t \leq T \quad (9.1)$$

с условиями

$$u(x, T) = u_T(x) = g(x), \quad (9.2)$$

$$u(0, t) = \mu(\pi, t) = 0 \quad (9.3)$$

перепишется в виде

$$\frac{\partial u_\alpha}{\partial t} = \frac{\partial^2 u_\alpha}{\partial x^2} + \alpha \frac{\partial^2}{\partial x^2} \left( \frac{\partial u_\alpha}{\partial t} \right), \quad \alpha > 0, \quad 0 < x < \pi, \quad 0 < t \leq T \quad (9.4)$$

с условиями (9.2), (9.3).

В операторном виде задача (9.4), (9.2), (9.3) будет сформулирована так

$$\frac{dy_\alpha}{dt} - Ay_\alpha + \alpha A \frac{dy_\alpha}{dt} = 0, \quad 0 < t \leq T \quad (9.5)$$

с начальным условием

$$y(T) = g(x). \quad (9.6)$$

Для решения задачи (9.4), (9.2), (9.3), аналогично, как и в первом варианте метода квазиобращения была получена оценка

$$\|u_\alpha(x, t)\| \leq e^{\frac{T-t}{\alpha}} \|g(x)\|.$$

Рассмотрим применение псевдопараболической регуляризации для поставленной задачи (7.1) – (7.3).

Задачу (7.1) – (7.3) заменим задачей:

$$\begin{aligned} \frac{\partial v}{\partial t_1} &= a^2 \frac{\partial^2 v}{\partial x^2} + \alpha \frac{\partial^2}{\partial x^2} \left( \frac{\partial u}{\partial t} \right) - f(x, t), \quad \alpha > 0, \\ v(x, 0) &= u_T(x), \\ v(0, t_1) &= \mu_1(t_1), \quad v(l, t_1) = \mu_2(t_1). \end{aligned} \quad (9.7)$$

Для разностной аппроксимации этой задачи введем сетку:

$$\begin{aligned} \bar{\omega}_h &= \left\{ x_i = ih, \quad i = \overline{0, n}, \quad h = \frac{l}{n} \right\}, \quad \bar{\omega}_\tau = \left\{ t_j = j\tau, \quad j = \overline{0, J_0}, \quad \tau = \frac{T}{J_0} \right\}, \\ \bar{\omega}_{ht} &= \bar{\omega}_h \times \bar{\omega}_\tau. \end{aligned}$$

Задачу (9.7) аппроксимируем простейшей разностной схемой:

$$\begin{aligned} \frac{y_i^{j+1} - y_i^j}{\tau} &= -a^2 \Delta y^{j+1} + \alpha \left( \frac{y_{i+1}^{j+1} - y_{i+1}^j}{\tau h^2} - 2 \frac{y_i^{j+1} - y_i^j}{\tau h^2} + \frac{y_{i-1}^{j+1} - y_{i-1}^j}{\tau h^2} \right) - f_i^{j+1} \\ y_i^0 &= u_T(x_i), \\ y_0^{j+1} &= \mu_1^{j+1}, \quad y_n^{j+1} = \mu_2^{j+1}. \end{aligned} \quad (9.8)$$

Схема (9.8) реализуется трехточечной прогонкой.

## § 10. Метод итерационной регуляризации

При решении некорректных задач с большим успехом применяются итерационные методы. В этом случае в качестве параметра регуляризации выступает число итераций.

Рассмотрим линейное операторное уравнение

$$Au = f. \quad (10.1)$$

Для простоты будем считать, что  $u \in H, f \in H$ , т. е.  $A: H \rightarrow H$  и пусть оператор  $A$  самосопряжен и положителен. Предположим, что правая часть уравнения задана с некоторой погрешностью  $\delta$ , т. е. вместо  $f$  известно  $f_\delta$  такое, что

$$\|f - f_\delta\| \leq \delta. \quad (10.2)$$

Тогда ставится задача нахождения приближенного решения  $u_\delta$  уравнения (10.1)

$$Au_\alpha = f_\alpha \quad (10.3)$$

причем параметр  $\alpha$  связан с уровнем погрешности в задании правой части,

$$\text{т. е. } \alpha = \alpha(\delta).$$

Некорректность задачи связана с тем, что собственные значения оператора  $A$ , упорядоченные по убыванию  $(\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_k \geq \dots \geq 0)$ , стремятся к нулю при  $k \rightarrow \infty$  ( $\lambda_k \rightarrow 0$ ).

Общий двухслойный итерационный метод для решения уравнения (10.3) с приближенно заданной правой частью запишется в виде

$$B \frac{u_{k+1} - u_k}{\tau_{k+1}} + Au_k = f_\delta, \quad k = 0, 1, \dots \quad (10.4)$$

Здесь  $B: H \rightarrow H$  и  $B^{-1}$  существует.

Итерационный метод (10.4), его скорость сходимости характеризуется выбором оператора  $B$  и итерационных параметров  $\tau_{k+1}, k = 0, 1, \dots$ .

Чаще всего из-за сложности выбора оператора  $B$  для простоты используются явные итерационные методы ( $B = E$ ), такие как

1) Метод простой итерации

$$\frac{u_{k+1} - u_k}{\tau} + Au_k = f_\delta, \quad k = 0, 1, \dots, \quad (10.5)$$

где спектр оператора  $A$  задан в виде двухстороннего операторного неравенства

$$\gamma_1 E \leq A \leq \gamma_2 E. \quad (10.6)$$

При  $\gamma_1 > 0$  итерационный метод (10.5) сходится в  $H, H_A$  при всех

$$0 < \tau < \frac{2}{\gamma_2}, \quad (10.7)$$

а для числа итераций  $n$ , необходимых для достижения точности  $\varepsilon$ , справедлива оценка

$$n \geq n_0(\varepsilon) = \frac{\ln \varepsilon}{\ln \rho_0},$$

где  $\rho_0 = \frac{1-\xi}{1+\xi}, \quad \xi = \frac{\gamma_1}{\gamma_2}.$

2) Метод скорейшего спуска

$$\frac{u_{k+1} - u_k}{\tau_{k+1}} + Au_k = f_\delta, \quad k = 0, 1, \dots, \quad (10.8)$$

$$\text{в котором } \tau_{k+1} = \frac{(r_k, r_k)}{(Ar_k, r_k)}, \quad (10.9)$$

где  $r_k = Au_k - f_\delta$  – невязка.

Для численного решения ретроспективной задачи (7.1) – (7.3) используем метод простой итерации:

$$\begin{aligned} \frac{y^{s+1}(x_i, t_{j+1}) - y^{s+1}(x_i, t_j)}{\tau} &= a^2 \Delta y^{s+1}(x_i, t_{j+1}) + f_i^{j+1}, \\ y^{s+1}(x_i, t_{j+1})|_{\square} &= \mu_1^{j+1}, \quad y^{s+1}(x_n, t_{j+1}) = \mu_2^{j+1}, \\ y^0(x_i, 0)|_{\square} &= \mu_1(0) + (\mu_2(0) - \mu_1(0)) \frac{ih}{l}, \quad i = \overline{0, n}, \end{aligned} \quad (10.10)$$

$$y^{s+1}(x_i, 0)_{\square} = y^s(x_i, 0) + \delta(u_i^{j_0} - y_i^{j_0}),$$

где  $\delta > 0$  – малое число.

1) Задаем начальное приближение  $s = 0$ ,

$$y^0(x_i, 0)_{\square} = \mu_1(0) + (\mu_2(0) - \mu_1(0)) \frac{ih}{l}, \quad i = \overline{0, n}.$$

2) Схему (10.10) приводим к стандартному виду [21, 32] и решаем методом прогонки в прямом направлении по времени. Дальнейшее уточнение начального условия проведем по формуле:

$$y^{s+1}(x_i, 0)_{\square} = y_i^0 + \delta(u_i^{j_0} - y_i^{j_0}).$$

3) Если  $\max_i \left| y^{s+1}(x_i, 0) - y^s(x_i, 0) \right| \leq \varepsilon$ , то прекращаем итерационный процесс и за решение примем значение сеточной функции на верхней итерации. В противном случае:  $S = S + 1$ ,  $\rightarrow 2$ ).

## § 11. Метод нелокального возмущения начальных условий

Важнейший класс приближенных методов решения некорректных эволюционных задач основан не на переходе к некоторому новому уравнению, как в обычном варианте метода квазиобращения, а на возмущении начальных условий. Такой подход может представляться более естественным и оправданным в задачах, в которых именно начальные условия задаются с погрешностью.

Рассмотрим операторную формулировку задачи (9.1) – (9.3). Пусть вместо обратной задачи

$$\frac{dy}{dt} - Ay = 0, \quad 0 < t \leq T, \quad (11.1)$$

$$y(x, T) = g(x), \quad (11.2)$$

решается прямая задача для уравнения (11.1), когда вместо (11.2) дано начальное условие

$$y(x, 0) = v(x). \quad (11.3)$$

Введем равномерную сетку  $\bar{\omega}_h = \{x \mid x_i = ih, \quad i = \overline{0, n}, \quad nh = \pi\}$ .

Итерационный процесс для задачи (11.1), (11.3) строится следующим образом

$$\frac{y^{n+1}-y^n}{\tau} + \Lambda y^{n+1} = 0, \quad n = 0, 1, \dots, N, \quad (11.4)$$

где  $n$  - временной слой,  $y^0 = v$  – начальное приближение,

$$y^N = S^N y^0, \quad (11.5)$$

где  $S^N$  - оператор перехода с начального слоя на конечный. Из (11.4) оператор  $S$  будет иметь вид

$$S^N = (E + \tau \Lambda)^{-1}. \quad (11.6)$$

Тогда решение обратной задачи сводится к решению сеточного операторного уравнения

$$Lv = g(x), \quad x \in \omega_h, \quad (11.7)$$

где  $L = S^N$ .

Для введения задачи (9.1) – (9.3) в класс корректности переходим к близкой задаче с нелокальным условием, для этого начальное условие (9.2) заменим на

$$u(x, T) + \alpha u(x, 0) = g(x), \quad (11.8)$$

где  $\alpha$  - параметр регуляризации.

Устойчивость полученной задачи доказывается теоремой.

Теорема. Для решения задачи (9.1), (11.3), (9.3) справедлива оценка

$$\|u(x, t)\| \leq \alpha^{-1} \|g(x)\|.$$

Доказательство. Для доказательства применяется метод Фурье. Для простоты будем считать, что оператор  $L$  - дискретный и состоит из собственных значений  $0 < \bar{\lambda}_1 \leq \bar{\lambda}_2 \leq \dots \leq \bar{\lambda}_k$ . Через  $g_k$  обозначим коэффициенты разложения функции  $g(x)$  в базисе по функциям  $\{v_k\}$ . Тогда решение уравнения (9.1), (11.3), (9.3) представимо в виде

$$u(x, t) = \sum_{k=1}^{\infty} \frac{g_k}{(1 + \alpha \exp(\lambda_k T))} \exp(\tilde{\lambda}_k (T - t)) v_k(x).$$

Отсюда находим

$$\|u(x, t)\|^2 = \sum_{k=1}^{\infty} \frac{g_k^2}{(1 + \alpha \exp(\lambda_k T))^2} \exp(2\tilde{\lambda}_k (T - t)) \leq$$



$$\sum_{k=1}^{\infty} \frac{g_k^2}{(1 + \alpha \exp(\lambda_k T))^2} \exp(2\tilde{\lambda}_k T) \leq \sum_{k=1}^{\infty} \frac{g_k^2}{\alpha^2} = \frac{1}{\alpha^2} \|g(x)\|^2.$$

Эта оценка обеспечивает устойчивость по начальным данным.

Рассмотрим применение данного метода к задаче (7.1) – (7.3).

Начальное условие  $u(x, T) = u_T(x)$  заменяем на

$$u(x, T) + \alpha u(x, 0) = u_T(x), \quad \alpha > 0. \quad (11.9)$$

Далее решается корректная задача:

$$\frac{y^{s+1}(x_i, t_{j+1}) - y^{s+1}(x_i, t_j)}{\tau} = a^2 \Delta y^{s+1}(x_i, t_{j+1}) + f_i^{j+1},$$

$$y^{s+1}[\boxminus](x_0, t_{j+1}) = \mu_1^{j+1}, \quad y^{s+1}(x_n, t_{j+1}) = \mu_2^{j+1}, \quad (11.10)$$

$$y^{s+1}[\boxminus](x_i, 0) = \frac{\sigma}{\alpha} (u_T(x_i) - y^s(x_i, T) + (1 - \sigma) y^s(x_i, 0)),$$

где  $\alpha > 0$  - малое число,  $\sigma$  - весовой параметр.

1) Задаем начальное приближение  $s = 0$ ,

$$y^0(x_i, 0) = \mu_1(0) + (\mu_2(0) - \mu_1(0)) \frac{ih}{l}, \quad i = \overline{0, n}.$$

2) Схему (11.10) приводим к стандартному виду и решаем методом прогонки в прямом направлении по времени. Дальнейшее уточнение начального условия проведем по формуле:

$$y^{s+1}[\boxminus](x_i, 0) = \frac{\sigma}{\alpha} (u_T(x_i) - y^s(x_i, T) + (1 - \sigma) y^s(x_i, 0)).$$

3) Если  $\max_i \left| y^{s+1}[\boxminus](x_i, 0) - y^s(x_i, 0) \right| \leq \varepsilon$ , то прекращаем итерационный

процесс и за решение примем значение сеточной функции на верхней итерации. В противном случае:  $s = s + 1, \rightarrow 2$ ).

## § 12. Численная реализация метода квазиобращения для двумерного уравнения теплопроводности

### 1. Постановка задачи

$$\frac{\partial u}{\partial t} = a_1^2 \frac{\partial^2 u}{\partial x_1^2} + a_2^2 \frac{\partial^2 u}{\partial x_2^2} + f(x, t), \quad 0 < x_\alpha < l_\alpha, \quad \alpha = \overline{1, 2}, \quad (12.1)$$

$$0 < t \leq T, \quad x = (x_1, x_2)$$

с начальным условием

$$u(x, T) = u_T(x) \quad (12.2)$$

и краевым условием

$$\begin{aligned} u(0, x_2, t) &= \mu_1^-(x_2, t), \quad u(l_1, x_2, t) = \mu_1^+(x_2, t), \\ u(x_1, 0, t) &= \mu_2^-(x_1, t), \quad u(x_1, l_2, t) = \mu_2^+(x_1, t). \end{aligned} \quad (12.3)$$

Задача (12.1) – (12.3) поставлена некорректно – нет устойчивости по начальным данным.

### 2. Первый вариант метода квазиобращения.

Уравнение (12.1) заменяется уравнением

$$\frac{\partial u}{\partial t} = a_1^2 \frac{\partial^2 u}{\partial x_1^2} + a_2^2 \frac{\partial^2 u}{\partial x_2^2} - \varepsilon^2 \sum_{\alpha=1}^2 \frac{\partial^4 u}{\partial x_\alpha^4} + f(x, t),$$

$$0 < x_\alpha < l_\alpha, \quad \alpha = \overline{1, 2}, \quad 0 < t \leq T, \quad x = (x_1, x_2),$$

где ( $\varepsilon$  - малое положительное число).

С начальным условием (12.2) и краевыми условиями (12.3),

$$\left. \frac{\partial^2 u}{\partial x_1^2} \right|_{x_1=0} = \left. \frac{\partial^2 u}{\partial x_1^2} \right|_{x_1=l_1} = 0, \quad \left. \frac{\partial^2 u}{\partial x_2^2} \right|_{x_2=0} = \left. \frac{\partial^2 u}{\partial x_2^2} \right|_{x_2=l_2} = 0. \quad (12.4)$$

Произведя замену  $\theta = T - \bar{t}$ ,  $\bar{t} = T - \theta$  и после этого получим задачу:

$$\frac{\partial u}{\partial \theta} = -a_1^2 \frac{\partial^2 u}{\partial x_1^2} - a_2^2 \frac{\partial^2 u}{\partial x_2^2} + \varepsilon^2 \sum_{\alpha=1}^2 \frac{\partial^4 u}{\partial x_\alpha^4} + f(x, T - \theta), \quad (12.1')$$

$$0 < x_\alpha < l_\alpha, \quad \alpha = \overline{1, 2}, \quad 0 < \theta \leq T, \quad x = (x_1, x_2)$$

$$u(x, 0) = u_T(x), \quad (12.2')$$

$$u(0, x_2, T - \theta) = \mu_1^-(x_2, T - \theta), \quad u(l_1, x_2, T - \theta) = \mu_1^+(x_2, T - \theta),$$

$u(x_1, 0, T - \theta) = \mu_2^-(x_1, T - \theta), \quad u(x_1, l_2, T - \theta) = \mu_2^+(x_1, T - \theta), \quad (12.3')$   
с дополнительными условиями (12.4).

Введем равномерную сетку

$$\bar{\omega}_{h_1} = \left\{ x_{1i} = ih_1, i = \overline{0, n_1}, h_1 = \frac{l_1}{n_1} \right\}, \quad \bar{\omega}_{h_2} = \left\{ x_{2j} = jh_2, j = \overline{0, n_2}, h_2 = \frac{l_2}{n_2} \right\},$$

$$\bar{\omega}_h = \bar{\omega}_{h_1} \times \bar{\omega}_{h_2}, \quad \bar{\omega}_\tau = \left\{ \theta_k = k\tau, k = \overline{0, m}, \tau = \frac{T}{m} \right\},$$

$$\bar{\omega}_{h\tau} = \bar{\omega}_h \times \bar{\omega}_\tau.$$

Задачу (12.1') – (12.3'), (12.4) аппроксимируем на этой сетке схемой расщепления с последовательным переходом:

$$\frac{z_{ij}^{k+1} - z_{ij}^k}{\tau} = -a_1^2 \Lambda_1(\sigma_1 z^{k+1} + (1 - \sigma_1)y^k) + \varepsilon^2 \Lambda_1^2(\sigma_2 z^{k+1} + (1 - \sigma_2)y^k), \quad (12.5)$$

$$z_{ij}^0 = u_T(x_i), \quad z_{ij}^k = y_{ij}^k, \quad (12.6)$$

$$z_{0j}^{k+1} = \mu_1^{-k+1}, \quad z_{n_1j}^{k+1} = \mu_1^{+k+1}, \quad (12.7)$$

$$\frac{z_{0j}^{k+1} - 2z_{1j}^{k+1} + z_{2j}^{k+1}}{h_1^2} = 0, \quad \frac{z_{n_1-2,j}^{k+1} - 2z_{n_1-1,j}^{k+1} + z_{n_1j}^{k+1}}{h_1^2} = 0; \quad (12.8)$$

$$\frac{y_{ij}^{k+1} - z_{ij}^{k+1}}{\tau} = -a_2^2 \Lambda_2(\sigma_1 y^{k+1} + (1 - \sigma_1)z^{k+1}) + \varepsilon^2 \Lambda_2^2(\sigma_2 y^{k+1} + (1 - \sigma_2)z^{k+1}) + f_{ij}^{m-k}, \quad (12.9)$$

$$y_{i0}^{k+1} = \mu_2^{-k+1}, \quad y_{in_2}^{k+1} = \mu_2^{+k+1}, \quad (12.10)$$

$$\frac{y_{i0}^{k+1} - 2y_{i1}^{k+1} + y_{i2}^{k+1}}{h_2^2} = 0, \quad \frac{y_{in_2-2}^{k+1} - 2y_{in_2-1}^{k+1} + y_{in_2}^{k+1}}{h_2^2} = 0. \quad (12.11)$$

Полученные схемы (12.5) – (12.8), (12.9) – (12.11) сводятся к пятиточечным системам (7.8), которые реализуются пятиточечным прогонкам (7.9), (7.10).

Задача для тестовых расчетов.

$$\begin{aligned} f(x_1, x_2, t) &= ABe^{B(x_1+x_2+t)}[1 - (a_1^2 + a_2^2)B], \\ \mu_1^- &= Ae^{B(x_2+t)}, \quad \mu_1^+ = Ae^{B(l_1+x_2+t)}, \quad \mu_2^- = Ae^{B(x_1+t)}, \\ \mu_2^+ &= Ae^{B(x_1+l_2+t)}, \quad u_T(x) = Ae^{B(x_1+x_2+T)}, \end{aligned}$$

$l_1 = 0,5, l_2 = 0,5, T = 1, A = 2, B = \{-1; 1\}, a_1 = 10, a_2 = 10.$   
Точное решение:  $u = Ae^{B(x_1+x_2+t)}.$

### § 13. Прием расщепления разностного оператора четвертого порядка для метода квазиобращения

Задачу (12.1') – (12.3'), (12.4) расщепим на четыре задачи:

$$\begin{aligned} \frac{\partial u_1}{\partial t} &= -a_1^2 \frac{\partial^2 u_1}{\partial x_1^2}, \quad 0 < x_1 < l_1, \quad \theta_k < \theta \leq \theta_{k+1}, \\ u_1(x, 0) &= u_T(x), \quad x = (x_1, x_2), \quad u_1(x, \theta_k) = u_n(x, \theta_k), \\ u_1(0, x_2, \theta) &= \mu_1^-, \quad u_1(l_1, x_2, \theta) = \mu_1^+; \end{aligned} \quad (13.1)$$

$$\begin{aligned} \frac{\partial u_2}{\partial \theta} &= \varepsilon^2 \frac{\partial^4 u_2}{\partial x_1^4}, \quad 0 < x_1 < l_1, \quad \theta_k < \theta \leq \theta_{k+1}, \\ u_2(x, \theta_k) &= u_1(x, \theta_{k+1}), \\ u_2(0, x_2, \theta) &= \mu_1^-, \quad u_2(l_1, x_2, \theta) = \mu_1^+; \end{aligned} \quad (13.2)$$

$$\begin{aligned} \left. \frac{\partial^2 u_2}{\partial x_1^2} \right|_{x_1=0} &= \left. \frac{\partial^2 u_2}{\partial x_1^2} \right|_{x_1=l_1} = 0; \\ \frac{\partial u_3}{\partial \theta} &= -a_2^2 \frac{\partial^2 u_3}{\partial x_2^2}, \quad 0 < x_2 < l_2, \quad \theta_k < \theta \leq \theta_{k+1}, \\ u_3(x, \theta_k) &= u_2(x, \theta_{k+1}), \\ u_3(x_1, 0, \theta) &= \mu_2^-, \quad u_3(x_1, l_2, \theta) = \mu_2^+; \end{aligned} \quad (13.3)$$

$$\begin{aligned} \frac{\partial u_4}{\partial \theta} &= \varepsilon^2 \frac{\partial^4 u_4}{\partial x_2^4} + f(x, T - \theta), \quad 0 < x_2 < l_2, \quad \theta_k < \theta \leq \theta_{k+1}, \\ u_4(x, \theta_k) &= u_3(x, \theta_{k+1}), \\ u_4(x_1, 0, \theta) &= \mu_2^-, \quad u_4(x, l_2, \theta) = \mu_2^+, \\ \left. \frac{\partial^2 u_4}{\partial x_2^2} \right|_{x_2=0} &= \left. \frac{\partial^2 u_4}{\partial x_2^2} \right|_{x_2=l_2} = 0. \end{aligned} \quad (13.4)$$

Задачу (13.1) – (13.4) аппроксимируем разностной схемой:

$$\begin{aligned} \frac{\omega_{ij}^{k+1} - y_{ij}^k}{\tau} &= -a_1^2 \Lambda_1 \omega^{k+1}, \\ y_{ij}^0 &= u_T(x_{ij}), \quad \omega_{ij}^k = y_{ij}^k, \\ \omega_{0j}^{k+1} &= \mu_1^{-k+1}, \quad \omega_{n_1 j}^{k+1} = \mu_1^{+k+1}; \end{aligned} \quad (13.5)$$

$$\begin{aligned}
\frac{v_{ij}^{k+1} - \omega_{ij}^{k+1}}{\tau} &= \varepsilon^2 \Lambda_1^2 v^{k+1}, \\
v_{0j}^{k+1} &= \mu_1^{-k+1}, v_{n_1 j}^{k+1} = \mu_1^{+k+1}, \\
\frac{v_{0j}^{k+1} - 2v_{1j}^{k+1} + v_{2j}^{k+1}}{h_1^2} &= 0, \quad \frac{v_{n_1-2,j}^{k+1} v_{n_1-1,j}^{k+1} + v_{n_1 j}^{k+1}}{h_1^2} = 0;
\end{aligned} \tag{13.6}$$

$$\begin{aligned}
\frac{z_{ij}^{k+1} - z_{ij}^{k+1}}{\tau} &= -a_2^2 \Lambda_2 z^{k+1}, \\
z_{i0}^{k+1} &= \mu_2^{-k+1}, z_{in_2}^{k+1} = \mu_2^{+k+1}, \\
\frac{y_{ij}^{k+1} - z_{ij}^{k+1}}{\tau} &= \varepsilon^2 \Lambda_2^2 z^{k+1} + f_{ij}^{m-k},
\end{aligned} \tag{13.7}$$

$$\begin{aligned}
y_{i0}^{k+1} &= \mu_2^{-k+1}, y_{in_2}^{k+1} = \mu_2^{+k+1}, \\
\frac{y_{i0}^{k+1} - 2y_{i1}^{k+1} + y_{i2}^{k+1}}{h_2^2} &= 0, \quad \frac{y_{in_2-2}^{k+1} - 2y_{in_2-1}^{k+1} + y_{in_2}^{k+1}}{h_2^2} = 0.
\end{aligned} \tag{13.8}$$

Схемы (13.5), (13.7) реализуются трехточечными прогонками, а схемы (13.6), (13.8) – пятиточечными прогонками. Чтобы упростить реализацию схем (13.6) и (13.8) используем прием расщепления разностного оператора четвертого порядка на два оператора второго порядка [20]. После этого разностные схемы примут следующий вид:

$$\begin{aligned}
\frac{\omega_{ij}^{k+1} - y_{ij}^k}{\tau} &= -a_1^2 \Lambda_1 \omega^{k+1}, \\
y_{ij}^0 &= u_T(x_{ij}), \quad \omega_{ij}^k = y_{ij}^k,
\end{aligned} \tag{13.9}$$

$$\begin{aligned}
\omega_{0j}^{k+1} &= \mu_1^{-k+1}, \quad \omega_{n_1 j}^{k+1} = \mu_1^{+k+1}; \\
\tilde{\omega}_{ij}^{k+1} &= \omega_{ij}^{k+1} + \varepsilon \frac{\sqrt{\tau}}{h_1^2} (\omega_{i-1,j}^{k+1} - 2\omega_{ij}^{k+1} + \omega_{i+1,j}^{k+1}), \\
\tilde{\omega}_{0j}^{k+1} &= \mu_1^{-k+1}, \quad \tilde{\omega}_{n_1 j}^{k+1} = \mu_1^{+k+1}, \\
v_{ij}^{k+1} &= \tilde{\omega}_{ij}^{k+1} + \varepsilon \frac{\sqrt{\tau}}{h_1^2} (\tilde{\omega}_{i-1,j}^{k+1} - 2\tilde{\omega}_{ij}^{k+1} + \tilde{\omega}_{i+1,j}^{k+1}),
\end{aligned} \tag{13.10}$$

$$\begin{aligned}
v_{0j}^{k+1} &= \mu_1^{-k+1}, \quad v_{n_1 j}^{k+1} = \mu_1^{+k+1}; \\
\frac{z_{ij}^{k+1} - v_{ij}^k}{\tau} &= -a_2^2 \Lambda_2 z^{k+1}, \\
z_{i0}^{k+1} &= \mu_2^{-k+1}, \quad z_{in_2}^{k+1} = \mu_2^{+k+1};
\end{aligned} \tag{13.11}$$

$$\begin{aligned}
\tilde{z}_{ij}^{k+1} &= z_{ij}^{k+1} + \varepsilon \frac{\sqrt{\tau}}{h_2^2} (z_{ij-1}^{k+1} - 2z_{ij}^{k+1} + z_{ij+1}^{k+1}), \\
\tilde{z}_{i0}^{k+1} &= \mu_2^{-k+1}, \quad \tilde{z}_{in_2}^{k+1} = \mu_2^{+k+1}; \\
y_{ij}^{k+1} &= \tilde{z}_{ij}^{k+1} + \varepsilon \frac{\sqrt{\tau}}{h_2^2} (z_{ij-1}^{k+1} - 2\tilde{z}_{ij}^{k+1} + \tilde{z}_{ij+1}^{k+1}) + f_{ij}^{m-k}, \\
y_{i0}^{k+1} &= \mu_2^{-k+1}, \quad y_{in_2}^{k+1} = \mu_2^{+k+1}.
\end{aligned} \tag{13.12}$$

Теперь не нужны дополнительные условия (12.8) и (12.11), используемые в методе квазиобращения. Схемы (13.9), (13.11) реализуются трехточечными прогонками, а схемы (13.10), (13.12) – явно.

## § 14. Второй вариант метода квазиобращения

Уравнение (12.1) заменим следующим уравнением

$$\frac{\partial u}{\partial t} = a_1^2 \frac{\partial^2 u}{\partial x_1^2} + a_2^2 \frac{\partial^2 u}{\partial x_2^2} - \varepsilon \left( \frac{\partial^4 u}{\partial x_1^4} + 2 \frac{\partial^4 u}{\partial x_1^2 \partial x_2^2} + \frac{\partial^4 u}{\partial x_2^4} \right), \tag{14.1}$$

$$0 < x_\alpha < l_\alpha, \quad \alpha = \overline{1,2}, \quad 0 < t \leq T, \quad x = (x_1, x_2)$$

с начальным условием (12.2), краевыми условиями (12.3) и дополнительными условиями (12.4).

Введем замену  $\theta = T - t$ ,  $t = T - \theta$ . Тогда решается краевая задача

$$\frac{\partial u}{\partial \theta} = -a_1^2 \frac{\partial^2 u}{\partial x_1^2} - a_2^2 \frac{\partial^2 u}{\partial x_2^2} + \varepsilon \left( \frac{\partial^4 u}{\partial x_1^4} + 2 \frac{\partial^4 u}{\partial x_1^2 \partial x_2^2} + \frac{\partial^4 u}{\partial x_2^4} \right), \tag{14.2}$$

$$0 < x_\alpha < l_\alpha, \quad \alpha = \overline{1,2}, \quad 0 < \theta \leq T, \quad x = (x_1, x_2)$$

с начальным условием (12.2'), краевыми условиями (12.3') и дополнительными условиями (12.4).

Задачу (14.2), (12.2'), (12.3'), (12.4) расщепим на две задачи.

Первая задача будет представлять собой задачу (12.1') – (12.3'), (12.4), только в этом случае параметр  $\varepsilon$  будет без квадрата. Тогда решение первой задачи будет служить начальным условием для второй задачи, которая запишется в следующем виде:

$$\frac{\partial u}{\partial \theta} = 2\varepsilon \frac{\partial^4 u}{\partial x_1^2 \partial x_2^2}, \quad 0 < x_\alpha < l_\alpha, \quad \alpha = \overline{1,2}, \quad \theta_k < \theta < \theta_{k+1} \tag{14.3}$$

с краевыми условиями (12.3') и дополнительным условием (12.4). Эту задачу аппроксимируем разностной схемой:

$$\begin{aligned} \frac{y_{ij}^{k+1} - y_{ij}^k}{\tau} = & 2\varepsilon \frac{y_{i+1,j+1}^{k+1} - 2y_{ij+1}^{k+1} + y_{i-1,j+1}^{k+1}}{h_1^2 h_2^2} - 4\varepsilon \frac{y_{i+1,j}^{k+1} - 2y_{ij}^{k+1} + y_{i-1,j}^{k+1}}{h_1^2 h_2^2} \\ & + \\ & 2\varepsilon \frac{y_{i+1,j-1}^{k+1} - 2y_{ij-1}^{k+1} + y_{i-1,j-1}^{k+1}}{h_1^2 h_2^2}, \end{aligned} \quad (14.4)$$

$$y_{0j}^{k+1} = \mu_1^{-k+1}, y_{n_1 j}^{k+1} = \mu_1^{+k+1}, y_{i0}^{k+1} = \mu_2^{-k+1}, y_{i n_2}^{k+1} = \mu_2^{+k+1} \quad (14.5)$$

Обозначим  $y_{ij}^{k+1} = y(i, j)$ ,  $y_{ij}^k = \check{y}_{ij}$  и упорядочим неизвестные естественным образом, начиная с нижней строки:

$$\begin{aligned} & -\frac{2\varepsilon}{h_1^2 h_2^2} y(i-1, j-1) + \frac{4\varepsilon}{h_1^2 h_2^2} y(i, j-1) - \frac{2\varepsilon}{h_1^2 h_2^2} y(i+1, j-1) + \\ & \frac{4\varepsilon}{h_1^2 h_2^2} y(i-1, j) + \left( \frac{1}{\tau} - \frac{8\varepsilon}{h_1^2 h_2^2} \right) y(i, j) + \frac{4\varepsilon}{h_1^2 h_2^2} y(i+1, j) - \\ & \frac{2\varepsilon}{h_1^2 h_2^2} y(i-1, j+1) + \frac{4\varepsilon}{h_1^2 h_2^2} y(i, j+1) - \frac{2\varepsilon}{h_1^2 h_2^2} y(i+1, j+1) = \\ & \frac{1}{\tau} \check{y}(i, j), \quad i = \overline{1, n_1 - 1}, \quad j = \overline{1, n_2 - 1}, \end{aligned} \quad (14.6)$$

$$\begin{aligned} y(0, j) &= \mu_1^{-k+1}, \quad y(n_1, j) = \mu_1^{+k+1}, \\ y(i, 0) &= \mu_2^{-k+1}, \quad y(i, n_2) = \mu_2^{+k+1}. \end{aligned} \quad (14.7)$$

Полученная девятиточечная схема (14.6) – (14.7) можно решить с помощью любого метода, применяемого при решении уравнений со смешанными производными, например, с помощью метода простой итерации

$$\begin{aligned} y_{\square}^{s+1}(i, j) = & \frac{2\tau\varepsilon}{h_1^2 h_2^2 - 8\tau\varepsilon} (y^s(i-1, j-1) - 2y^s(i, j-1) + y^s(i+1, j-1) - \\ & 2y^s(i-1, j) - 2y^s(i+1, j) + y^s(i-1, j+1) - \\ & 2y^s(i, j+1) + y^s(i+1, j+1)) + \check{y}(i, j) \frac{h_1^2 h_2^2}{h_1^2 h_2^2 - 8\tau\varepsilon}, \\ & i = \overline{1, n_1 - 1}, \quad j = \overline{1, n_2 - 1}, \\ y_{\square}^{s+1}(0, j) &= \mu_1^{-k+1}, \quad y_{\square}^{s+1}(n_1, j) = \mu_1^{+k+1}, \end{aligned}$$

$$y_{\square}^{s+1}(i, 0) = \mu_2^{-k+1}, \quad y_{\square}^{s+1}(i, n_2) = \mu_2^{+k+1},$$

где  $s = 0, 1, 2, \dots$  – номера итерации.

За начальное приближение можно взять решение предыдущей задачи.

Условие выхода из итерационного процесса зададим в следующем виде

$$\sqrt{\sum_{i,j=1}^{n_1;n_2} \left| y_{\square}^{s+1}(i, j) - y_{\square}^s(i, j) \right|^2} < \varepsilon_1.$$

После нахождения решения задачи (14.6), (14.7) переходим на новый временной слой.

## § 15. Псевдопараболическая регуляризация для двумерного уравнения

Уравнение (12.1) заменяется уравнением

$$\frac{\partial u}{\partial t} = a_1^2 \frac{\partial^2 u}{\partial x_1^2} + a_2^2 \frac{\partial^2 u}{\partial x_2^2} - \varepsilon \sum_{\alpha=1}^2 \frac{\partial^2}{\partial x_{\alpha}^2} \left( \frac{\partial u}{\partial t} \right), \quad 0 < x_{\alpha} < l_{\alpha}, \quad \alpha = \overline{1, 2},$$

$$0 < t \leq T, x = (x_1, x_2),$$

( $\varepsilon$  - малое положительное число), с начальным условием (12.2) и краевыми условиями (12.3).

Введем замену  $\theta = T - t$ ,  $t = T - \theta$ , тогда будет решаться краевая задача для уравнения теплопроводности

$$\frac{\partial u}{\partial \theta} = -a_1^2 \frac{\partial^2 u}{\partial x_1^2} - a_2^2 \frac{\partial^2 u}{\partial x_2^2} - \varepsilon \sum_{\alpha=1}^2 \frac{\partial^2}{\partial x_{\alpha}^2} \left( \frac{\partial u}{\partial \theta} \right) - f(x, T - \theta), \quad (15.1)$$

$$0 < x_{\alpha} < l_{\alpha}, \alpha = \overline{1, 2}, 0 < \theta \leq T, x = (x_1, x_2)$$

с начальным условием (12.2') и краевыми условиями (12.3').

На равномерной сетке задачу (15.1), (12.2'), (12.3') аппроксимируем схемой расщепления:

$$\frac{z_{ij}^{k+1} - y_{ij}^k}{\tau} = -a_1^2 \Lambda_1 (\sigma z_{ij}^{k+1} + (1 - \sigma) y_{ij}^k) -$$



$$\varepsilon \left( \frac{z_{i+1j}^{k+1} - y_{ij}^k}{\tau h_1^2} - 2 \frac{z_{ij}^{k+1} - y_{ij}^k}{\tau h_1^2} + \frac{z_{i-1j}^{k+1} - y_{i-1j}^k}{\tau h_1^2} \right),$$

$$y_{ij}^0 = u_T(x_i), \quad z_{ij}^k = y_{ij}^k, \quad (15.2)$$

$$z_{0j}^{k+1} = \mu_1^{-k+1}, \quad z_{n_1j}^{k+1} = \mu_1^{+k+1};$$

$$\frac{y_{ij}^{k+1} - z_{ij}^{k+1}}{\tau} = -a_2^2 \Lambda_2 (\sigma y_{ij}^{k+1} + (1 - \sigma) z_{ij}^{k+1}) -$$

$$\varepsilon \left( \frac{y_{i+1j}^{k+1} - z_{ij}^{k+1}}{\tau h_2^2} - 2 \frac{y_{ij}^{k+1} - z_{ij}^{k+1}}{\tau h_2^2} + \frac{y_{i-1j}^{k+1} - z_{i-1j}^{k+1}}{\tau h_2^2} \right) - f_{ij}^{m-k}, \quad (15.3)$$

$$y_{i0}^{k+1} = \mu_2^{-k+1}, \quad z_{in_2}^{k+1} = \mu_2^{+k+1}.$$

Схемы (15.2) – (15.3) реализуются трехточечными прогонками.

## § 16. Итерационное уточнение начального условия

Начальное условие  $u(x, T) = u_T(x)$  заменяем на нелокальное условие

$$u(x, T) + \alpha u(x, 0) = u_T(x), \quad \alpha > 0. \quad (16.1)$$

Теперь решается корректная задача (12.1), (16.1), (12.3). Для разностной аппроксимации полученной задачи введем равномерную сетку:

$$\bar{\omega}_{h_1} = \left\{ x_{1i_1} = i_1 h_1, \quad i_1 = \overline{0, n_1}, \quad h_1 = \frac{l_1}{n_1} \right\}, \quad \bar{\omega}_{h_2} = \{ x_{2i_2} = i_2 h_2, \quad i_2 = \overline{0, n_2},$$

$$h_2 = \frac{l_2}{n_2} \}, \quad \bar{\omega}_h = \bar{\omega}_{h_1} \times \bar{\omega}_{h_2}, \quad \bar{\omega}_\tau = \left\{ t_k = k\tau, \quad k = \overline{0, m}, \quad \tau = \frac{T}{m} \right\},$$

$$\bar{\omega}_{h\tau} = \bar{\omega}_h \times \bar{\omega}_\tau.$$

Строим итерационный процесс:

1) задаем начальное приближение  $s = 0$

$$y_{ij}^0 = \mu_1^+(0) + (\mu_1^-(0) - \mu_1^+(0)) \frac{ih_1}{l_1} + \mu_2^+(0) + (\mu_2^-(0) - \mu_2^+(0)) \frac{jh_2}{l_2},$$

$$i = \overline{0, n_1}, \quad j = \overline{0, n_2};$$

2) аппроксимируем уравнение (12.1) с краевыми условиями (12.3):

$$\frac{{}^{s+1}z_{ij}(t_{k+1}) - {}^{s+1}y_{ij}(t_k)}{\tau} = a_1^2 \Lambda_1 {}^{s+1}z_{ij}(t_{k+1}),$$

$${}^{s+1}z_{0j}(t_{k+1}) = \mu_1^{-k+1}, {}^{s+1}z_{n_1j}(t_{k+1}) = \mu_1^{+k+1}, {}^{s+1}z_{ij}(t_k) = {}^{s+1}y_{ij}(t_k); \quad (16.2)$$

$$\frac{{}^{s+1}y_{ij}(t_{k+1}) - {}^{s+1}z_{ij}(t_{k+1})}{\tau} = a_2^2 \Lambda_2 {}^{s+1}y_{ij}(t_{k+1}) + f_{ij}^{k+1},$$

$${}^{s+1}y_{i0}(t_{k+1}) = \mu_2^{-k+1}, {}^{s+1}z_{in_2}(t_{k+1}) = \mu_2^{+k+1};$$

3) схему (16.2) приводим к стандартному виду и решаем трехточечными прогонками в прямом направлении по времени. Дальнейшее уточнение начального условия проведем по формуле:

$${}^{s+1}y_{ij}(0) = \frac{\sigma}{\alpha} \left( u(ih_1, jh_2, m) - {}^s y_{ij}^m \right) + (1 - \sigma) {}^s y_{ij}(0),$$

$\alpha > 0$  - малое число,  $\sigma$  - весовой параметр;

$$4) \text{ если } \max_{ij} \left| {}^{s+1}y_{ij}^0 - {}^s y_{ij}^0 \right| < \varepsilon, \text{ то прекращаем итерационный процесс и}$$

за решение примем значение сеточной функции на верхней итерации. В противном случае  $s = s + 1, \rightarrow 2$ ).

## Литература

1. Адамар Ж. Задача Коши для линейных уравнений с частными производными гиперболического типа. – М.: Наука, 1978. – 351 с.
2. Алифанов О. М. Обратные задачи теплообмена. – М.: Машиностроение, 1988. -280 с.
3. Алифанов О. М., Артюхин Е. А., Румянцев С. В. Экстремальные методы решения некорректных задач. – М.: Наука, 1988. – 288 с.
4. Атамбаев С. А. Методическая разработка по разделу вычислительной математики «Условно-корректные задачи для эволюционных уравнений». – Алма-Ата, изд. Каз. ГУ, 1986. – 43 с.

5. Вабищевич П. Н. Численное моделирование. – М.: Изд-во МГУ, 1993. – 152 с.
6. Вабищевич П. Н. Нелокальные параболические задачи и обратная задача теплопроводности // Диффер. уравнения, 1981, т. 27, № 7. – С. 1193-1199.
7. Боев Н. В., Ватульян А. О., Сумбатян М. А. Восстановление контура препятствия по характеристикам рассеянного акустического поля в коротковолновой области // Акуст. журн., 1997, № 4. – С. 458-462.
8. Вайникко Г. М., Веретенников А. Ю. Итерационные процедуры в некорректных задачах. – М.: Наука, 1986. – 181 с.
9. Ватульян А. О. Математические модели и обратные задачи // Соросовский образовательный журнал, 1998, № 11. – С. 143-147.
10. Денисов А. М. Введение в теорию обратных задач. – М.: Изд-во МГУ, 1994. – 208 с.
11. Калиткин Н. Н. Численные методы. – М.: Наука, 1978. – 512 с.
12. Лаврентьев М. М., Резницкая К. Г., Яхно В. Г. Одномерные обратные задачи математической физики. – Новосибирск: Наука, 1982. – 88 с.
13. Латтес Р., Лионс Ж. Л. Метод квазиобращения и его приложения. – М.: Мир, 1970. – 336 с.
14. Лионс Ж. Л. Оптимальное управление системами, описываемые уравнениями с частными производными. – М.: Наука, 1975. – 416 с.
15. Математический энциклопедический словарь. – М.: Советская энциклопедия, 1988. – С. 400-401.
16. Марчук Г. И. Методы вычислительной математики. – М.: Наука, 1977. – 456 с.
17. Охлопков Н. М. Об экономичных методах решения задач математической физики. – Якутск: Изд. ЯГУ, 1982. – 132 с.
18. Охлопков Н. М. Численные методы решения краевых задач математической физики. – Якутск: Изд. ЯГУ, 1993. – 177 с.
19. Охлопков Н. М., Охлопков Г. Н. Вычислительные алгоритмы решения некоторых задач алгебры. – Якутск: Изд. ЯГУ, 1996. – С. 18-20.

20. Охлопков Н. М., Охлопков Г. Н. Численные методы решения некорректных задач математической физики. – Якутск: ЯФ СО РАН, 2002. – 72 с.
21. Охлопков Н. М., Иванов Ф. В. Методы вычислений (задачи математической физики). – Якутск: Изд. ЯГУ, 2008. – 111 с. ([http: // Sitim. Sitc. ru](http://Sitim.Sitc.ru))
22. Самарский А. А. Теория разностных схем. – М.: Наука, 1977. – 656 с.
23. Самарский А. А., Андреев В. Б. Разностные методы для эллиптических уравнений. – М.: Наука, 1976. – 352 с.
24. Самарский А. А., Николаев Е. С. Методы решения сеточных уравнений. – М.: Наука, 1978. – 592 с.
25. Самарский А. А., Вабищевич П. Н. Численные методы решения обратных задач математической физики. – М.: Едиториал УРСС, 2004. – 480 с.
26. Тихонов А. Н. О решении некорректно поставленных задач и методе регуляризации // Докл. АН СССР, 1963, т. 151, т. 153, № 1, № 3. – С. 49-52, С. 501-504.
27. Тихонов А. Н. Об устойчивости обратных задач // Докл. АН СССР, 1943, т. 39, № 5.
28. Тихонов А. Н., Арсенин В. Я. Методы решения некорректных задач. – М.: Наука, 1986. – 287 с.
29. Тихонов А. Н., Арсенин В. Я., Тимонов А. А. Математические задачи компьютерной томографии. – М.: Наука, 1987. – 160 с.
30. Тихонов А. Н., Самарский А. А. Уравнения математической физики. – М.: Наука, 1972. – 736 с.
31. Hadamard J. Le problem de Carchy et jes equations aux derives partielles lincaire hypeboliques. Paris: Hermann, 1932.
32. Охлопков Н. М., Иванов Ф. В. Численные методы: теория и практика: учебное пособие. – Якутск: Издательский дом СВФУ. 2016. – 370 с.

**Учебное издание**

*Охлопков Николай Михайлович, Иванов Федор Васильевич*

**ЧИСЛЕННЫЕ МЕТОДЫ  
И ВЫЧИСЛИТЕЛЬНЫЕ АЛГОРИТМЫ**

Учебное пособие

Выпускается в авторской редакции

Дата подписания к использованию 05.02.2018. Электронное издание.

Объем 3,63 Мб. Тираж 10 дисков. Заказ № 20.

Минимальные системные требования:

процессор с тактовой частотой 1,3 ГГц и выше, оперативная память 128 Мб,  
операционные системы: Microsoft Windows XP/Vista/7/8/10, ОС MAC OS версии 10,8.

Издательский дом Северо-Восточного федерального университета  
677891, г. Якутск, ул. Петровского, 5.

Изготовлено с готового оригинал-макета в ИД СВФУ